GOOGLE CLOUD CERTIFIED · ASSOCIATE DATA PRACTITIONER

Cheatsheet ADP Pahami, Bukan Sekadar Hafal

Semua materi exam guide v1.0, tabel keputusan, kata kunci soal, dan ringkasan last-minute, dalam Bahasa Indonesia

D1 · 30% D2 · 27% D3 · 18% D4 · 25%

Disusun untuk: Muhammad Yusuf Ridho

Acuan: Associate Data Practitioner Exam Guide v1.0 + dokumentasi Google Cloud (dicek Oktober 2026)

Daftar Isi

1. Gambaran Ujian ADP 4
Tips menjawab soal skenario 4
2. Domain 1 — Data Preparation & Ingestion (~30%) 5
1.1 Prepare and process data 5
1.2 Extract and load data into appropriate storage 5
3. Domain 2 — Data Analysis & Presentation (~27%) 6
2.1 Trends & insights dengan BigQuery dan Jupyter notebooks 6
2.2 Dashboard dengan Looker 6
2.3 Define, train, evaluate, and use ML models 6
4. Domain 3 — Data Pipeline Orchestration (~18%) 8
3.1 Design and implement simple data pipelines 8
3.2 Schedule, automate, and monitor 8
5. Domain 4 — Data Management (~25%) 9
4.1 Access control & governance 9
4.2 Lifecycle management 9
4.3 High availability & disaster recovery (GCS & Cloud SQL) 9
4.4 Security & compliance 9
6. Tabel Perbandingan (yang Sering Tertukar) 10
6.1 Cloud Storage storage classes 10
6.2 Autoclass vs Lifecycle vs Retention vs Object Hold 10
6.3 Lokasi: region vs dual-region vs multi-region 10
6.4 Memilih storage 11
6.5 ETL vs ELT vs ETLT 11
6.6 Tool transformasi: Dataflow vs Dataproc vs Data Fusion vs Dataprep vs Dataform 11
6.7 Orkestrasi & penjadwalan 12
6.8 Memindahkan data: STS vs Transfer Appliance vs BQ DTS vs Datastream vs DMS 12

6.9 BigLake vs BigQuery Omni vs External table **13**

6.10 View vs Authorized view vs Materialized view vs Snapshot vs Clone **13**

6.11 Looker vs Looker Studio **13**

6.12 BigQuery ML vs AutoML vs model custom **13**

6.13 Cloud SQL: HA vs Read replica vs Backup/PITR **14**

6.14 IAM: role penting **14**

6.15 Enkripsi: Google-managed vs CMEK vs CSEK **14**

6.16 Governance, sharing, messaging & observability **15**

7. Kata Kunci di Soal → Jawaban **16**

8. Fokus Kamu — Topik Lemah dari Catatan Latihanmu **18**

9. Ringkasan Last-Minute (1 Halaman) **19**

1. Gambaran Ujian ADP

Item	Detail (sumber: halaman sertifikasi resmi Google Cloud)
Durasi	2 jam
Jumlah & format soal	50–60 soal multiple choice (pilih satu) dan multiple select (pilih dua atau lebih)
Biaya	USD 125 (+ pajak)
Bahasa	English, Japanese
Cara ujian	Online-proctored (dari rumah) atau di test center
Prasyarat	Tidak ada. Rekomendasi: 6+ bulan pengalaman mengolah data di Google Cloud
Masa berlaku	3 tahun. Perpanjangan dengan mengulang ujian, jendela dibuka 180 hari sebelum kedaluwarsa
Passing score	Tidak dipublikasikan oleh Google

Domain (exam guide v1.0)	Bobot	Inti yang diuji
1. Data Preparation and Ingestion	~30%	ETL/ELT, tool transfer, kualitas & pembersihan data, format file, memilih storage & lokasi, cara load
2. Data Analysis and Presentation	~27%	SQL BigQuery, notebook (Colab Enterprise), Looker vs Looker Studio, LookML, BigQuery ML, LLM via remote model
3. Data Pipeline Orchestration	~18%	Memilih tool transformasi, ETL vs ELT, scheduling, monitoring, orkestrasi, event-driven (Pub/Sub, Eventarc)
4. Data Management	~25%	IAM least privilege, akses GCS, Analytics Hub, lifecycle, storage class, HA/DR, enkripsi (CMEK/CSEK/KMS)

Tips menjawab soal skenario

- **Cari kata kunci batasan** di soal: "least operational overhead", "serverless", "minimal code", "cost-effective", "near real-time", "least privilege", "without moving data". Biasanya justru kata kunci inilah yang menentukan jawaban.
- **Google suka jawaban managed/serverless.** Kalau dua opsi sama-sama benar secara teknis, pilih yang paling sedikit pengelolaannya. Opsi seperti VM + cron atau skrip custom hampir selalu salah.
- **Pilih yang paling sederhana yang memenuhi semua syarat.** Composer untuk satu query terjamin berlebihan, jadi scheduled query lebih tepat.
- **Eliminasi dulu.** Buang opsi yang melanggar satu syarat (misalnya memindahkan data padahal dilarang), baru pilih di antara sisanya.
- **Multiple select:** jumlah jawaban selalu disebut di soal ("Choose two"). Setiap pilihan harus benar sendiri-sendiri.
- **Manajemen waktu:** sekitar 2 menit per soal. Tandai (mark for review) soal yang ragu, lalu lanjut.

> ⚠ **CATATAN**
>
> **Nama produk berubah (rebranding).** Ujian memakai nama di exam guide v1.0, jadi cheatsheet ini juga memakai nama itu. Nama terbaru di dokumentasi: **Analytics Hub → "BigQuery sharing"**; **Dataplex / Dataplex Universal Catalog → "Knowledge Catalog"** (sejak 10 April 2026); **Vertex AI → "Gemini Enterprise Agent Platform"**. Halaman sertifikasi juga menyebut ujian "akan segera diperbarui" untuk nama-nama baru ini.

2. Domain 1 — Data Preparation & Ingestion (~30%)

1.1 Prepare and process data

ETL vs ELT vs ETLT. *ETL* = transformasi dulu, baru load ke tujuan (cocok jika data harus dibersihkan atau di-mask sebelum disimpan). *ELT* = load mentah ke BigQuery dulu, lalu transformasi dengan SQL di dalam BigQuery (paling umum di Google Cloud karena BigQuery kuat dan murah untuk transformasi). *ETLT* = transformasi ringan sebelum load (misalnya masking PII atau dedup kecil), lalu transformasi berat setelah load.

Memilih tool transfer: *Storage Transfer Service* (online, ke Cloud Storage, dari S3/Azure/HTTP/on-prem via agent, terjadwal, bisa dibatasi bandwidth) vs *Transfer Appliance* (perangkat fisik yang dikirim, untuk puluhan TB sampai PB dengan jaringan lambat). Rumus cepat: waktu transfer ≈ ukuran ÷ bandwidth. Jika hasilnya berminggu-minggu, pakai Appliance.

Assess data quality: cek completeness (null), uniqueness (duplikat), validity (format atau rentang), consistency, timeliness. Tool: *Dataplex data profiling & data quality scans*, query SQL (COUNTIF, SAFE_CAST), Dataform assertions.

Data cleaning: *Cloud Data Fusion* (visual, Wrangler, tanpa kode), *BigQuery SQL* (TRIM, SAFE_CAST, REGEXP_REPLACE, dedup dengan ROW_NUMBER + QUALIFY), *Dataflow* (kode Beam, skala besar, streaming, dead-letter untuk record rusak).

1.2 Extract and load data into appropriate storage

Format	Tipe	Kapan dipilih
CSV	Baris, tanpa skema	Paling umum dan sederhana. Tidak mendukung nested field, dan skema harus didefinisikan atau di-autodetect
JSON (newline-delimited)	Baris, semi-terstruktur	Data API atau event dengan field nested yang sering berubah
Avro	Baris, skema tertanam, biner	Streaming atau penulisan, evolusi skema. Load ke BigQuery sangat cepat (blok bisa dibaca paralel)
Parquet / ORC	Kolumnar, terkompresi	Analitik di data lake yang hanya membaca sebagian kolom (column pruning). Cocok untuk BigLake dan external table
Tabel database	Terstruktur relasional	Sumber OLTP (MySQL/PostgreSQL), diambil dengan DMS, Datastream, atau federated query

Tool ekstraksi: *Dataflow* (pipeline custom batch/stream), *BigQuery Data Transfer Service* (jadwal load ke BigQuery dari SaaS seperti Google Ads/YouTube, S3, GCS, Redshift/Teradata), *Database Migration Service* (migrasi database ke Cloud SQL/AlloyDB), *Cloud Data Fusion* (ETL visual dengan banyak connector). Ditambah *Datastream* (CDC database ke BigQuery/GCS).

Klasifikasi data: *Terstruktur* (tabel dengan kolom tetap) → BigQuery atau Cloud SQL. *Semi-terstruktur* (JSON, Avro, log) → BigQuery (tipe JSON, STRUCT/ARRAY) atau Firestore/Bigtable. *Tidak terstruktur* (gambar, video, PDF, audio) → Cloud Storage.

Cara load: `gcloud storage cp` (file ke GCS), `bq load --source_format=CSV --autodetect ds.tbl gs://b/*.csv`, SQL `LOAD DATA INTO`, Storage Transfer Service, BQ DTS, client libraries (Python/Java), BigQuery Storage Write API untuk streaming. Load batch dari GCS ke BigQuery tidak dikenai biaya, yang dibayar hanya penyimpanannya.

> 🎯 **FOKUS KAMU**
>
> **Fokus kamu (Domain 1):** bedakan **STS** (tujuan GCS) vs **BQ DTS** (tujuan BigQuery) · **Datastream** = CDC serverless (MySQL, PostgreSQL, Oracle, SQL Server → BigQuery/GCS) · **BigLake** = tabel di atas file GCS/S3 dengan keamanan granular · **BigQuery Omni** = query data di AWS/Azure tanpa memindahkan · **Data Fusion/Dataprep** (visual) vs **Dataflow** (kode).

3. Domain 2 — Data Analysis & Presentation (~27%)

2.1 Trends & insights dengan BigQuery dan Jupyter notebooks

- **SQL penting:** GROUP BY, JOIN, window function (ROW_NUMBER, RANK, LAG/LEAD, SUM() OVER untuk running total, AVG() OVER (... ROWS BETWEEN 6 PRECEDING AND CURRENT ROW) untuk moving average), QUALIFY, UNNEST untuk ARRAY, STRUCT, SAFE_DIVIDE, SAFE_CAST, DATE_TRUNC, EXTRACT.
- **Hemat biaya query:** SELECT hanya kolom yang perlu (BigQuery bersifat kolumnar, LIMIT tidak mengurangi byte yang di-scan), pakai *partitioning* (umumnya per tanggal) dan *clustering* (kolom yang sering difilter), cek estimasi byte sebelum run (dry run), materialized view untuk agregasi berulang.
- **Colab Enterprise** = notebook Jupyter managed di BigQuery Studio dan Vertex AI. Tanpa kelola VM, akses lewat IAM, bisa SQL + Python (pandas, BigQuery DataFrames). *Vertex AI Workbench* = alternatif notebook dengan instance yang bisa dikustomisasi.
- **Analisis untuk pertanyaan bisnis:** pahami metrik (revenue, churn, retention), pilih agregasi dan grain yang tepat, hati-hati dengan duplikasi akibat JOIN.

2.2 Dashboard dengan Looker

Looker = platform BI enterprise dengan semantic layer **LookML**: metrik didefinisikan sekali, terkelola, di-version-control dengan Git, mendukung embedded analytics dan permission granular. **Looker Studio** = tool dashboard gratis yang self-service, cepat, dengan banyak connector (BigQuery, Sheets, GA4), dibagikan seperti Google Docs. Ada juga *Looker Studio Pro* (fitur tim/enterprise).

Konsep LookML: *project* → *model* (koneksi + explore) → *view* (mewakili tabel: dimension & measure) → *explore* (titik awal query, berisi join).

Parameter LookML	Arti	Contoh
dimension	Atribut per baris (kolom)	`dimension: city { type: string sql: ${TABLE}.city ;; }`
measure	Agregasi	`measure: total_rev { type: sum sql: ${revenue} ;; }`
type	Tipe field: string, number, yesno, date, tier; measure: count, sum, average, count_distinct, max, min	`type: count_distinct`
sql	Ekspresi SQL, diakhiri dengan ;;	`sql: ${TABLE}.price * 1.1 ;;`
label / description	Nama tampilan & keterangan	`label: "Total Pendapatan"`
hidden: yes	Sembunyikan field dari field picker (bukan kontrol keamanan)	`hidden: yes`
primary_key: yes	Kunci unik view, wajib agar symmetric aggregates benar	`primary_key: yes`
dimension_group	Membuat banyak timeframe dari satu kolom waktu	`type: time timeframes: [date, week, month]`
join + relationship	Join di explore: many_to_one, one_to_many, one_to_one	`relationship: many_to_one`
sql_always_where	Filter yang selalu diterapkan di explore	`sql_always_where: ${status} != 'test' ;;`

2.3 Define, train, evaluate, and use ML models

BigQuery ML = membuat dan menjalankan model ML dengan SQL, langsung di BigQuery tanpa memindahkan data. **AutoML** (Vertex AI) = melatih model berkualitas tanpa kode untuk gambar, teks, video, atau tabular. Pilih BQML untuk analis SQL dengan data tabular di BigQuery, dan AutoML untuk data non-tabular atau ketika butuh model terbaik tanpa coding.

Kebutuhan	model_type BQML
Prediksi angka (harga, revenue)	LINEAR_REG, BOOSTED_TREE_REGRESSOR, RANDOM_FOREST_REGRESSOR, DNN_REGRESSOR
Klasifikasi (churn ya/tidak, kategori)	LOGISTIC_REG, BOOSTED_TREE_CLASSIFIER, RANDOM_FOREST_CLASSIFIER, DNN_CLASSIFIER
Segmentasi tanpa label	KMEANS
Forecast time series	ARIMA_PLUS (opsi time_series_timestamp_col, time_series_data_col, time_series_id_col)
Rekomendasi	MATRIX_FACTORIZATION
Deteksi anomali	ML.DETECT_ANOMALIES pada model KMEANS, ARIMA_PLUS, atau AUTOENCODER
LLM / Gemini, embedding	Remote model (REMOTE WITH CONNECTION)

```
-- 1) Training
CREATE OR REPLACE MODEL `ds.churn_model`
OPTIONS(model_type='LOGISTIC_REG', input_label_cols=['churned']) AS
SELECT tenure, monthly_spend, region, churned FROM `ds.customers`;

-- 2) Evaluasi (precision, recall, roc_auc, ...)
SELECT * FROM ML.EVALUATE(MODEL `ds.churn_model`);

-- 3) Prediksi / inference
SELECT * FROM ML.PREDICT(MODEL `ds.churn_model`, (SELECT * FROM `ds.new_customers`));

-- Forecast time series
SELECT * FROM ML.FORECAST(MODEL `ds.sales_arima`, STRUCT(30 AS horizon));

-- Remote model ke Gemini (butuh Cloud resource connection + role Vertex AI User)
CREATE OR REPLACE MODEL `ds.gemini`
  REMOTE WITH CONNECTION `project.us.my_conn` OPTIONS(ENDPOINT = 'gemini-...');
SELECT * FROM AI.GENERATE_TEXT(MODEL `ds.gemini`, (SELECT CONCAT('Ringkas: ', review) AS prompt FROM
`ds.reviews`));
-- (fungsi lama: ML.GENERATE_TEXT)

-- Daftarkan ke Vertex AI Model Registry
CREATE MODEL `ds.m` OPTIONS(model_type='LINEAR_REG', input_label_cols=['y'], MODEL_REGISTRY='VERTEX_AI')
AS ...
```

- **Fungsi lain:** ML.TRAINING_INFO (riwayat iterasi), ML.FEATURE_INFO, ML.EXPLAIN_PREDICT dan ML.GLOBAL_EXPLAIN (explainability), ML.CONFUSION_MATRIX, ML.ROC_CURVE.
- **Alur proyek ML standar:** definisikan masalah → kumpulkan dan siapkan data (feature engineering, split train/test) → training → evaluasi pada data uji → deploy/prediksi → monitoring (drift) → retrain.
- **Model Registry** (Vertex AI): tempat terpusat untuk versi model, alias (misalnya "production"), evaluasi, dan deploy ke endpoint untuk prediksi online.

🎯 **FOKUS KAMU**

Fokus kamu (Domain 2): sintaks **CREATE MODEL → ML.EVALUATE → ML.PREDICT** · pemilihan model_type · remote model (connection + ENDPOINT) · **Looker vs Looker Studio** · parameter LookML (dimension/measure/type/sql/hidden/relationship) · query BigQuery (window function, UNNEST).

4. Domain 3 — Data Pipeline Orchestration (~18%)

3.1 Design and implement simple data pipelines

- **Memilih tool transformasi** (detail di tabel perbandingan): Dataflow (Beam, serverless, batch+stream), Dataproc (Spark/Hadoop yang sudah ada), Cloud Data Fusion (visual), Cloud Composer (orkestrasi, bukan engine transformasi), Dataform (SQL ELT di BigQuery).
- **ELT dipilih** jika data sudah atau boleh mendarat di BigQuery, tim kuat di SQL, dan data mentah ingin disimpan. **ETL dipilih** jika data harus dibersihkan atau di-mask sebelum disimpan, transformasinya kompleks dan bukan SQL, atau targetnya tidak bisa bertransformasi.
- **Pipeline dasar:** sumber → ingest (Pub/Sub, STS, DTS, Datastream) → storage (GCS/BigQuery) → transformasi (Dataflow/Dataform/SQL) → serving (BigQuery, Looker).

3.2 Schedule, automate, and monitor

- **Scheduled queries** BigQuery: menjalankan SQL berkala (berbasis BQ DTS), dengan parameter @run_date/@run_time dan opsi notifikasi email jika run gagal. **Cloud Scheduler**: cron managed untuk memicu HTTP, Pub/Sub, atau Workflows. **Cloud Composer**: DAG Airflow.
- **Monitoring Dataflow:** Dataflow job UI menampilkan job graph per langkah, throughput, *data freshness*, *system latency*, autoscaling, dan log worker.
- **Cloud Logging** = mengumpulkan dan mencari log (Logs Explorer, log-based metrics, log sinks ke BigQuery/GCS/Pub/Sub). **Cloud Monitoring** = metrik, dashboard, alerting policy, notification channel (email, SMS, Slack, PagerDuty).
- **Event-driven ingestion:** Pub/Sub → BigQuery subscription (langsung, tanpa transformasi) atau Pub/Sub → Dataflow → BigQuery (jika perlu transformasi atau windowing).
- **Eventarc**: merutekan event (misalnya "objek GCS selesai ditulis" atau entri audit log) ke target seperti Cloud Run, Cloud Run functions, Workflows, atau GKE. Dengan begitu pipeline bisa dipicu oleh file baru tanpa polling.

> 🎯 **FOKUS KAMU**
>
> **Fokus kamu (Domain 3): Composer** (Airflow, DAG Python, pipeline data kompleks, backfill) vs **Workflows** (serverless, YAML, merangkai API/service, ringan) vs **Scheduler** (cron saja) vs **scheduled query** (SQL saja) vs **Dataproc Workflow Templates** (rangkaian job Spark + cluster ephemeral).

5. Domain 4 — Data Management (~25%)

4.1 Access control & governance

- **Least privilege:** beri role sesempit mungkin (predefined, bukan basic) di level resource sekecil mungkin (dataset/ bucket, bukan project), sebaiknya ke group atau service account.
- **Basic roles** (Owner, Editor, Viewer) terlalu luas dan hindari di produksi. **Predefined roles** dibuat Google per layanan (misalnya roles/bigquery.dataViewer). **Custom roles** berisi kumpulan permission yang Anda pilih sendiri, dipakai jika tidak ada predefined role yang pas.
- **Akses Cloud Storage:** *uniform bucket-level access* (hanya IAM, ACL dimatikan, direkomendasikan) vs *fine-grained* (IAM + ACL per objek). *Public access prevention* mencegah bucket jadi publik. *Signed URL* = akses sementara ke satu objek tanpa akun Google (maksimal 7 hari untuk V4).
- **Analytics Hub** (BigQuery sharing): berbagi dataset lintas organisasi lewat *exchange* dan *listing*. Subscriber mendapat *linked dataset* read-only di project-nya tanpa salinan, dan membayar sendiri biaya query.

4.2 Lifecycle management

- Pilih **storage class** sesuai frekuensi akses dan durasi retensi (lihat tabel). Biaya penyimpanan makin murah ke arah Archive, tetapi biaya akses atau retrieval dan durasi minimum makin tinggi.
- **Object Lifecycle Management**: rule Delete atau SetStorageClass berdasarkan kondisi (age, createdBefore, matchesPrefix/Suffix, isLive, numNewerVersions, daysSinceNoncurrentTime). **BigQuery**: default table expiration (dataset), partition expiration, table expiration.
- **Arsip:** GCS Archive (akses kurang dari 1x/tahun), BigQuery long-term storage (tabel atau partisi yang tidak diubah 90 hari otomatis jadi lebih murah, sekitar 50%), table snapshot untuk menyimpan kondisi tabel.

4.3 High availability & disaster recovery (GCS & Cloud SQL)

- **GCS:** lokasi region, dual-region, atau multi-region (redundansi otomatis). Dual-region bisa ditambah **Turbo replication** (RPO 15 menit). Ada juga Object Versioning dan soft delete untuk pemulihan dari penghapusan, serta cross-bucket replication.
- **Cloud SQL: HA** (regional instance, standby di zona lain, replikasi sinkron, failover otomatis) untuk kegagalan zona. **Read replica** (asinkron, bisa cross-region, di-promote manual) untuk scale-out baca dan DR regional. **Backup otomatis dan on-demand** serta **PITR** untuk kesalahan manusia atau korupsi data.

4.4 Security & compliance

- **Encryption at rest** (data tersimpan di disk) sudah otomatis aktif dengan Google-managed keys. **Encryption in transit** (data bergerak di jaringan) memakai TLS.
- **Google-managed** (default, tanpa usaha) vs **CMEK** (kunci di Cloud KMS yang Anda kendalikan: rotasi, disable, IAM, audit) vs **CSEK** (Anda yang memegang kunci dan mengirimkannya di setiap request, Google hanya menyimpan hash-nya. Dipakai di Cloud Storage. Catatan: CSEK untuk Compute Engine sudah deprecated).
- **Cloud KMS**: layanan pengelolaan kunci (key ring → key → key version), rotasi otomatis, dan opsi HSM. Service agent layanan (misalnya BigQuery) perlu role `roles/cloudkms.cryptoKeyEncrypterDecrypter` pada kunci CMEK.
- Proteksi data sensitif tambahan: column-level security (policy tag), row-level security, dynamic data masking di BigQuery, dan Sensitive Data Protection (DLP) untuk menemukan atau me-mask PII.

🎯 **FOKUS KAMU**

Fokus kamu (Domain 4): storage class (30/90/365 hari) · **Autoclass** · lifecycle vs retention vs **object hold** · region vs dual vs multi-region · **Cloud SQL HA vs read replica** · authorized/materialized view, snapshot · **Analytics Hub** · **Dataplex** · IAM least privilege · **CMEK/KMS** vs CSEK.

6. Tabel Perbandingan (yang Sering Tertukar)

6.1 Cloud Storage storage classes

Class	Durasi minimum	Akses ideal	Biaya simpan / akses	Contoh
Standard	Tidak ada	Sering (hot data)	Simpan termahal, tanpa biaya retrieval	Website, data yang sedang diproses, analitik aktif
Nearline	30 hari	≤ 1x per bulan	Lebih murah; ada biaya retrieval	Backup bulanan, laporan yang dibuka sebulan sekali
Coldline	90 hari	≤ 1x per kuartal	Lebih murah lagi; retrieval lebih mahal	DR, arsip yang dibuka per kuartal
Archive	365 hari	< 1x per tahun	Termurah; retrieval termahal	Arsip compliance/audit tahunan, data legal

> 💡 **TIP**
> Semua class punya latensi milidetik dan durabilitas yang sama (11 nines). Data Archive tetap bisa diakses langsung, berbeda dengan tape. Yang berbeda hanya harga dan SLA availability. Menghapus objek sebelum durasi minimum tetap dikenai biaya sisa hari (early deletion fee).

6.2 Autoclass vs Lifecycle vs Retention vs Object Hold

Fitur	Apa itu	Kapan dipakai
Autoclass	Memindahkan class otomatis berdasarkan akses per objek. Tidak diakses 30 hari → Nearline; opsional terus ke Coldline (90 hari) dan Archive (365 hari). Dibaca → kembali ke Standard	Pola akses tidak diketahui atau bervariasi. Tanpa biaya retrieval dan early deletion (ada management fee). Tidak bisa digabung dengan lifecycle SetStorageClass. Objek di bawah 128 KiB tetap Standard
Lifecycle rule	Aksi otomatis Delete atau SetStorageClass berdasarkan umur, prefix, versi, dan kondisi lain	Pola akses diketahui (misalnya "pindah ke Coldline setelah 90 hari" atau "hapus tmp/ setelah 7 hari")
Retention policy	Objek tidak bisa dihapus atau ditimpa sebelum umur X. Bisa dikunci permanen dengan **Bucket Lock**	Compliance (WORM), misalnya "simpan minimal 7 tahun"
Event-based hold	Objek ditahan sampai hold dilepas. Jika bucket punya retention policy, hitungan retensi dimulai saat hold dilepas	"Simpan 5 tahun SETELAH kontrak ditutup" (tanggal event belum diketahui). Bisa default untuk semua objek baru
Temporary hold	Penahan manual sementara; melepasnya tidak mengubah hitungan retensi	Legal hold atau investigasi sementara
Object Versioning / soft delete	Menyimpan versi lama, atau objek terhapus bisa dipulihkan dalam periode tertentu	Pemulihan dari penghapusan atau penimpaan tidak sengaja

6.3 Lokasi: region vs dual-region vs multi-region

Tipe	Arti	Kelebihan	Kapan
Region	Satu region (misalnya asia-southeast2 Jakarta). Data tetap redundan antar zona	Latensi terendah ke compute di region yang sama, termurah, memenuhi data residency	Data residency, data diproses Dataproc/ Dataflow/BigQuery di region itu

Tipe	Arti	Kelebihan	Kapan
Dual-region	Dua region spesifik yang dipilih (atau pasangan bawaan)	Tahan kegagalan satu region, region diketahui; opsi **Turbo replication** (RPO 15 menit)	DR dengan lokasi terkontrol, RPO ketat
Multi-region	Area geografis luas (US, EU, ASIA)	Availability tertinggi, cocok untuk penyajian global	Konten untuk pengguna di banyak lokasi, tanpa syarat region spesifik

> 💡 **TIP**
> Default replication (dual/multi-region): 99,9% objek baru tereplikasi dalam 1 jam dan 100% dalam 12 jam. Turbo replication: 100% dalam 15 menit (khusus dual-region). Untuk BigQuery, lokasi dataset (region atau multi-region US/EU) ditentukan saat dibuat dan tidak bisa diubah. Query tidak bisa langsung JOIN dataset beda lokasi.

6.4 Memilih storage

Layanan	Tipe	Gunakan jika	Jangan jika
Cloud Storage	Object storage	File tidak terstruktur, data lake, backup, arsip, staging	Butuh query SQL transaksional atau update per baris
BigQuery	Data warehouse serverless (OLAP)	Analitik SQL skala TB–PB, BI, BQML	OLTP aplikasi dengan banyak update kecil dan latensi milidetik
Cloud SQL	Relasional managed (MySQL, PostgreSQL, SQL Server)	OLTP regional, aplikasi web, ukuran sampai beberapa puluh TB	Butuh skala tulis global horizontal
AlloyDB	PostgreSQL-compatible berperforma tinggi	Workload PostgreSQL berat, transaksi dan analitik (HTAP)	Butuh MySQL atau skala global multi-region write
Spanner	Relasional terdistribusi global	ACID + SQL + strong consistency + skala horizontal, multi-region, 99,999%	Workload kecil dan sederhana (mahal dan berlebihan)
Bigtable	NoSQL wide-column	Throughput sangat tinggi, latensi ms, IoT/ time series/ad-tech, lookup by row key	Butuh JOIN, SQL ad-hoc kompleks, atau transaksi multi-baris
Firestore	NoSQL dokumen	Aplikasi mobile/web, sinkron real-time, offline, skema fleksibel	Analitik besar atau join kompleks

6.5 ETL vs ELT vs ETLT

Pola	Urutan	Tool khas	Pilih jika
ETL	Extract → Transform → Load	Dataflow, Data Fusion, Dataproc	Data harus bersih atau di-mask sebelum disimpan; transformasi kompleks non-SQL
ELT	Extract → Load → Transform	BigQuery SQL, Dataform, scheduled query	Data boleh mendarat mentah di BigQuery; tim SQL; ingin data mentah tersimpan untuk reprocess
ETLT	Transform ringan → Load → Transform berat	Kombinasi (misalnya Dataflow lalu Dataform)	Butuh masking atau pembersihan ringan sebelum load, lalu modeling di BigQuery

6.6 Tool transformasi: Dataflow vs Dataproc vs Data Fusion vs Dataprep vs Dataform

Tool	Apa itu	Kata kunci di soal
Dataflow	Apache Beam managed, serverless, autoscaling, batch + streaming, windowing, exactly-once, banyak template siap pakai	"serverless", "streaming", "unified batch & stream", "Apache Beam", "autoscale", "pipeline baru"

Tool	Apa itu	Kata kunci di soal
Dataproc	Spark/Hadoop/Hive managed (cluster cepat dibuat; ada juga Dataproc Serverless untuk Spark)	"existing Spark/Hadoop jobs", "lift and shift", "PySpark", "minimal code changes"
Cloud Data Fusion	ETL/ELT visual (CDAP), Wrangler, ratusan connector, berjalan di atas Dataproc	"visual", "no-code/low-code", "drag-and-drop", "banyak connector", "data quality insight"
Dataprep (Trifacta/ Alteryx)	Wrangling data visual dan interaktif dengan saran transformasi otomatis; job dijalankan di Dataflow/ BigQuery	"analis bisnis membersihkan data secara visual". Catatan: produk pihak ketiga (Alteryx) dan tidak disebut di exam guide v1.0
Dataform	Transformasi SQL (SQLX) di BigQuery: dependensi, assertion, Git, jadwal	"SQL-based ELT di BigQuery", "version control", "assertions", "dbt-like"

6.7 Orkestrasi & penjadwalan

Tool	Apa itu	Pilih jika
Cloud Composer	Apache Airflow managed. DAG Python, ratusan operator, retry, backfill/catchup	Pipeline data kompleks multi-sistem (BQ, Dataproc, GCS, on-prem), dependensi rumit, tim paham Airflow
Workflows	Orkestrator serverless (YAML/JSON) yang memanggil HTTP/API dan layanan Google; bayar per langkah	Merangkai beberapa service atau API secara ringan, murah, tanpa environment selalu menyala
Cloud Scheduler	Cron managed: memicu target HTTP, Pub/Sub, atau Workflows sesuai jadwal	Hanya butuh "jalankan X setiap jam/hari" tanpa logika dependensi
BigQuery scheduled query	SQL yang dijalankan berkala di BigQuery	Transformasi atau agregasi SQL berkala yang sederhana
Dataproc Workflow Templates	Graf job Dataproc + managed (ephemeral) cluster yang dibuat lalu dihapus otomatis	Rangkaian job Spark/Hadoop yang saling bergantung, hemat cluster
Dataform workflows	Eksekusi terjadwal action Dataform	Pipeline ELT SQL di BigQuery

6.8 Memindahkan data: STS vs Transfer Appliance vs BQ DTS vs Datastream vs DMS

Layanan	Sumber → Tujuan	Pilih jika
Storage Transfer Service	S3, Azure Blob, HTTP(S), GCS lain, file system on-prem (via agent) → **Cloud Storage**	Transfer online besar atau berulang ke GCS, terjadwal, incremental, bandwidth limit
Transfer Appliance	Data center on-prem → perangkat fisik → **Cloud Storage**	Data sangat besar (puluhan TB sampai PB) dengan bandwidth kecil atau mahal (transfer online butuh waktu lama)
BigQuery Data Transfer Service	SaaS (Google Ads, YouTube, GA4, Campaign Manager), S3, Azure, GCS, Redshift/Teradata → **BigQuery**	Load terjadwal ke BigQuery tanpa kode; juga dasar dari scheduled query
Datastream	MySQL, PostgreSQL, Oracle, SQL Server (dan lainnya) → **BigQuery / Cloud Storage** (CDC)	Replikasi perubahan (insert/update/ delete) hampir real-time, serverless, beban kecil ke sumber
Database Migration Service	MySQL, PostgreSQL, SQL Server, Oracle → **Cloud SQL / AlloyDB**	Migrasi database dengan downtime minimal (continuous migration lalu promote)

6.9 BigLake vs BigQuery Omni vs External table

Fitur	Apa itu	Kapan
External table (biasa)	BigQuery membaca file di GCS/Drive/Bigtable tanpa load; pengguna butuh akses langsung ke sumber	Akses cepat dan sederhana, tanpa kebutuhan keamanan granular
BigLake table	External table generasi baru dengan connection (access delegation) → row/column-level security, masking, caching metadata; format terbuka (Parquet, Iceberg, Delta, dll.)	Data lake di GCS/S3/Azure dengan governance seperti tabel BigQuery, pengguna tidak perlu akses bucket
BigQuery Omni	Engine BigQuery yang berjalan di AWS/Azure; query data S3/Azure Blob lewat BigLake di tempatnya	Data harus tetap di AWS/Azure (egress, kontrak) tetapi ingin dianalisis dengan BigQuery SQL
Federated query	Query langsung ke Cloud SQL/Spanner/AlloyDB dari BigQuery (EXTERNAL_QUERY)	Join data operasional dengan data warehouse tanpa ETL

6.10 View vs Authorized view vs Materialized view vs Snapshot vs Clone

Objek	Menyimpan data?	Bisa ditulis?	Kegunaan utama
Logical view	Tidak (hanya query)	Tidak	Menyederhanakan query, menyembunyikan kompleksitas
Authorized view	Tidak	Tidak	Berbagi sebagian kolom/baris tanpa memberi akses ke tabel sumber (view di dataset lain diotorisasi di dataset sumber)
Materialized view	Ya (hasil precomputed, refresh incremental otomatis)	Tidak	Mempercepat dan menghemat agregasi berulang; data tetap segar
Table snapshot	Ya (hanya selisih dari base table yang ditagih)	Tidak (read-only; bisa di-restore ke tabel baru)	Simpan kondisi tabel pada titik waktu tertentu lebih lama dari 7 hari (audit, backup)
Table clone	Ya (hanya selisih yang ditagih)	Ya	Salinan writable yang ringan untuk dev/test/ eksperimen
Time travel	Otomatis	Tidak	Akses data hingga 7 hari ke belakang (window bisa diatur 2–7 hari) dengan FOR SYSTEM_TIME AS OF; setelahnya ada fail-safe 7 hari (hanya lewat Google Support)

6.11 Looker vs Looker Studio

Aspek	Looker	Looker Studio
Model	Platform BI enterprise berlisensi	Gratis (ada versi Pro)
Semantic layer	LookML: metrik terkelola, Git, reuse	Data source + calculated field (tanpa LookML)
Cocok untuk	Single source of truth, governance, embedded analytics, banyak tim	Dashboard cepat, self-service, tim kecil, banyak connector
Berbagi	Permission granular, schedule delivery, embed	Share seperti Google Docs (link/email), scheduled email

6.12 BigQuery ML vs AutoML vs model custom

Opsi	Kapan
BigQuery ML	Analis SQL, data tabular sudah di BigQuery, ingin model cepat tanpa memindahkan data; juga remote model ke Gemini atau Vertex AI

Opsi	Kapan
AutoML (Vertex AI)	Data gambar, teks, video, atau tabular berlabel; tanpa keahlian ML; ingin akurasi tinggi dengan sedikit kode
Pretrained API (Vision, NL, Speech, Translation)	Tugas umum tanpa training (OCR, deteksi label, sentimen umum)
Custom training (Vertex AI)	Tim ML yang butuh kontrol penuh (TensorFlow/PyTorch)

6.13 Cloud SQL: HA vs Read replica vs Backup/PITR

Fitur	Cara kerja	Melindungi dari	Catatan
High availability (regional)	Primary + standby di zona lain dalam region yang sama; replikasi sinkron	Kegagalan instance atau zona (failover otomatis, tanpa kehilangan commit)	Standby tidak bisa dipakai untuk baca
Read replica	Salinan asinkron; bisa di region lain (cross-region)	Beban baca berlebih; bencana regional (promote manual)	Ada replication lag; promote menjadikannya instance mandiri
Automated / on-demand backup	Snapshot harian atau manual	Kehilangan data, penghapusan	Restore ke instance yang sama atau lain
Point-in-time recovery	Backup + log transaksi (binlog/WAL)	Kesalahan manusia (DELETE tanpa WHERE) pada waktu tertentu	Selalu membuat instance baru

6.14 IAM: role penting

Role	Hak
roles/bigquery.dataViewer	Membaca data dan metadata tabel/dataset
roles/bigquery.dataEditor	Membaca + membuat/mengubah/menghapus tabel dan data
roles/bigquery.dataOwner	dataEditor + mengatur akses dataset
roles/bigquery.jobUser	Menjalankan job (query, load) di project. Dipasangkan dengan dataViewer untuk query
roles/bigquery.user	jobUser + membuat dataset dan melihat daftar dataset
roles/bigquery.admin	Kendali penuh BigQuery
roles/storage.objectViewer	Membaca dan mendaftar objek
roles/storage.objectCreator	Hanya membuat objek baru (tidak bisa baca, timpa, atau hapus)
roles/storage.objectUser / objectAdmin	objectUser: baca, buat, timpa, hapus objek. objectAdmin: kendali penuh atas objek
roles/storage.admin	Kendali penuh bucket dan objek
roles/ cloudkms.cryptoKeyEncrypterDecrypter	Memakai kunci KMS untuk enkripsi/dekripsi (diberikan ke service agent untuk CMEK)
roles/dataflow.worker / dataflow.developer	Service account worker / menjalankan job Dataflow

6.15 Enkripsi: Google-managed vs CMEK vs CSEK

Opsi	Siapa memegang kunci	Layanan	Kapan
Google-managed (default)	Google	Semua	Tidak ada syarat khusus

Opsi	Siapa memegang kunci	Layanan	Kapan
CMEK (Cloud KMS)	Pelanggan mengendalikan kunci di Cloud KMS (rotasi, disable, IAM, audit log)	BigQuery, GCS, Cloud SQL, Dataflow, Pub/Sub, dan banyak lagi	Compliance: "kami harus bisa rotate/revoke kunci sendiri"
CSEK	Pelanggan memegang kunci dan mengirimnya di setiap request; Google hanya menyimpan hash	Cloud Storage (Compute Engine: deprecated); **tidak** BigQuery	"Google tidak boleh menyimpan kunci"
Cloud EKM	Kunci di key manager eksternal (pihak ketiga)	Layanan yang mendukung EKM	Kunci harus di luar Google

6.16 Governance, sharing, messaging & observability

Layanan	Apa itu	Kata kunci
Dataplex (kini Knowledge Catalog)	Data fabric/governance: katalog dan pencarian metadata, data lineage, data profiling, data quality scan, pengelolaan data lake (lake/zone/asset)	"discover", "catalog", "metadata", "lineage", "data quality", "governance terpusat"
Analytics Hub (kini BigQuery sharing)	Exchange dan listing untuk berbagi dataset tanpa salinan; subscriber dapat linked dataset	"share with partners/other orgs", "no copy", "subscriber pays", "data marketplace"
Pub/Sub	Messaging asinkron global (topic → subscription: pull, push, BigQuery, Cloud Storage)	"decouple", "event ingestion", "streaming", "at-least-once"
Eventarc	Routing event Google Cloud (GCS, audit log, Pub/Sub) ke Cloud Run, functions, Workflows	"trigger saat file diupload", "event-driven"
Cloud Logging	Kumpulan log, Logs Explorer, log-based metric, sink	"audit", "cari error", "ekspor log ke BigQuery"
Cloud Monitoring	Metrik, dashboard, alerting policy, uptime check	"alert", "notifikasi", "threshold", "SLO"

7. Kata Kunci di Soal → Jawaban

Jika soal menyebut...	Jawaban yang biasanya benar
Real-time / streaming events + transformasi	Pub/Sub + Dataflow (streaming) → BigQuery
Streaming tanpa transformasi, paling sederhana	Pub/Sub BigQuery subscription
Existing Spark / Hadoop jobs, minimal changes	Dataproc (atau Dataproc Serverless)
Pipeline baru, serverless, batch + stream	Dataflow
Visual / no-code / drag-and-drop ETL	Cloud Data Fusion (Dataprep untuk wrangling interaktif)
SQL transformations in BigQuery, Git, assertions	Dataform
Satu query terjadwal di BigQuery	BigQuery scheduled query
Complex DAG, Airflow, banyak sistem, backfill	Cloud Composer
Merangkai beberapa API/Cloud Run, serverless, ringan	Workflows
Picu proses saat file masuk bucket	Eventarc (event object finalized) → Cloud Run / functions
Pindahkan file dari S3/Azure/on-prem ke GCS	Storage Transfer Service
Ratusan TB, bandwidth lambat, deadline singkat	Transfer Appliance
Load terjadwal dari Google Ads / YouTube / S3 ke BigQuery	BigQuery Data Transfer Service
CDC / replicate changes from MySQL/Oracle/PostgreSQL to BigQuery	Datastream
Migrate database ke Cloud SQL dengan minimal downtime	Database Migration Service
Query data di S3/Azure tanpa memindahkan	BigQuery Omni (+ BigLake)
Data lake GCS + row/column security, user tanpa akses bucket	BigLake table
Global, relational, strongly consistent, 99.999%	Spanner
High throughput, low latency, time series/IoT, key lookup	Bigtable
Mobile app, offline sync, document	Firestore
OLTP relasional regional (MySQL/PostgreSQL)	Cloud SQL (AlloyDB untuk PostgreSQL performa tinggi)
Gambar, video, file tidak terstruktur	Cloud Storage
Analitik SQL skala besar, serverless	BigQuery
Akses jarang, pola akses tidak diketahui	Autoclass
Diakses ~1x/bulan | ~1x/kuartal | <1x/tahun	Nearline | Coldline | Archive
Hapus otomatis setelah N hari	Lifecycle rule (GCS) / table atau partition expiration (BigQuery)
Tidak boleh dihapus selama X tahun (WORM)	Retention policy + Bucket Lock
Retensi dihitung sejak suatu event	Event-based hold + retention policy
RPO 15 menit lintas region untuk GCS	Dual-region + Turbo replication
Data residency di satu negara/region	Regional bucket/dataset di region tersebut
Zonal outage, automatic failover Cloud SQL	Cloud SQL high availability
Offload reads / cross-region DR Cloud SQL	Read replica (cross-region, promote)

Jika soal menyebut…	Jawaban yang biasanya benar
Pulihkan ke menit tertentu sebelum kesalahan	Point-in-time recovery (instance baru)
Share subset kolom tanpa akses tabel sumber	Authorized view
Share dataset ke organisasi lain tanpa copy	Analytics Hub
Dashboard lambat, agregasi berulang	Materialized view (+ partition/cluster, BI Engine)
Simpan kondisi tabel lebih dari 7 hari, read-only	Table snapshot
Salinan tabel writable untuk testing	Table clone
Kembalikan data yang terhapus kemarin	Time travel (FOR SYSTEM_TIME AS OF)
Cari metadata, lineage, kualitas data	Dataplex
Least privilege: query satu dataset	bigquery.dataViewer (dataset) + bigquery.jobUser (project)
Akses hanya lewat IAM, tanpa ACL	Uniform bucket-level access (+ public access prevention)
Akses sementara ke objek untuk orang tanpa akun Google	Signed URL (≤ 7 hari)
Kontrol rotasi/revoke kunci sendiri	CMEK dengan Cloud KMS
Google tidak boleh menyimpan kunci (GCS)	CSEK
Kolom sensitif hanya untuk grup tertentu	Column-level security (policy tag) / data masking
Baris per region/tenant	Row-level security (row access policy)
Governed metrics, LookML, embed	Looker
Dashboard gratis cepat, Sheets + BigQuery	Looker Studio
ML dengan SQL di BigQuery	BigQuery ML (CREATE MODEL, ML.EVALUATE, ML.PREDICT)
Forecast penjualan	BQML ARIMA_PLUS + ML.FORECAST
Segmentasi pelanggan tanpa label	BQML KMEANS
Gemini / LLM dari SQL	Remote model + AI.GENERATE_TEXT
Klasifikasi gambar tanpa ahli ML	Vertex AI AutoML
Kelola versi model + deploy endpoint	Vertex AI Model Registry
Notebook Python managed di BigQuery	Colab Enterprise
Pantau lag job streaming	Dataflow job UI (data freshness, system latency)
Alert email jika pipeline gagal	Cloud Monitoring alert / log-based alert

8. Fokus Kamu — Topik Lemah dari Catatan Latihanmu

Daftar ini diambil dari catatan latihanmu (review soal, jawaban ADP 9 & 10, Buku Belajar). Kuasai tiap baris sampai bisa menjelaskannya dengan kata-katamu sendiri.

Topik	Inti yang harus nempel
BigLake	Tabel di atas file object storage (GCS/S3/Azure) + connection (access delegation) → row/column security tanpa memberi akses bucket
BigQuery Omni	BigQuery yang berjalan di AWS/Azure; data tidak dipindahkan; pakai BigLake table
Datastream	CDC serverless dari database (MySQL, PostgreSQL, Oracle, SQL Server) → BigQuery/GCS, hampir real-time
Storage class	Standard (0) · Nearline 30 hari (≤1x/bulan) · Coldline 90 hari (≤1x/kuartal) · Archive 365 hari (<1x/tahun)
Autoclass	Berdasarkan akses, bukan umur; tanpa biaya retrieval; tidak bisa digabung dengan SetStorageClass
Lifecycle vs retention vs hold	Lifecycle = aksi otomatis (hapus/pindah). Retention = larangan hapus sebelum X (Bucket Lock = permanen). Event-based hold = retensi dihitung sejak hold dilepas
Region vs dual vs multi	Region = residency + latensi rendah. Dual-region = 2 region spesifik + Turbo (RPO 15 menit). Multi-region = availability tertinggi, area luas
Cloud SQL HA vs read replica	HA = standby sinkron di zona lain, failover otomatis, tidak bisa dibaca. Replica = asinkron, bisa dibaca, bisa cross-region, promote manual
Snapshot vs view	Snapshot = salinan read-only pada titik waktu. View = query tersimpan tanpa data. Materialized = hasil precomputed. Clone = salinan writable
Authorized view	Berbagi subset tanpa akses ke tabel sumber (view diotorisasi di dataset sumber)
Analytics Hub	Berbagi dataset lintas organisasi lewat listing; linked dataset tanpa salinan; subscriber membayar query
Dataplex	Governance: katalog, lineage, profiling, data quality scan. Bukan tool untuk "melihat semua akses IAM" (untuk itu pakai IAM/Policy Analyzer)
Composer vs Workflows	Composer = Airflow DAG Python, pipeline data kompleks. Workflows = serverless, YAML, merangkai API
STS vs BQ DTS	STS → tujuan Cloud Storage (file). BQ DTS → tujuan BigQuery (tabel), termasuk SaaS seperti Google Ads
LookML	view (dimension/measure) · model · explore · join + relationship · primary_key · hidden
Dataprep vs Dataflow	Dataprep/Data Fusion = visual tanpa kode. Dataflow = engine Beam berbasis kode, serverless
BQML	CREATE MODEL (OPTIONS model_type, input_label_cols) → ML.EVALUATE → ML.PREDICT; ARIMA_PLUS → ML.FORECAST
IAM least privilege	Predefined role, scope sekecil mungkin. Query = dataViewer + jobUser. Upload saja = objectCreator
CMEK / KMS	CMEK = kunci di Cloud KMS yang dikendalikan pelanggan; service agent perlu cryptoKeyEncrypterDecrypter. CSEK = kunci dikirim per request (GCS)

🎯 **FOKUS KAMU**

Jebakan yang sering bikin salah: (1) Memilih Composer untuk tugas yang cukup dengan scheduled query atau Workflows. (2) Memilih read replica untuk "automatic failover zonal" (jawabannya HA). (3) Memilih time travel untuk retensi lebih dari 7 hari (jawabannya snapshot). (4) Memilih STS saat tujuannya BigQuery (jawabannya BQ DTS). (5) Memilih CSEK untuk BigQuery (tidak didukung). (6) Memilih Archive untuk data yang diakses tiap bulan. (7) Memberi basic role Editor/Owner padahal ada predefined role yang lebih sempit.

9. Ringkasan Last-Minute (1 Halaman)

Ujian

- 2 jam · 50–60 soal · MC + multiple select · USD 125 · EN/JP
- D1 30% · D2 27% · D3 18% · D4 25%
- Pilih yang managed, serverless, paling sederhana, dan least privilege

Ingest & pindah data

- File → GCS: **STS** (online) / **Transfer Appliance** (besar + lambat)
- Ke BigQuery terjadwal / SaaS: **BQ DTS**
- CDC database → BQ: **Datastream**
- Migrasi DB → Cloud SQL/AlloyDB: **DMS**
- Streaming: **Pub/Sub** (+ Dataflow jika ada transformasi)
- Parquet = kolumnar · Avro = baris + skema · CSV/JSON = baris

Pilih storage

- File/unstructured → **GCS** · Analitik SQL → **BigQuery**
- OLTP regional → **Cloud SQL** / **AlloyDB** (PG kencang)
- Global ACID 99,999% → **Spanner**
- Throughput tinggi, ms, key lookup → **Bigtable**
- Mobile/dokumen/offline → **Firestore**

Analisis & BI

- Window: ROW_NUMBER+QUALIFY (dedup), LAG/LEAD, SUM() OVER
- ARRAY → **UNNEST** · SAFE_CAST · partition + cluster
- Notebook managed → **Colab Enterprise**
- **Looker** = LookML, governed, Git, embed · **Looker Studio** = gratis, cepat
- LookML: dimension/measure/type/sql ;; · hidden · primary_key · relationship

ML

- CREATE MODEL … OPTIONS(model_type, input_label_cols) → ML.EVALUATE → ML.PREDICT
- LINEAR_REG angka · LOGISTIC_REG kelas · KMEANS segmen · ARIMA_PLUS + ML.FORECAST
- LLM: connection + REMOTE WITH CONNECTION + AI.GENERATE_TEXT
- Gambar tanpa ahli ML → **AutoML** · versi/deploy → **Model Registry**

Pipeline & orkestrasi

- Pipeline baru batch+stream → **Dataflow** · Spark lama → **Dataproc**
- Visual → **Data Fusion** · SQL ELT di BQ → **Dataform**
- 1 SQL berkala → **scheduled query** · cron → **Scheduler**
- DAG kompleks → **Composer** · rangkai API → **Workflows**
- Spark berantai + cluster ephemeral → **Dataproc Workflow Template**
- File masuk bucket → **Eventarc** → Cloud Run · lag → **Dataflow job UI**

Akses & sharing

- Query = **dataViewer** (dataset) + **jobUser** (project)
- Upload saja = **objectCreator** · hindari basic role
- Uniform bucket-level access + public access prevention
- Signed URL ≤ 7 hari · Authorized view = subset tanpa akses sumber
- Antar organisasi tanpa copy → **Analytics Hub** · governance/quality → **Dataplex**

Lifecycle & storage class

- Standard 0 · **Nearline 30** · **Coldline 90** · **Archive 365** hari
- Akses tak diketahui → **Autoclass** · pola diketahui → lifecycle rule
- WORM → retention + Bucket Lock · sejak event → event-based hold
- BQ: partition/table expiration · time travel ≤7 hari · snapshot (read-only) · clone (writable) · MV (agregasi cepat)

HA / DR & enkripsi

- Residency → region · DR 2 region + RPO 15 menit → dual-region + Turbo
- Cloud SQL zona gagal → **HA** · baca/DR regional → **read replica** · salah DELETE → **PITR** (instance baru)
- Default = Google-managed · rotate/revoke sendiri → **CMEK** (KMS)
- Google tak simpan kunci → **CSEK** (GCS, bukan BigQuery) · TLS = in transit