GOOGLE CLOUD CERTIFIED · ASSOCIATE DATA PRACTITIONER

Latihan Soal Google Cloud Associate Data Practitioner – Prediksi Ujian

60 soal skenario orisinal · Bilingual (English / Bahasa Indonesia) · Kunci jawaban & pembahasan lengkap

Disusun untuk: Muhammad Yusuf Ridho

Acuan: Associate Data Practitioner Certification Exam Guide v1.0 (Google Cloud)
Versi: Oktober 2026

Cara Memakai Buku Ini

1. **Kerjakan seperti ujian asli.** Baca soal versi English dulu (ujian resmi tersedia dalam English dan Japanese), lalu tutup bagian jawaban dengan kertas. Target waktu: ±2 menit per soal (ujian asli 2 jam untuk 50–60 soal).
2. **Bingung istilah?** Baca terjemahan Bahasa Indonesia di kotak abu-abu.
3. **Cocokkan jawaban**, lalu baca pembahasan. Bagian terpenting adalah "kenapa opsi lain salah", karena ujian ADP banyak memakai distraktor yang terdengar benar.
4. **Soal "Choose two" (Pilih dua)** ada 6 buah (no. 17, 30, 44, 48, 56, 58), mengikuti format multiple-select di ujian asli. Nilainya benar hanya jika kedua pilihan tepat.
5. **Catat salahmu per domain** di tabel ringkasan jawaban di halaman akhir, lalu ulangi materi domain yang paling lemah.

Domain (exam guide v1.0)	Bobot resmi	Jumlah soal	Nomor
Section 1 · Data Preparation & Ingestion	~30%	18	1–18
Section 2 · Data Analysis & Presentation	~27%	16	19–34
Section 3 · Data Pipeline Orchestration	~18%	11	35–45
Section 4 · Data Management	~25%	15	46–60
Total	**100%**	**60**	**1–60**

Fokus khusus (berdasarkan catatan kelemahanmu): BigLake/BigQuery Omni/Datastream, storage class, lifecycle, Autoclass, object hold, region vs dual/multi-region, Cloud SQL HA vs read replica, snapshot vs view/authorized view/materialized view, Analytics Hub, Dataplex, Composer vs Workflows, Storage Transfer Service vs BigQuery DTS, LookML, Dataprep/Data Fusion vs Dataflow, BigQuery ML, IAM least privilege, CMEK/CSEK/Cloud KMS.

> **Penting, soal ini bukan bocoran.** Soal ujian resmi Google bersifat rahasia dan tidak dipublikasikan. Semua soal di sini orisinal, disusun dari exam guide resmi dan dokumentasi Google Cloud agar gaya dan cakupannya semirip mungkin dengan ujian. Nama beberapa produk sedang di-rebrand oleh Google (misalnya Analytics Hub menjadi "BigQuery sharing", Dataplex menjadi "Dataplex Universal Catalog", dan Vertex AI). Buku ini memakai nama seperti di exam guide v1.0. Selalu cek dokumentasi resmi untuk detail angka atau fitur terbaru.

Soal 1

Section 1 · Data Preparation & Ingestion

ENGLISH

A hospital network is moving patient visit records from an on-premises database to BigQuery for analytics. A regulation states that national ID numbers must be irreversibly masked before the data is stored in any cloud system. The team prefers a visual, low-code tool. What should you do?

A. Load the raw records into BigQuery and apply column-level security with a policy tag on the national ID column.

B. Copy the raw files to Cloud Storage and create a BigQuery external table that excludes the national ID column.

C. Load the raw records into BigQuery and create a view that hides the national ID column from analysts.

D. Build a Cloud Data Fusion pipeline that masks the national ID field during the transformation stage, and then writes the result to BigQuery.

BAHASA INDONESIA

Sebuah jaringan rumah sakit memindahkan data kunjungan pasien dari database on-premises ke BigQuery untuk analitik. Regulasi mewajibkan nomor KTP di-mask secara permanen SEBELUM data disimpan di sistem cloud mana pun. Tim lebih suka tool visual low-code. Apa yang harus Anda lakukan?

A. Load data mentah ke BigQuery lalu terapkan column-level security dengan policy tag pada kolom KTP.

B. Salin file mentah ke Cloud Storage lalu buat external table BigQuery yang tidak menyertakan kolom KTP.

C. Load data mentah ke BigQuery lalu buat view yang menyembunyikan kolom KTP dari analis.

D. Buat pipeline Cloud Data Fusion yang me-mask kolom KTP di tahap transformasi, lalu menulis hasilnya ke BigQuery.

✔ Jawaban benar: D

Kenapa benar: Syaratnya data harus sudah ter-mask sebelum mendarat di cloud, jadi transformasi wajib terjadi sebelum load. Itu pola ETL (Extract, Transform, Load). Cloud Data Fusion adalah tool ETL visual/low-code yang bisa melakukan masking di tengah pipeline sebelum menulis ke BigQuery.

A salah: Policy tag membatasi siapa yang boleh melihat kolom, tetapi nilai KTP asli tetap tersimpan di BigQuery.

B salah: File mentah yang berisi KTP asli tetap tersimpan di Cloud Storage, yang juga merupakan sistem cloud.

C salah: Ini pola ELT. Data mentah (dengan KTP asli) sudah tersimpan di BigQuery, jadi melanggar regulasi. View hanya menyembunyikan, tidak menghapus data.

Soal 2

Section 1 · Data Preparation & Ingestion

ENGLISH

Your company has 40 TB of log archives on an on-premises NAS and adds about 200 GB of new files every day. You have a 10 Gbps Dedicated Interconnect to Google Cloud. The files must be copied to

Cloud Storage and kept in sync daily, and the transfer must not use more than 2 Gbps during business hours. What should you use?

A. Transfer Appliance, shipped every week with the new files.

B. BigQuery Data Transfer Service with a Cloud Storage source.

C. A cron job on an on-premises server that runs gcloud storage cp every night.

D. Storage Transfer Service with transfer agents installed on-premises, a daily schedule, and a bandwidth limit.

BAHASA INDONESIA

Perusahaan Anda punya arsip log 40 TB di NAS on-premises dan bertambah sekitar 200 GB file baru setiap hari. Anda punya Dedicated Interconnect 10 Gbps ke Google Cloud. File harus disalin ke Cloud Storage dan disinkronkan setiap hari, dan transfer tidak boleh memakai lebih dari 2 Gbps saat jam kerja. Apa yang sebaiknya digunakan?

A. Transfer Appliance yang dikirim setiap minggu berisi file baru.

B. BigQuery Data Transfer Service dengan sumber Cloud Storage.

C. Cron job di server on-premises yang menjalankan gcloud storage cp setiap malam.

D. Storage Transfer Service dengan transfer agent yang di-install di on-premises, jadwal harian, dan batas bandwidth.

✔ Jawaban benar: D

Kenapa benar: Storage Transfer Service (STS) mendukung transfer dari file system on-premises lewat agent, bisa dijadwalkan, hanya menyalin file yang baru/berubah (incremental), dan mendukung pembatasan bandwidth. Dengan link 10 Gbps, 40 TB bisa selesai dalam hitungan hari, jadi transfer online lebih masuk akal.

A salah: Transfer Appliance cocok untuk volume sangat besar dengan jaringan lambat, dan untuk sekali kirim. Mengirim perangkat fisik tiap minggu untuk 200 GB/hari tidak praktis.

B salah: BigQuery Data Transfer Service memuat data ke BigQuery dari sumber yang didukung (SaaS, Cloud Storage, S3, dll.). Ia tidak membaca file dari NAS on-premises dan tujuannya bukan Cloud Storage.

C salah: Bisa jalan, tetapi Anda harus membuat sendiri retry, sinkronisasi incremental, monitoring, dan bandwidth throttling. Ini bukan solusi managed.

Soal 3

Section 1 · Data Preparation & Ingestion

ENGLISH

The marketing team exports daily campaign CSV files to an Amazon S3 bucket. They want the files loaded into a BigQuery table every morning on a schedule, with no custom code and without first copying them to Cloud Storage. What should you do?

A. Use Database Migration Service to migrate the S3 data into BigQuery.

B. Use Datastream to replicate the S3 bucket into BigQuery.

C. Use Storage Transfer Service to copy the files to Cloud Storage, then run bq load manually.

D. Create a BigQuery Data Transfer Service transfer for Amazon S3 with a daily schedule.

BAHASA INDONESIA

Tim marketing mengekspor file CSV kampanye harian ke bucket Amazon S3. Mereka ingin file tersebut di-load ke tabel BigQuery setiap pagi secara terjadwal, tanpa kode custom dan tanpa harus menyalinnya dulu ke Cloud Storage. Apa yang harus Anda lakukan?

A. Gunakan Database Migration Service untuk memigrasikan data S3 ke BigQuery.

B. Gunakan Datastream untuk mereplikasi bucket S3 ke BigQuery.

C. Gunakan Storage Transfer Service untuk menyalin file ke Cloud Storage, lalu jalankan bq load secara manual.

D. Buat transfer BigQuery Data Transfer Service untuk Amazon S3 dengan jadwal harian.

✔ Jawaban benar: D

Kenapa benar: BigQuery Data Transfer Service (BQ DTS) punya connector Amazon S3 yang langsung memuat file (CSV, JSON, Avro, Parquet, ORC) ke tabel BigQuery secara terjadwal, tanpa kode. Cara cepat mengingatnya: tujuannya BigQuery, jadi pakai BQ DTS. Kalau tujuannya Cloud Storage, pakai STS.

A salah: Database Migration Service memigrasikan database ke Cloud SQL atau AlloyDB, bukan file S3 ke BigQuery.

B salah: Datastream adalah layanan CDC (change data capture) untuk database seperti MySQL, PostgreSQL, Oracle, dan SQL Server, bukan untuk file di object storage.

C salah: Ada langkah manual dan perantara Cloud Storage, padahal syaratnya tanpa kode dan tanpa menyalin ke Cloud Storage.

Soal 4

Section 1 · Data Preparation & Ingestion

ENGLISH

A media company must copy 600 TB of video files from Azure Blob Storage into a Cloud Storage bucket for long-term archiving. They also want to copy any new files once a week. The videos will not be analyzed in BigQuery. Which service should you use?

A. BigQuery Data Transfer Service

B. Storage Transfer Service

C. Transfer Appliance

D. Datastream

BAHASA INDONESIA

Sebuah perusahaan media harus menyalin 600 TB file video dari Azure Blob Storage ke bucket Cloud Storage untuk arsip jangka panjang. Mereka juga ingin file baru ikut disalin seminggu sekali. Video tidak akan dianalisis di BigQuery. Layanan mana yang sebaiknya digunakan?

A. BigQuery Data Transfer Service

B. Storage Transfer Service

C. Transfer Appliance

D. Datastream

✔ **Jawaban benar: B**

Kenapa benar: Storage Transfer Service mendukung sumber cloud lain (Amazon S3, Azure Blob Storage, URL HTTP/HTTPS) dengan tujuan Cloud Storage, berjalan cloud-to-cloud tanpa perangkat fisik, dan bisa dijadwalkan berulang untuk file baru.

A salah: BQ DTS memuat data ke tabel BigQuery. Di sini tujuannya bucket Cloud Storage untuk arsip, bukan BigQuery.

C salah: Transfer Appliance untuk data on-premises dengan jaringan terbatas. Data ini sudah ada di cloud publik (Azure), jadi transfer online cloud-to-cloud lebih tepat.

D salah: Datastream untuk replikasi CDC dari database, bukan menyalin file objek.

Soal 5

Section 1 · Data Preparation & Ingestion

ENGLISH

An e-commerce company runs its order system on Cloud SQL for MySQL. Analysts need inserts, updates, and deletes from the orders tables to appear in BigQuery within minutes. The solution must be serverless, require no custom code, and add minimal load on the source database. What should you do?

A. Schedule a BigQuery federated query to Cloud SQL every 5 minutes that copies all rows into BigQuery.

B. Use Datastream to replicate changes from Cloud SQL for MySQL directly into BigQuery.

C. Export the database to Cloud Storage every hour and load the dump into BigQuery.

D. Use Database Migration Service with a continuous migration job to BigQuery.

BAHASA INDONESIA

Sebuah perusahaan e-commerce menjalankan sistem order di Cloud SQL for MySQL. Analis perlu insert, update, dan delete dari tabel order muncul di BigQuery dalam hitungan menit. Solusinya harus serverless, tanpa kode custom, dan menambah beban seminimal mungkin ke database sumber. Apa yang harus Anda lakukan?

A. Jadwalkan federated query BigQuery ke Cloud SQL setiap 5 menit yang menyalin semua baris ke BigQuery.

B. Gunakan Datastream untuk mereplikasi perubahan dari Cloud SQL for MySQL langsung ke BigQuery.

C. Ekspor database ke Cloud Storage setiap jam lalu load dump-nya ke BigQuery.

D. Gunakan Database Migration Service dengan continuous migration job ke BigQuery.

✔ **Jawaban benar: B**

Kenapa benar: Datastream adalah layanan CDC serverless. Ia membaca log perubahan database (binlog di MySQL), jadi beban ke database sumber rendah, lalu mereplikasi insert, update, dan delete ke BigQuery hampir real-time tanpa kode.

A salah: Menyalin semua baris tiap 5 menit memberi beban berat ke database dan boros. Pendekatan polling seperti ini juga tidak menangkap delete dengan baik.

C salah: Ekspor tiap jam tidak memenuhi syarat "dalam hitungan menit" dan ekspor penuh membebani database.

D salah: Database Migration Service memigrasikan database ke Cloud SQL atau AlloyDB. BigQuery bukan target DMS.

Soal 6

Section 1 · Data Preparation & Ingestion

ENGLISH

You need to migrate a 2 TB on-premises PostgreSQL database to Cloud SQL for PostgreSQL. The application can only tolerate a few minutes of downtime during cutover. What should you do?

A. Run pg_dump, upload the file to Cloud Storage, and import it into Cloud SQL during a maintenance window.

B. Use Database Migration Service with a continuous migration job, then promote the destination instance at cutover.

C. Use Storage Transfer Service to copy the PostgreSQL data files to Cloud SQL.

D. Use Datastream to replicate the database into BigQuery, then point the application at BigQuery.

BAHASA INDONESIA

Anda perlu memigrasikan database PostgreSQL on-premises berukuran 2 TB ke Cloud SQL for PostgreSQL. Aplikasi hanya bisa menoleransi downtime beberapa menit saat cutover. Apa yang harus Anda lakukan?

A. Jalankan pg_dump, upload file ke Cloud Storage, lalu import ke Cloud SQL saat maintenance window.

B. Gunakan Database Migration Service dengan continuous migration job, lalu promote instance tujuan saat cutover.

C. Gunakan Storage Transfer Service untuk menyalin file data PostgreSQL ke Cloud SQL.

D. Gunakan Datastream untuk mereplikasi database ke BigQuery, lalu arahkan aplikasi ke BigQuery.

✔ Jawaban benar: B

Kenapa benar: Database Migration Service (DMS) melakukan full dump awal lalu terus mereplikasi perubahan (continuous migration). Saat semuanya sudah sinkron, Anda tinggal promote instance Cloud SQL, jadi downtime hanya beberapa menit.

A salah: Dump dan restore 2 TB butuh berjam-jam, dan selama itu aplikasi harus berhenti agar data konsisten. Downtime-nya terlalu lama.

C salah: STS memindahkan file ke Cloud Storage. Ia tidak bisa menulis ke Cloud SQL, dan menyalin file data mentah PostgreSQL bukan cara migrasi yang didukung.

D salah: BigQuery adalah data warehouse analitik, bukan pengganti database transaksional (OLTP) untuk aplikasi.

Soal 7

Section 1 · Data Preparation & Ingestion

ENGLISH

A data lake in Cloud Storage holds billions of event records. Analysts query them from BigQuery without loading the data, and most queries read only 5 of the 120 fields. You want to minimize the amount of data scanned. In which file format should the events be stored?

A. Newline-delimited JSON

B. CSV

C. Apache Parquet

D. Apache Avro

BAHASA INDONESIA

Sebuah data lake di Cloud Storage menyimpan miliaran record event. Analis meng-query-nya dari BigQuery tanpa me-load data, dan kebanyakan query hanya membaca 5 dari 120 kolom. Anda ingin meminimalkan jumlah data yang di-scan. Dalam format file apa event sebaiknya disimpan?

A. Newline-delimited JSON

B. CSV

C. Apache Parquet

D. Apache Avro

✔ Jawaban benar: C

Kenapa benar: Parquet adalah format kolumnar. Engine hanya membaca kolom yang dibutuhkan (column pruning), datanya terkompresi per kolom, dan skemanya ikut tersimpan di file. Untuk query yang hanya membaca sedikit kolom dari banyak kolom, Parquet paling efisien.

A salah: JSON juga berbasis baris, sehingga lebih besar dan lebih lambat untuk query analitik.

B salah: CSV berbasis baris dan tanpa skema, jadi seluruh baris harus dibaca.

D salah: Avro berbasis baris. Avro sangat bagus untuk menulis/streaming, evolusi skema, dan load ke BigQuery, tetapi tidak bisa membaca hanya sebagian kolom secara efisien seperti Parquet.

Soal 8

Section 1 · Data Preparation & Ingestion

ENGLISH

A fintech company is building a payment ledger that must support ACID transactions, a relational schema with SQL, strong consistency, and writes from users in Asia, Europe, and the US with 99.999% availability. Which storage service should you choose?

A. Bigtable

B. Spanner

C. Cloud SQL with cross-region read replicas

D. BigQuery

BAHASA INDONESIA

Sebuah perusahaan fintech membangun ledger pembayaran yang harus mendukung transaksi ACID, skema relasional dengan SQL, strong consistency, dan penulisan dari pengguna di Asia, Eropa, dan AS dengan availability 99,999%. Layanan penyimpanan apa yang sebaiknya dipilih?

A. Bigtable
B. Spanner
C. Cloud SQL dengan cross-region read replica
D. BigQuery

✔ Jawaban benar: B

Kenapa benar: Spanner adalah database relasional yang terdistribusi global. Ia mendukung transaksi ACID, SQL, dan strong consistency, bisa menerima tulisan di banyak region, dan konfigurasi multi-region-nya punya SLA 99,999%.

A salah: Bigtable adalah NoSQL wide-column tanpa SQL relasional penuh dan tanpa transaksi multi-baris yang umum.

C salah: Cloud SQL hanya punya satu primary yang menerima tulisan. Read replica hanya untuk baca dan replikasinya asinkron, jadi tidak memenuhi kebutuhan tulis global.

D salah: BigQuery adalah data warehouse analitik (OLAP), bukan database transaksional untuk ledger.

Soal 9

Section 1 · Data Preparation & Ingestion

ENGLISH

An ad-tech platform must store user profiles keyed by a device ID. It handles hundreds of thousands of reads and writes per second, each needing single-digit millisecond latency. Queries are always lookups by key, and no joins are needed. Which service fits best?

A. BigQuery
B. Bigtable
C. Cloud Storage
D. Cloud SQL for PostgreSQL

BAHASA INDONESIA

Sebuah platform ad-tech harus menyimpan profil pengguna dengan key device ID. Beban mencapai ratusan ribu baca dan tulis per detik, masing-masing dengan latensi satu digit milidetik. Query selalu lookup berdasarkan key dan tidak butuh join. Layanan mana yang paling cocok?

A. BigQuery
B. Bigtable
C. Cloud Storage
D. Cloud SQL for PostgreSQL

✔ **Jawaban benar: B**

Kenapa benar: Bigtable adalah NoSQL wide-column untuk throughput sangat tinggi dan latensi rendah pada akses berbasis row key. Contoh kasus khasnya: IoT, time series, ad-tech, dan personalisasi.

A salah: BigQuery dirancang untuk query analitik besar dengan latensi hitungan detik, bukan lookup per key dalam milidetik.

C salah: Cloud Storage adalah object storage untuk file, bukan database key-value berlatensi rendah.

D salah: Cloud SQL cocok untuk OLTP relasional skala kecil sampai menengah, dan sulit melayani ratusan ribu operasi per detik dengan latensi konsisten.

Soal 10

Section 1 · Data Preparation & Ingestion

ENGLISH

A retailer has three new data sources: (1) product photos, (2) clickstream events in JSON whose fields change often, and (3) a customer master table with fixed columns that a web application updates in real time. Which storage mapping is most appropriate?

A. (1) Bigtable, (2) Cloud Storage, (3) BigQuery

B. (1) BigQuery, (2) Cloud SQL, (3) Cloud Storage

C. (1) Cloud Storage, (2) BigQuery with the JSON data type, (3) Cloud SQL

D. (1) Cloud SQL, (2) Bigtable, (3) Cloud Storage

BAHASA INDONESIA

Sebuah peritel punya tiga sumber data baru: (1) foto produk, (2) event clickstream dalam JSON yang field-nya sering berubah, (3) tabel master pelanggan dengan kolom tetap yang di-update real-time oleh aplikasi web. Pemetaan penyimpanan mana yang paling tepat?

A. (1) Bigtable, (2) Cloud Storage, (3) BigQuery

B. (1) BigQuery, (2) Cloud SQL, (3) Cloud Storage

C. (1) Cloud Storage, (2) BigQuery dengan tipe data JSON, (3) Cloud SQL

D. (1) Cloud SQL, (2) Bigtable, (3) Cloud Storage

✔ **Jawaban benar: C**

Kenapa benar: Foto adalah data tidak terstruktur, jadi disimpan di Cloud Storage. Clickstream JSON adalah data semi-terstruktur yang akan dianalisis, dan BigQuery mendukung tipe JSON serta nested/repeated field, jadi cocok untuk skema yang sering berubah. Tabel master yang di-update aplikasi secara real-time adalah data terstruktur transaksional (OLTP), jadi disimpan di Cloud SQL.

A salah: Bigtable bukan tempat file gambar, dan BigQuery bukan database untuk update transaksional real-time dari aplikasi web.

B salah: Foto tidak disimpan di BigQuery, data OLTP tidak cocok di Cloud Storage, dan Cloud SQL kaku untuk JSON yang skemanya sering berubah.

D salah: Cloud SQL bukan tempat menyimpan file foto, dan Cloud Storage tidak bisa melayani update baris secara transaksional.

Soal 11

Section 1 · Data Preparation & Ingestion

ENGLISH

A bank in Indonesia must keep raw transaction files inside Indonesia because of data residency rules. The files are processed by a Dataproc cluster in asia-southeast2 (Jakarta). You want the lowest latency and to avoid network egress charges between storage and compute. Which bucket location should you choose?

A. Multi-region ASIA

B. Dual-region asia-southeast1 and asia-southeast2

C. Multi-region US, with Turbo replication

D. Region asia-southeast2

BAHASA INDONESIA

Sebuah bank di Indonesia wajib menyimpan file transaksi mentah di dalam wilayah Indonesia karena aturan data residency. File diproses oleh cluster Dataproc di asia-southeast2 (Jakarta). Anda ingin latensi terendah dan tidak ada biaya egress jaringan antara storage dan compute. Lokasi bucket mana yang sebaiknya dipilih?

A. Multi-region ASIA

B. Dual-region asia-southeast1 dan asia-southeast2

C. Multi-region US dengan Turbo replication

D. Region asia-southeast2

✔ Jawaban benar: D

Kenapa benar: Bucket regional di asia-southeast2 menyimpan data hanya di Jakarta, sehingga memenuhi data residency. Bucket itu juga berada di region yang sama dengan Dataproc, jadi latensinya terendah dan tidak ada biaya transfer antar-lokasi.

A salah: Multi-region ASIA bisa menyimpan data di beberapa negara Asia, jadi melanggar aturan residency.

B salah: asia-southeast1 adalah Singapura, di luar Indonesia.

C salah: Data akan berada di AS, jadi melanggar residency. Turbo replication juga hanya tersedia untuk dual-region.

Soal 12

Section 1 · Data Preparation & Ingestion

ENGLISH

A one-time export of 3 GB of CSV files is in gs://sales-raw/2026/. You want to load the files into a new BigQuery table from the command line and let BigQuery infer the schema. Which command should you use?

A. `bq load --source_format=CSV --autodetect sales.orders_2026 gs://sales-raw/2026/*.csv`

B. `gcloud dataflow jobs run load-csv --source=gs://sales-raw/2026/`

C. `gcloud storage cp gs://sales-raw/2026/*.csv bq://sales.orders_2026`

D. bq query --autodetect "LOAD gs://sales-raw/2026/*.csv"

BAHASA INDONESIA

Ada ekspor sekali jalan berupa file CSV 3 GB di gs://sales-raw/2026/. Anda ingin me-load file tersebut ke tabel BigQuery baru dari command line dan membiarkan BigQuery mendeteksi skema secara otomatis. Perintah mana yang digunakan?

A. `bq load --source_format=CSV --autodetect sales.orders_2026 gs://sales-raw/2026/*.csv`

B. `gcloud dataflow jobs run load-csv --source=gs://sales-raw/2026/`

C. `gcloud storage cp gs://sales-raw/2026/*.csv bq://sales.orders_2026`

D. bq query --autodetect "LOAD gs://sales-raw/2026/*.csv"

✔ Jawaban benar: A

Kenapa benar: bq load adalah perintah CLI untuk load job BigQuery. --source_format menentukan format file, --autodetect mengaktifkan deteksi skema, dan wildcard (*) memuat banyak file sekaligus. Load job dari Cloud Storage tidak dikenai biaya.

B salah: Dataflow terlalu berlebihan untuk load sekali jalan tanpa transformasi, dan contoh perintah ini juga bukan sintaks yang benar.

C salah: gcloud storage cp menyalin objek antar lokasi storage. Tidak ada tujuan "bq://".

D salah: Sintaks ini tidak valid. Versi SQL-nya adalah statement LOAD DATA INTO ... FROM FILES(...), bukan flag --autodetect pada bq query.

Soal 13

Section 1 · Data Preparation & Ingestion

ENGLISH

Before data is used in executive dashboards, a data team wants to check BigQuery tables on a schedule for null rates, uniqueness of IDs, and valid value ranges, and to see the results without writing a custom framework. What should you use?

A. BigQuery table snapshots taken every day

B. Dataplex data quality scans (with data profiling) on the BigQuery tables

C. Looker Studio charts that count nulls

D. Cloud Monitoring uptime checks on the BigQuery API

BAHASA INDONESIA

Sebelum data dipakai di dashboard eksekutif, tim data ingin memeriksa tabel BigQuery secara terjadwal untuk persentase null, keunikan ID, dan rentang nilai yang valid, serta melihat hasilnya tanpa membuat framework sendiri. Apa yang sebaiknya digunakan?

A. Table snapshot BigQuery yang diambil setiap hari
B. Dataplex data quality scan (beserta data profiling) pada tabel BigQuery
C. Chart di Looker Studio yang menghitung null
D. Uptime check Cloud Monitoring pada BigQuery API

✔ Jawaban benar: B

Kenapa benar: Dataplex (sekarang disebut Dataplex Universal Catalog) menyediakan data profiling dan data quality scan berbasis aturan (misalnya non-null, uniqueness, range, regex, atau aturan SQL) yang bisa dijadwalkan, dan hasilnya bisa dipublikasikan atau diekspor ke BigQuery. Dataplex adalah layanan governance: katalog, lineage, kualitas data, dan profiling.

A salah: Snapshot hanya menyimpan salinan tabel di satu titik waktu dan tidak memeriksa kualitas apa pun.

C salah: Looker Studio adalah tool visualisasi. Menghitung null secara manual di chart bukan pemeriksaan kualitas data yang terjadwal dan berbasis aturan.

D salah: Uptime check memantau ketersediaan endpoint, bukan isi atau kualitas data.

Soal 14

Section 1 · Data Preparation & Ingestion

ENGLISH

Business analysts who do not write code must clean messy CSV files every week: trim spaces, standardize date formats, remove duplicates, and join with a reference file. Then they load the result into BigQuery. They want a visual, drag-and-drop interface with prebuilt transformations and connectors. What should you recommend?

A. Use Pub/Sub with a BigQuery subscription.
B. Use Cloud Data Fusion to build the pipeline visually with its Wrangler and prebuilt plugins.
C. Run PySpark jobs on a Dataproc cluster.
D. Write an Apache Beam pipeline in Java and run it on Dataflow.

BAHASA INDONESIA

Analis bisnis yang tidak menulis kode harus membersihkan file CSV yang berantakan setiap minggu: trim spasi, menyeragamkan format tanggal, menghapus duplikat, dan join dengan file referensi. Setelah itu hasilnya di-load ke BigQuery. Mereka ingin antarmuka visual drag-and-drop dengan transformasi dan connector siap pakai. Apa rekomendasi Anda?

A. Gunakan Pub/Sub dengan BigQuery subscription.
B. Gunakan Cloud Data Fusion untuk membangun pipeline secara visual dengan Wrangler dan plugin siap pakai.
C. Jalankan job PySpark di cluster Dataproc.
D. Tulis pipeline Apache Beam dalam Java dan jalankan di Dataflow.

✔ **Jawaban benar: B**

Kenapa benar: Cloud Data Fusion adalah layanan integrasi data visual (berbasis CDAP) dengan Wrangler untuk pembersihan data interaktif dan ratusan connector/plugin, sehingga cocok untuk pengguna low-code atau no-code. Catatan Dataprep vs Dataflow: Dataprep (dari Trifacta/Alteryx) adalah tool wrangling visual yang dulu menjalankan job-nya di Dataflow, sedangkan Dataflow sendiri adalah engine pemrosesan berbasis kode (Apache Beam). Untuk "visual, tanpa kode", jangan pilih Dataflow langsung.

A salah: Pub/Sub adalah layanan messaging untuk event streaming, bukan tool pembersihan file batch.

C salah: Dataproc menjalankan Spark atau Hadoop dan butuh kode PySpark atau Scala.

D salah: Dataflow menuntut kemampuan coding (Beam SDK), tidak sesuai untuk analis yang tidak menulis kode.

Soal 15

Section 1 · Data Preparation & Ingestion

ENGLISH

A staging table loaded from partner CSV files stores the amount column as STRING. Most values are valid numbers, but some contain text such as "N/A" or "12,5x". When you run CAST(amount AS NUMERIC), the whole query fails. You need to convert the column so that invalid values become NULL and can be counted as a data quality issue, without the query failing. What should you use?

A. CAST(amount AS NUMERIC) with the --max_bad_records flag on the query

B. SAFE_CAST(amount AS NUMERIC)

C. CAST(amount AS STRING)

D. PARSE_DATE('%Y-%m-%d', amount)

BAHASA INDONESIA

Tabel staging yang di-load dari file CSV partner menyimpan kolom amount sebagai STRING. Sebagian besar nilainya angka valid, tetapi ada yang berisi teks seperti "N/A" atau "12,5x". Saat Anda menjalankan CAST(amount AS NUMERIC), seluruh query gagal. Anda perlu mengonversi kolom tersebut agar nilai yang tidak valid menjadi NULL dan bisa dihitung sebagai masalah kualitas data, tanpa membuat query gagal. Apa yang sebaiknya digunakan?

A. CAST(amount AS NUMERIC) dengan flag --max_bad_records pada query

B. SAFE_CAST(amount AS NUMERIC)

C. CAST(amount AS STRING)

D. PARSE_DATE('%Y-%m-%d', amount)

✔ **Jawaban benar: B**

Kenapa benar: SAFE_CAST bekerja seperti CAST, tetapi mengembalikan NULL (bukan error) jika konversi gagal. Dengan begitu query tetap berjalan, dan Anda bisa menghitung baris bermasalah, misalnya dengan COUNTIF(amount IS NOT NULL AND SAFE_CAST(amount AS NUMERIC) IS NULL), sebagai metrik kualitas data. Prefiks SAFE. juga tersedia untuk banyak fungsi lain, misalnya SAFE.PARSE_DATE dan SAFE_DIVIDE.

A salah: --max_bad_records adalah opsi untuk load job (bq load), yang melewati baris rusak saat memuat file. Opsi ini tidak berlaku untuk CAST di dalam query.

C salah: Kolomnya sudah STRING. Mengubahnya ke STRING tidak menghasilkan angka.

D salah: PARSE_DATE mengurai tanggal, bukan angka, dan juga akan error pada nilai yang tidak valid.

Soal 16

Section 1 · Data Preparation & Ingestion

ENGLISH

A streaming pipeline reads JSON messages from Pub/Sub, cleans them, and writes them to BigQuery. About 0.5% of messages are malformed and currently make the job fail repeatedly. You want valid records to keep flowing while malformed records are kept for later inspection. What should you do in the Dataflow pipeline?

A. Catch parsing errors and route failed records to a dead-letter output, such as a separate BigQuery table or a Cloud Storage location.

B. Delete the Pub/Sub subscription and recreate it.

C. Increase the number of Dataflow workers.

D. Switch the pipeline from streaming to batch mode.

BAHASA INDONESIA

Sebuah pipeline streaming membaca pesan JSON dari Pub/Sub, membersihkannya, lalu menulis ke BigQuery. Sekitar 0,5% pesan rusak (malformed) dan saat ini membuat job gagal berulang kali. Anda ingin record yang valid tetap mengalir, sementara record rusak disimpan untuk diperiksa nanti. Apa yang harus dilakukan di pipeline Dataflow?

A. Tangkap error parsing dan arahkan record yang gagal ke dead-letter output, misalnya tabel BigQuery terpisah atau lokasi Cloud Storage.

B. Hapus subscription Pub/Sub lalu buat ulang.

C. Tambah jumlah worker Dataflow.

D. Ubah pipeline dari mode streaming ke batch.

✔ **Jawaban benar: A**

Kenapa benar: Pola dead-letter (dead-letter queue/output) memisahkan record yang gagal diproses ke tujuan lain, sementara record valid terus diproses. Ini praktik standar untuk data cleaning di Dataflow (misalnya dengan multiple outputs atau tagged outputs di Beam).

B salah: Membuat ulang subscription tidak menyelesaikan masalah data rusak dan bisa menghilangkan pesan.

C salah: Masalahnya data rusak, bukan kapasitas. Worker tambahan tetap akan gagal pada pesan yang sama.

D salah: Mode batch tidak memenuhi kebutuhan streaming dan tetap gagal pada record rusak.

Soal 17 CHOOSE TWO

Section 1 · Data Preparation & Ingestion

ENGLISH

Your data lake stores Parquet files in Cloud Storage. Analysts should query them from BigQuery, but they must not get direct access to the bucket, and some columns must be hidden from certain groups. You decide to create BigLake tables instead of standard external tables. Which TWO benefits of BigLake tables support this decision? (Choose two.)

A. Access delegation: queries use a BigQuery connection's service account, so users do not need Cloud Storage permissions.

B. Fine-grained security, such as row-level and column-level security, can be enforced on the table.

C. The Parquet files are automatically copied into BigQuery managed storage.

D. BigLake tables can only read CSV files, which simplifies governance.

E. Queries on BigLake tables are always free of charge.

BAHASA INDONESIA

Data lake Anda menyimpan file Parquet di Cloud Storage. Analis harus bisa meng-query-nya dari BigQuery tetapi tidak boleh punya akses langsung ke bucket, dan beberapa kolom harus disembunyikan dari grup tertentu. Anda memutuskan membuat BigLake table, bukan external table biasa. DUA manfaat BigLake table mana yang mendukung keputusan ini? (Pilih dua.)

A. Access delegation: query memakai service account dari BigQuery connection, sehingga pengguna tidak perlu izin Cloud Storage.

B. Keamanan granular, seperti row-level dan column-level security, dapat diterapkan pada tabel.

C. File Parquet otomatis disalin ke managed storage BigQuery.

D. BigLake table hanya bisa membaca file CSV sehingga governance lebih sederhana.

E. Query pada BigLake table selalu gratis.

✔ Jawaban benar: A, B

Kenapa benar: BigLake table memakai BigQuery connection (access delegation), sehingga pengguna cukup diberi izin pada tabel dan tidak perlu izin ke bucket. BigLake juga mendukung row-level security, column-level security (policy tag), dan data masking, sama seperti tabel BigQuery biasa, padahal datanya tetap di object storage.

C salah: Data tetap berada di Cloud Storage. BigLake tidak menyalin data ke storage BigQuery.

D salah: BigLake mendukung format terbuka seperti Parquet, ORC, Avro, CSV, JSON, serta Iceberg dan Delta Lake.

E salah: Query tetap dikenai biaya sesuai model harga BigQuery (on-demand atau capacity).

Soal 18

Section 1 · Data Preparation & Ingestion

ENGLISH

A company stores 500 TB of clickstream data in Amazon S3. Moving the data out of AWS is not allowed for contractual reasons and egress costs. Analysts want to use standard BigQuery SQL from the Google Cloud console to analyze this data in place. What should you do?

A. Use Storage Transfer Service to copy the data to Cloud Storage, then query it.

B. Use BigQuery Data Transfer Service to load the S3 data into BigQuery every day.

C. Use BigQuery Omni with BigLake tables that point to the S3 data.

D. Use Datastream to replicate the S3 data to BigQuery.

BAHASA INDONESIA

Sebuah perusahaan menyimpan 500 TB data clickstream di Amazon S3. Data tidak boleh dipindahkan keluar dari AWS karena alasan kontrak dan biaya egress. Analis ingin memakai SQL BigQuery standar dari Google Cloud console untuk menganalisis data tersebut di tempatnya. Apa yang harus dilakukan?

A. Gunakan Storage Transfer Service untuk menyalin data ke Cloud Storage, lalu query.

B. Gunakan BigQuery Data Transfer Service untuk memuat data S3 ke BigQuery setiap hari.

C. Gunakan BigQuery Omni dengan BigLake table yang menunjuk ke data S3.

D. Gunakan Datastream untuk mereplikasi data S3 ke BigQuery.

✔ Jawaban benar: C

Kenapa benar: BigQuery Omni menjalankan engine BigQuery di region AWS atau Azure, sehingga query diproses dekat dengan data di S3 atau Azure Blob melalui BigLake table, dan data tidak dipindahkan. Analis tetap memakai antarmuka dan SQL BigQuery yang sama.

A salah: Data dipindahkan keluar dari AWS, jadi melanggar kontrak dan menimbulkan biaya egress.

B salah: BQ DTS memindahkan atau menyalin data ke BigQuery, sama-sama melanggar syarat "tidak boleh keluar AWS".

D salah: Datastream untuk CDC dari database, bukan file di S3, dan tetap memindahkan data.

Soal 19

Section 2 · Data Analysis & Presentation

ENGLISH

The table monthly_revenue has the columns month (DATE) and revenue (NUMERIC), with one row per month. Finance wants each month's revenue next to the previous month's revenue so they can calculate month-over-month growth. Which expression returns the previous month's revenue?

A. LAG(revenue) OVER (ORDER BY month)

B. LEAD(revenue) OVER (ORDER BY month)

C. FIRST_VALUE(revenue) OVER (PARTITION BY month)

D. SUM(revenue) OVER (ORDER BY month)

BAHASA INDONESIA

Tabel monthly_revenue memiliki kolom month (DATE) dan revenue (NUMERIC), satu baris per bulan. Tim finance ingin revenue setiap bulan ditampilkan berdampingan dengan revenue bulan sebelumnya untuk menghitung pertumbuhan month-over-month. Ekspresi mana yang mengembalikan revenue bulan sebelumnya?

A. LAG(revenue) OVER (ORDER BY month)

B. LEAD(revenue) OVER (ORDER BY month)

C. FIRST_VALUE(revenue) OVER (PARTITION BY month)

D. SUM(revenue) OVER (ORDER BY month)

✔ Jawaban benar: A

Kenapa benar: LAG() adalah window function yang mengambil nilai dari baris sebelumnya sesuai urutan ORDER BY. Pertumbuhannya bisa dihitung dengan SAFE_DIVIDE(revenue - LAG(revenue) OVER (ORDER BY month), LAG(revenue) OVER (ORDER BY month)).

B salah: LEAD() mengambil nilai baris berikutnya (bulan setelahnya), bukan bulan sebelumnya.

C salah: PARTITION BY month membuat satu partisi per bulan, sehingga FIRST_VALUE hanya mengembalikan nilai bulan itu sendiri.

D salah: SUM() OVER (ORDER BY ...) menghasilkan running total (kumulatif), bukan nilai bulan sebelumnya.

Soal 20

Section 2 · Data Analysis & Presentation

ENGLISH

In BigQuery, the orders table has a column items of type ARRAY<STRUCT<sku STRING, qty INT64>>. You need the total quantity sold per SKU. Which query is correct?

A. `SELECT JSON_EXTRACT(items, '$.sku'), COUNT(*) FROM orders GROUP BY 1`

B. `SELECT sku, SUM(qty) FROM orders.items GROUP BY sku`

C. `SELECT i.sku, SUM(i.qty) AS total_qty FROM orders, UNNEST(items) AS i GROUP BY i.sku`

D. `SELECT items.sku, SUM(items.qty) FROM orders GROUP BY items.sku`

BAHASA INDONESIA

Di BigQuery, tabel orders punya kolom items bertipe ARRAY<STRUCT<sku STRING, qty INT64>>. Anda butuh total kuantitas terjual per SKU. Query mana yang benar?

A. `SELECT JSON_EXTRACT(items, '$.sku'), COUNT(*) FROM orders GROUP BY 1`

B. `SELECT sku, SUM(qty) FROM orders.items GROUP BY sku`

C. `SELECT i.sku, SUM(i.qty) AS total_qty FROM orders, UNNEST(items) AS i GROUP BY i.sku`

D. `SELECT items.sku, SUM(items.qty) FROM orders GROUP BY items.sku`

✔ **Jawaban benar: C**

Kenapa benar: Kolom repeated (ARRAY) harus diratakan dengan UNNEST. Tanda koma sebelum UNNEST adalah CROSS JOIN implisit (correlated join), sehingga setiap elemen array menjadi satu baris. Setelah itu sku dan qty bisa di-GROUP BY dan dijumlahkan.

A salah: items bukan kolom JSON, dan COUNT(*) menghitung jumlah order, bukan menjumlahkan qty.

B salah: orders.items bukan tabel. Array harus di-UNNEST, tidak bisa dipakai di FROM seperti itu.

D salah: Field di dalam ARRAY tidak bisa diakses langsung dengan items.sku. BigQuery akan memberi error karena items adalah array.

Soal 21

Section 2 · Data Analysis & Presentation

ENGLISH

A dashboard runs the same aggregation (daily revenue per region) every few minutes against a 20 TB BigQuery table that receives new rows continuously. Query costs and latency are too high. The results must stay fresh, and you want BigQuery to maintain them automatically. What should you create?

A. A materialized view with the aggregation query

B. An authorized view in another dataset

C. A logical (standard) view with the aggregation query

D. A table snapshot of the base table every hour

BAHASA INDONESIA

Sebuah dashboard menjalankan agregasi yang sama (revenue harian per region) setiap beberapa menit pada tabel BigQuery 20 TB yang terus menerima baris baru. Biaya dan latensi query terlalu tinggi. Hasil harus tetap segar dan Anda ingin BigQuery memeliharanya secara otomatis. Apa yang sebaiknya dibuat?

A. Materialized view berisi query agregasi

B. Authorized view di dataset lain

C. Logical view (view standar) berisi query agregasi

D. Table snapshot dari tabel dasar setiap jam

✔ **Jawaban benar: A**

Kenapa benar: Materialized view menyimpan hasil query yang sudah dihitung (precomputed) dan di-refresh otomatis secara incremental. Saat dibaca, BigQuery menggabungkan hasil tersimpan dengan perubahan terbaru, jadi data tetap segar. Byte yang di-scan dan latensinya jauh lebih kecil. BigQuery juga bisa memakai materialized view secara otomatis untuk query ke tabel dasar (smart tuning).

B salah: Authorized view digunakan untuk berbagi data tanpa memberi akses ke tabel sumber. Ia tidak mempercepat query karena tetap logical view.

C salah: Logical view tidak menyimpan hasil, hanya query yang disimpan. Setiap akses tetap men-scan tabel 20 TB.

D salah: Snapshot adalah salinan read-only di satu titik waktu, tidak berisi agregasi, dan tidak segar.

Soal 22

Section 2 · Data Analysis & Presentation

ENGLISH

A data analyst wants to explore BigQuery data with Python (pandas, matplotlib) in a managed notebook, without provisioning or maintaining any VMs. The notebook should be integrated with BigQuery Studio and shareable with teammates, with access controlled by IAM. What should the analyst use?

A. A Dataproc cluster with the Jupyter component

B. Looker Studio calculated fields

C. Jupyter installed on a Compute Engine VM

D. Colab Enterprise notebooks in BigQuery Studio

BAHASA INDONESIA

Seorang analis data ingin mengeksplorasi data BigQuery dengan Python (pandas, matplotlib) di notebook managed, tanpa menyiapkan atau memelihara VM. Notebook harus terintegrasi dengan BigQuery Studio dan bisa dibagikan ke rekan tim dengan akses yang diatur lewat IAM. Apa yang sebaiknya digunakan?

A. Cluster Dataproc dengan komponen Jupyter

B. Calculated field di Looker Studio

C. Jupyter yang di-install di VM Compute Engine

D. Notebook Colab Enterprise di BigQuery Studio

✔ Jawaban benar: D

Kenapa benar: Colab Enterprise adalah notebook Jupyter managed yang terintegrasi di BigQuery Studio. Runtime-nya dikelola Google, akses dan berbagi diatur lewat IAM, dan analis bisa langsung memakai SQL, BigQuery DataFrames, atau pandas. Exam guide menyebut Colab Enterprise secara eksplisit untuk analisis dan visualisasi dengan notebook.

A salah: Cluster Dataproc juga harus dikelola dan lebih cocok untuk workload Spark, bukan sekadar eksplorasi dengan pandas.

B salah: Looker Studio adalah tool dashboard, bukan lingkungan Python.

C salah: Anda harus mengelola VM sendiri (patching, ukuran mesin), jadi bertentangan dengan syarat tanpa VM.

Soal 23

Section 2 · Data Analysis & Presentation

ENGLISH

A large enterprise wants one governed definition of business metrics (for example, "active customer" and "net revenue") that all teams reuse. The definitions should be version-controlled in Git, and dashboards should also be embedded in a customer portal. Which tool fits best?

A. Looker
B. Looker Studio
C. Colab Enterprise
D. Google Sheets connected sheets

BAHASA INDONESIA

Sebuah enterprise besar menginginkan satu definisi metrik bisnis yang terkelola (governed), misalnya "pelanggan aktif" dan "net revenue", yang dipakai ulang oleh semua tim. Definisinya harus di-version-control dengan Git, dan dashboard juga harus di-embed di portal pelanggan. Tool mana yang paling cocok?

A. Looker
B. Looker Studio
C. Colab Enterprise
D. Google Sheets connected sheets

✔ Jawaban benar: A

Kenapa benar: Looker punya semantic layer berbasis LookML. Metrik didefinisikan sekali secara terpusat, disimpan di repository Git, lalu dipakai konsisten oleh semua pengguna. Looker juga mendukung embedded analytics dan fitur enterprise seperti permission granular dan scheduling.

B salah: Looker Studio cocok untuk dashboard self-service yang cepat dan gratis, tetapi tidak punya semantic modeling LookML yang di-version-control dengan Git untuk governance metrik di skala enterprise.

C salah: Colab Enterprise adalah notebook untuk analisis, bukan platform BI dengan metrik terkelola.

D salah: Connected Sheets memudahkan analisis BigQuery di spreadsheet, tetapi tidak menyediakan semantic layer terkelola dan embedding.

Soal 24

Section 2 · Data Analysis & Presentation

ENGLISH

A five-person marketing team with no BI budget needs an interactive dashboard that combines a BigQuery table with a Google Sheets file of campaign targets. They want to share it with management through a link within a day. What should they use?

A. Looker Studio, with BigQuery and Google Sheets data sources
B. Looker, with a new LookML project
C. A Dataflow job that writes charts to Cloud Storage
D. Vertex AI Workbench

BAHASA INDONESIA

Tim marketing beranggotakan lima orang tanpa anggaran BI butuh dashboard interaktif yang menggabungkan tabel BigQuery dengan file Google Sheets berisi target kampanye. Mereka ingin membagikannya ke manajemen lewat link dalam satu hari. Apa yang sebaiknya digunakan?

A. Looker Studio dengan data source BigQuery dan Google Sheets
B. Looker dengan proyek LookML baru
C. Job Dataflow yang menulis chart ke Cloud Storage
D. Vertex AI Workbench

✔ Jawaban benar: A

Kenapa benar: Looker Studio gratis, berbasis web, punya connector bawaan untuk BigQuery dan Google Sheets, mendukung data blending, dan laporan bisa dibagikan seperti Google Docs (via link atau email). Ini pilihan tepat untuk kebutuhan cepat dan sederhana.

B salah: Looker adalah platform enterprise berlisensi yang butuh pemodelan LookML. Berlebihan untuk tim kecil tanpa budget yang butuh hasil dalam sehari.

C salah: Dataflow adalah engine pemrosesan data, bukan tool visualisasi.

D salah: Workbench adalah notebook untuk data science, bukan dashboard interaktif yang mudah dibagikan ke manajemen.

Soal 25

Section 2 · Data Analysis & Presentation

ENGLISH

In a Looker view file, the dimension customer_email is used inside another dimension's SQL definition. Business users should not see customer_email in the Explore field picker, but the dimension must keep working for the other definition. Which LookML change should you make?

A. Add label: "" to the customer_email dimension.
B. Delete the customer_email dimension.
C. Add hidden: yes to the customer_email dimension.
D. Change the dimension to type: number.

BAHASA INDONESIA

Di file view Looker, dimension customer_email dipakai di dalam definisi SQL dimension lain. Pengguna bisnis tidak boleh melihat customer_email di field picker Explore, tetapi dimension itu harus tetap berfungsi untuk definisi lain tersebut. Perubahan LookML apa yang harus dilakukan?

A. Tambahkan label: "" pada dimension customer_email.
B. Hapus dimension customer_email.
C. Tambahkan hidden: yes pada dimension customer_email.
D. Ubah dimension menjadi type: number.

✔ **Jawaban benar: C**

Kenapa benar: Parameter hidden: yes menyembunyikan field dari field picker di Explore, tetapi field tetap ada dan bisa direferensikan oleh field lain (misalnya `${customer_email}`). Catatan: hidden bukan kontrol keamanan. Untuk membatasi akses data, gunakan access_filter, access_grant, atau keamanan di database.

A salah: Label hanya mengubah nama tampilan. Label kosong tidak menyembunyikan field dan justru membingungkan.

B salah: Jika dihapus, field lain yang mereferensikannya akan error.

D salah: Mengubah tipe ke number salah secara data (email adalah string) dan tidak menyembunyikan field.

Soal 26

Section 2 · Data Analysis & Presentation

ENGLISH

You need a LookML measure that shows total revenue by adding up the revenue column of the orders table. Which definition is correct?

A. `measure: total_revenue { type: count sql: ${TABLE}.revenue ;; }`

B. `measure: total_revenue { type: string sql: SUM(revenue) ;; }`

C. `measure: total_revenue { type: sum sql: ${TABLE}.revenue ;; }`

D. `dimension: total_revenue { type: sum sql: ${TABLE}.revenue ;; }`

BAHASA INDONESIA

Anda butuh measure LookML yang menampilkan total revenue dengan menjumlahkan kolom revenue di tabel orders. Definisi mana yang benar?

A. `measure: total_revenue { type: count sql: ${TABLE}.revenue ;; }`

B. `measure: total_revenue { type: string sql: SUM(revenue) ;; }`

C. `measure: total_revenue { type: sum sql: ${TABLE}.revenue ;; }`

D. `dimension: total_revenue { type: sum sql: ${TABLE}.revenue ;; }`

✔ **Jawaban benar: C**

Kenapa benar: Measure dengan type: sum menjumlahkan ekspresi di parameter sql. `${TABLE}.revenue` merujuk ke kolom revenue di tabel yang mendasari view tersebut. Measure adalah agregasi, sedangkan dimension adalah atribut per baris.

A salah: type: count menghitung jumlah baris (primary key) dan tidak memakai parameter sql untuk menjumlahkan nilai.

B salah: type: string untuk measure tidak dipakai untuk penjumlahan. Kalau Anda ingin menulis agregasi sendiri di SQL, tipe yang benar adalah type: number.

D salah: Agregasi seperti sum harus didefinisikan sebagai measure. Dimension tidak memiliki type: sum.

Soal 27

Section 2 · Data Analysis & Presentation

ENGLISH

In a Looker Explore, the orders view is joined to order_items, and one order has many items. The measure orders.total_shipping_cost now shows values that are too high, because shipping cost is counted once per item instead of once per order. What should you fix in LookML?

A. Change the measure type from sum to average.

B. Add a sql_always_where filter that shows only the first item of each order.

C. Remove the join and create a separate dashboard for items.

D. Set relationship: one_to_many on the order_items join and make sure the orders view defines a primary_key: yes dimension, so Looker can apply symmetric aggregates.

BAHASA INDONESIA

Di sebuah Explore Looker, view orders di-join dengan order_items, dan satu order memiliki banyak item. Measure orders.total_shipping_cost kini menampilkan angka yang terlalu besar karena biaya kirim terhitung per item, bukan per order. Apa yang harus diperbaiki di LookML?

A. Ubah tipe measure dari sum menjadi average.

B. Tambahkan filter sql_always_where yang hanya menampilkan item pertama dari setiap order.

C. Hapus join dan buat dashboard terpisah untuk item.

D. Set relationship: one_to_many pada join order_items dan pastikan view orders mendefinisikan dimension dengan primary_key: yes, agar Looker bisa menerapkan symmetric aggregates.

✔ Jawaban benar: D

Kenapa benar: Masalah ini disebut fanout. Join one-to-many menggandakan baris order. Jika parameter relationship di join benar dan view memiliki primary_key, Looker otomatis memakai symmetric aggregates sehingga SUM tetap dihitung sekali per order.

A salah: Average tidak sama dengan total, dan perhitungannya tetap terdistorsi oleh duplikasi.

B salah: Filter seperti ini membuang data item yang sah dan merusak analisis lainnya.

C salah: Ini menghindari masalah, bukan memperbaikinya, dan menghilangkan kemampuan analisis gabungan.

Soal 28

Section 2 · Data Analysis & Presentation

ENGLISH

A retail chain wants to forecast daily unit sales for each of its 300 stores for the next 30 days, using two years of history stored in BigQuery. Analysts only know SQL. Which approach is correct?

A. `CREATE MODEL with model_type='LOGISTIC_REG', then call ML.EVALUATE.`

B. `CREATE MODEL with model_type='ARIMA_PLUS', time_series_timestamp_col='sale_date', time_series_data_col='units', time_series_id_col='store_id', then call ML.FORECAST with STRUCT(30 AS horizon).`

C. `CREATE MODEL with model_type='LINEAR_REG', then call ML.PREDICT with 30 future rows.`

D. `CREATE MODEL with model_type='KMEANS' and num_clusters=30.`

BAHASA INDONESIA

Sebuah jaringan ritel ingin memprediksi penjualan unit harian untuk masing-masing dari 300 tokonya selama 30 hari ke depan, memakai riwayat dua tahun yang tersimpan di BigQuery. Analis hanya menguasai SQL. Pendekatan mana yang benar?

A. `CREATE MODEL dengan model_type='LOGISTIC_REG', lalu panggil ML.EVALUATE.`

B. `CREATE MODEL dengan model_type='ARIMA_PLUS', time_series_timestamp_col='sale_date', time_series_data_col='units', time_series_id_col='store_id', lalu panggil ML.FORECAST dengan STRUCT(30 AS horizon).`

C. `CREATE MODEL dengan model_type='LINEAR_REG', lalu panggil ML.PREDICT dengan 30 baris masa depan.`

D. `CREATE MODEL dengan model_type='KMEANS' dan num_clusters=30.`

✔ Jawaban benar: B

Kenapa benar: ARIMA_PLUS adalah model time-series di BigQuery ML. time_series_id_col membuat satu model per toko sekaligus dalam satu statement, dan ML.FORECAST dengan horizon 30 menghasilkan forecast 30 periode ke depan beserta interval prediksinya.

A salah: Logistic regression untuk klasifikasi (misalnya ya/tidak), bukan memprediksi angka penjualan di masa depan.

C salah: Linear regression tidak menangani tren dan musiman time series secara otomatis, dan Anda harus membuat sendiri fitur untuk tanggal-tanggal masa depan.

D salah: K-means adalah clustering (unsupervised) untuk segmentasi, bukan forecasting.

Soal 29

Section 2 · Data Analysis & Presentation

ENGLISH

The marketing team wants to group customers into segments based on purchase frequency, average basket size, and tenure. There is no existing label that says which segment a customer belongs to. Which BigQuery ML model type should you use?

A. LOGISTIC_REG

B. KMEANS

C. ARIMA_PLUS

D. BOOSTED_TREE_REGRESSOR

BAHASA INDONESIA

Tim marketing ingin mengelompokkan pelanggan ke beberapa segmen berdasarkan frekuensi pembelian, rata-rata nilai keranjang, dan lama menjadi pelanggan. Tidak ada label yang menunjukkan segmen setiap pelanggan. Tipe model BigQuery ML apa yang sebaiknya digunakan?

A. LOGISTIC_REG

B. KMEANS

C. ARIMA_PLUS

D. BOOSTED_TREE_REGRESSOR

✔ **Jawaban benar: B**

Kenapa benar: Tanpa label berarti kasusnya unsupervised learning. K-means clustering mengelompokkan data yang mirip ke dalam k cluster. Di BigQuery ML, gunakan model_type='KMEANS' (opsional num_clusters), lalu ML.PREDICT untuk menentukan cluster tiap pelanggan.

A salah: Logistic regression adalah model supervised yang butuh kolom label.

C salah: ARIMA_PLUS untuk forecasting time series, bukan segmentasi.

D salah: Boosted tree regressor juga supervised dan memprediksi nilai numerik berdasarkan label.

Soal 30 CHOOSE TWO

Section 2 · Data Analysis & Presentation

ENGLISH

You trained a BigQuery ML classification model named mydataset.churn_model. You now need to (1) review precision, recall, and ROC AUC on held-out data, and (2) score a table of new customers. Which TWO functions should you use? (Choose two.)

A. `SELECT * FROM mydataset.churn_model, to return predictions`

B. ML.FORECAST

C. ML.PREDICT

D. ML.EVALUATE

E. ML.TRAINING_INFO, to score new customers

BAHASA INDONESIA

Anda sudah melatih model klasifikasi BigQuery ML bernama mydataset.churn_model. Sekarang Anda perlu (1) melihat precision, recall, dan ROC AUC pada data uji, dan (2) memberi skor pada tabel pelanggan baru. DUA fungsi mana yang digunakan? (Pilih dua.)

A. `SELECT * FROM mydataset.churn_model untuk mengembalikan prediksi`

B. ML.FORECAST

C. ML.PREDICT

D. ML.EVALUATE

E. ML.TRAINING_INFO untuk memberi skor pelanggan baru

✔ **Jawaban benar: C, D**

Kenapa benar: ML.EVALUATE mengembalikan metrik evaluasi seperti precision, recall, accuracy, f1_score, log_loss, dan roc_auc untuk model klasifikasi. ML.PREDICT melakukan inference pada data baru, dengan sintaks SELECT * FROM ML.PREDICT(MODEL `mydataset.churn_model`, (SELECT ... FROM new_customers)).

A salah: Model tidak bisa di-query seperti tabel untuk menghasilkan prediksi. Prediksi harus lewat ML.PREDICT.

B salah: ML.FORECAST hanya untuk model time-series seperti ARIMA_PLUS, bukan model klasifikasi.

E salah: ML.TRAINING_INFO menampilkan riwayat iterasi training (loss, durasi), bukan prediksi.

Soal 31

Section 2 · Data Analysis & Presentation

ENGLISH

A support team stores 2 million customer reviews in a BigQuery table. They want to generate a one-sentence summary and a sentiment label for each review with a Google Gemini model, using only SQL and without exporting the data. What should you do?

A. Create a Cloud resource connection, grant its service account access to Vertex AI, create a remote model with CREATE MODEL ... REMOTE WITH CONNECTION ... OPTIONS(ENDPOINT = '<Gemini model>'), and then call the BigQuery generate-text function on the reviews table.

B. Use Looker Studio's built-in sentiment analysis chart.

C. Export the table to Cloud Storage and call the Gemini API from a Python script on a VM.

D. Train a LOGISTIC_REG model in BigQuery ML on the review text to produce summaries.

BAHASA INDONESIA

Tim support menyimpan 2 juta ulasan pelanggan di tabel BigQuery. Mereka ingin membuat ringkasan satu kalimat dan label sentimen untuk setiap ulasan dengan model Google Gemini, hanya memakai SQL dan tanpa mengekspor data. Apa yang harus dilakukan?

A. Buat Cloud resource connection, beri service account-nya akses ke Vertex AI, buat remote model dengan CREATE MODEL ... REMOTE WITH CONNECTION ... OPTIONS(ENDPOINT = '<model Gemini>'), lalu panggil fungsi generate-text BigQuery pada tabel ulasan.

B. Gunakan chart analisis sentimen bawaan Looker Studio.

C. Ekspor tabel ke Cloud Storage lalu panggil Gemini API dari skrip Python di VM.

D. Latih model LOGISTIC_REG di BigQuery ML pada teks ulasan untuk menghasilkan ringkasan.

✔ Jawaban benar: A

Kenapa benar: Exam guide menyebut pemakaian LLM pretrained Google lewat remote connection di BigQuery. Langkahnya: (1) buat Cloud resource connection, (2) beri service account connection role Vertex AI User, (3) CREATE MODEL ... REMOTE WITH CONNECTION dengan ENDPOINT model Gemini, (4) panggil fungsi generate-text (AI.GENERATE_TEXT; versi lamanya ML.GENERATE_TEXT) dengan prompt berisi kolom ulasan. Semua dilakukan dengan SQL dan data tidak keluar dari BigQuery.

B salah: Looker Studio tidak punya fitur generatif bawaan untuk meringkas setiap baris data. Ia adalah tool visualisasi.

C salah: Data diekspor dan ada infrastruktur yang harus dikelola, jadi melanggar syarat hanya SQL dan tanpa ekspor.

D salah: Logistic regression adalah klasifikasi yang butuh label dan tidak bisa menghasilkan teks ringkasan.

Soal 32

Section 2 · Data Analysis & Presentation

ENGLISH

A manufacturer has 50,000 labeled photos of products from the assembly line, tagged "defect" or "ok". The team has no ML engineers and wants to build an image classification model with minimal code. What should they use?

A. BigQuery ML LINEAR_REG

B. Looker with a custom LookML dimension

C. BigQuery ML KMEANS

D. Vertex AI AutoML image classification

BAHASA INDONESIA

Sebuah pabrik punya 50.000 foto produk dari lini perakitan yang sudah dilabeli "cacat" atau "ok". Tim tidak punya ML engineer dan ingin membangun model klasifikasi gambar dengan kode seminimal mungkin. Apa yang sebaiknya digunakan?

A. BigQuery ML LINEAR_REG

B. Looker dengan dimension LookML custom

C. BigQuery ML KMEANS

D. Vertex AI AutoML image classification

✔ Jawaban benar: D

Kenapa benar: AutoML di Vertex AI melatih model berkualitas tinggi untuk data gambar, teks, atau tabular hanya dari data berlabel, tanpa perlu menulis kode model. Kasus klasifikasi gambar berlabel dengan tim tanpa keahlian ML adalah use case klasik AutoML.

A salah: BigQuery ML terutama dipakai untuk data tabular dengan SQL. Linear regression memprediksi angka, bukan mengklasifikasikan gambar.

B salah: Looker adalah tool BI, bukan platform untuk melatih model ML.

C salah: K-means adalah clustering tanpa label, padahal data sudah berlabel dan tujuannya klasifikasi.

Soal 33

Section 2 · Data Analysis & Presentation

ENGLISH

A team is planning its first ML project to predict late deliveries. Which sequence of activities reflects a standard ML workflow?

A. Evaluate the model, collect data, train it, then skip deployment.

B. Deploy the model, evaluate it on production data, then collect training data.

C. Collect and prepare data (including a train/test split), train the model, evaluate it on held-out data, then deploy it and run predictions while monitoring performance.

D. Train the model, deploy it, collect data, then evaluate it.

BAHASA INDONESIA

Sebuah tim merencanakan proyek ML pertama untuk memprediksi keterlambatan pengiriman. Urutan aktivitas mana yang mencerminkan workflow ML standar?

A. Evaluasi model, kumpulkan data, latih, lalu lewati deployment.

B. Deploy model, evaluasi pada data produksi, lalu kumpulkan data training.

C. Kumpulkan dan siapkan data (termasuk split train/test), latih model, evaluasi pada data uji yang dipisahkan, lalu deploy dan jalankan prediksi sambil memantau performa.

D. Latih model, deploy, kumpulkan data, lalu evaluasi.

✔ Jawaban benar: C

Kenapa benar: Workflow ML standar (sesuai exam guide: data collection, model training, model evaluation, prediction) adalah: kumpulkan dan siapkan data, bagi data menjadi train dan test/validation, latih model, evaluasi pada data yang tidak dipakai saat training, lalu deploy dan prediksi. Setelah itu performa dipantau untuk mendeteksi drift dan dilakukan retraining jika perlu.

A salah: Evaluasi tidak bisa dilakukan sebelum ada model, dan tanpa deployment model tidak menghasilkan nilai bisnis.

B salah: Melakukan deploy sebelum training dan evaluasi berisiko dan tidak logis.

D salah: Model tidak bisa dilatih sebelum ada data.

Soal 34

Section 2 · Data Analysis & Presentation

ENGLISH

Your team trains several versions of a BigQuery ML model and wants to manage the versions centrally, assign aliases such as "production", and deploy a chosen version to an endpoint for online predictions. What should you do?

A. Store each model's SQL in a Cloud Storage bucket.

B. Export the models to Looker as LookML views.

C. Register the models in Vertex AI Model Registry, for example by adding the MODEL_REGISTRY = 'VERTEX_AI' option to the CREATE MODEL statement.

D. Copy the models to a new BigQuery dataset for each version.

BAHASA INDONESIA

Tim Anda melatih beberapa versi model BigQuery ML dan ingin mengelola versinya secara terpusat, memberi alias seperti "production", dan men-deploy versi tertentu ke endpoint untuk prediksi online. Apa yang harus dilakukan?

A. Simpan SQL setiap model di bucket Cloud Storage.

B. Ekspor model ke Looker sebagai view LookML.

C. Daftarkan model ke Vertex AI Model Registry, misalnya dengan menambahkan opsi MODEL_REGISTRY = 'VERTEX_AI' pada statement CREATE MODEL.

D. Salin model ke dataset BigQuery baru untuk setiap versi.

✔ **Jawaban benar: C**

Kenapa benar: Vertex AI Model Registry adalah tempat terpusat untuk mengelola model dan versinya, termasuk alias, evaluasi, dan deploy ke endpoint. Model BigQuery ML bisa didaftarkan langsung lewat opsi MODEL_REGISTRY di CREATE MODEL (opsional dengan VERTEX_AI_MODEL_ID dan VERTEX_AI_MODEL_VERSION_ALIASES), atau dari console. Catatan: produk Vertex AI sedang di-rebrand di dokumentasi Google, tetapi exam guide v1.0 masih memakai nama Vertex AI dan Model Registry.

A salah: Menyimpan SQL bukan manajemen model, karena tidak ada versioning, alias, maupun deployment.

B salah: Looker adalah tool BI, bukan registry model.

D salah: Menyalin model ke banyak dataset membuat pengelolaan berantakan dan tidak menyediakan deployment ke endpoint.

Soal 35

Section 3 · Data Pipeline Orchestration

ENGLISH

Raw data already lands in BigQuery every hour. Your SQL-skilled analytics team wants to build a chain of transformation steps (staging → intermediate → reporting tables) inside BigQuery. They need dependency management, data quality assertions, Git version control, and scheduled runs, and they do not want to manage infrastructure. Which tool should you choose?

A. Dataform
B. Cloud Data Fusion with a Spark engine
C. Bigtable
D. Dataproc

BAHASA INDONESIA

Data mentah sudah masuk ke BigQuery setiap jam. Tim analitik yang mahir SQL ingin membangun rangkaian langkah transformasi (staging → intermediate → tabel reporting) di dalam BigQuery. Mereka butuh pengelolaan dependensi, assertion kualitas data, version control Git, dan eksekusi terjadwal, tanpa mengelola infrastruktur. Tool mana yang sebaiknya dipilih?

A. Dataform
B. Cloud Data Fusion dengan engine Spark
C. Bigtable
D. Dataproc

✔ **Jawaban benar: A**

Kenapa benar: Dataform adalah layanan serverless untuk transformasi ELT di BigQuery memakai SQLX. Dataform otomatis membangun graf dependensi dari ref(), mendukung assertion (uji kualitas data), terintegrasi dengan Git, dan menyediakan workflow configuration untuk eksekusi terjadwal.

B salah: Data Fusion adalah tool ETL visual yang memproses data di luar BigQuery. Untuk ELT berbasis SQL di BigQuery, Dataform lebih alami.

C salah: Bigtable adalah database NoSQL, bukan tool transformasi.

D salah: Dataproc menjalankan Spark atau Hadoop di cluster. Kurang cocok untuk tim SQL yang ingin bertransformasi di dalam BigQuery tanpa infrastruktur.

Soal 36

Section 3 · Data Pipeline Orchestration

ENGLISH

Every night you run three dependent Spark jobs: job B needs the output of job A, and job C needs the output of job B. To save money, you want a Dataproc cluster to be created just for this run and deleted automatically when the jobs finish, with the job order defined in one reusable resource. What should you use?

A. A long-running Dataproc cluster with a crontab on the master node

B. BigQuery scheduled queries

C. A Dataproc Workflow Template with a managed (ephemeral) cluster

D. A Pub/Sub BigQuery subscription

BAHASA INDONESIA

Setiap malam Anda menjalankan tiga job Spark yang saling bergantung: job B butuh output job A, dan job C butuh output job B. Untuk menghemat biaya, Anda ingin cluster Dataproc dibuat khusus untuk run ini dan dihapus otomatis setelah job selesai, dengan urutan job didefinisikan dalam satu resource yang bisa dipakai ulang. Apa yang sebaiknya digunakan?

A. Cluster Dataproc yang selalu menyala dengan crontab di master node

B. BigQuery scheduled query

C. Dataproc Workflow Template dengan managed (ephemeral) cluster

D. Pub/Sub BigQuery subscription

✔ Jawaban benar: C

Kenapa benar: Dataproc Workflow Template mendefinisikan graf job beserta dependensinya. Dengan opsi managed cluster, Dataproc membuat cluster, menjalankan job sesuai urutan, lalu menghapus cluster secara otomatis. Template bisa dijalankan ulang, misalnya dipicu oleh Cloud Scheduler atau Composer.

A salah: Cluster yang selalu menyala boros biaya, dan crontab tidak punya penanganan dependensi atau retry yang baik.

B salah: Scheduled query hanya menjalankan SQL di BigQuery, bukan job Spark.

D salah: Pub/Sub BigQuery subscription untuk ingest pesan, bukan orkestrasi job Spark.

Soal 37

Section 3 · Data Pipeline Orchestration

ENGLISH

After a file is processed, you must call three services in order: a Cloud Run service that validates data, the BigQuery API to run a load job, and a third-party REST API to send a notification. The process

needs retries and simple conditional branching. You want a serverless, low-cost solution with no always-on environment and no Python DAG code. What should you use?

A. A Compute Engine VM running a cron script
B. Workflows
C. Dataproc Workflow Templates
D. Cloud Composer

BAHASA INDONESIA

Setelah sebuah file diproses, Anda harus memanggil tiga layanan secara berurutan: service Cloud Run untuk validasi data, BigQuery API untuk menjalankan load job, dan REST API pihak ketiga untuk mengirim notifikasi. Proses ini butuh retry dan percabangan kondisional sederhana. Anda ingin solusi serverless berbiaya rendah, tanpa environment yang selalu menyala dan tanpa kode DAG Python. Apa yang sebaiknya digunakan?

A. VM Compute Engine yang menjalankan skrip cron
B. Workflows
C. Dataproc Workflow Templates
D. Cloud Composer

✔ Jawaban benar: B

Kenapa benar: Workflows adalah orkestrator serverless yang didefinisikan dalam YAML atau JSON untuk merangkai panggilan HTTP/API, termasuk Google Cloud APIs, Cloud Run, dan API eksternal. Workflows mendukung retry, kondisi, dan variabel, dan biayanya dihitung per langkah yang dieksekusi tanpa environment yang selalu menyala. Ringkasnya: Composer (Airflow) untuk pipeline data kompleks berbasis DAG Python, sedangkan Workflows untuk merangkai beberapa service atau API secara ringan.

A salah: VM harus dikelola dan selalu menyala, sehingga tidak serverless.

C salah: Workflow Template khusus untuk job Dataproc (Spark/Hadoop), bukan untuk memanggil Cloud Run atau API eksternal.

D salah: Composer adalah Airflow managed dengan environment yang terus berjalan (dan biayanya ikut berjalan) serta DAG berbasis Python. Berlebihan untuk tiga panggilan API.

Soal 38

Section 3 · Data Pipeline Orchestration

ENGLISH

A data engineering team must orchestrate a nightly pipeline of 40 tasks across BigQuery, Dataproc, Cloud Storage, and an on-premises SFTP server. They need complex dependencies, retries, backfills of past dates, and many prebuilt operators, and the team already writes Apache Airflow DAGs in Python. What should you choose?

A. Cloud Scheduler only
B. Cloud Composer
C. BigQuery scheduled queries
D. Workflows

BAHASA INDONESIA

Tim data engineering harus mengorkestrasi pipeline malam berisi 40 task yang melibatkan BigQuery, Dataproc, Cloud Storage, dan server SFTP on-premises. Mereka butuh dependensi kompleks, retry, backfill untuk tanggal-tanggal lampau, dan banyak operator siap pakai, dan tim sudah terbiasa menulis DAG Apache Airflow dengan Python. Apa yang sebaiknya dipilih?

A. Cloud Scheduler saja
B. Cloud Composer
C. BigQuery scheduled query
D. Workflows

✔ Jawaban benar: B

Kenapa benar: Cloud Composer adalah Apache Airflow yang dikelola Google. Pipeline didefinisikan sebagai DAG Python dan bisa memakai banyak operator (BigQuery, Dataproc, GCS, SFTP, dan lainnya). Composer mendukung retry, backfill/catchup, sensor, dan monitoring di UI Airflow, sehingga cocok untuk pipeline data besar yang kompleks dan tim yang sudah memakai Airflow.

A salah: Cloud Scheduler hanya memicu job sesuai jadwal (seperti cron) dan tidak mengelola dependensi antar-task.

C salah: Scheduled query hanya menjalankan SQL BigQuery, tidak bisa mengorkestrasi Dataproc atau SFTP.

D salah: Workflows bagus untuk orkestrasi ringan berbasis API, tetapi tidak punya fitur backfill dan ekosistem operator Airflow.

Soal 39

Section 3 · Data Pipeline Orchestration

ENGLISH

Every day at 02:00, you need to run one SQL statement that aggregates yesterday's sales into a summary table in BigQuery. Nothing else is involved. What is the simplest solution with the least operational overhead?

A. Create a BigQuery scheduled query.
B. Build a Dataflow pipeline that runs daily.
C. Run a cron job on a Compute Engine VM that calls the bq CLI.
D. Create a Cloud Composer environment with a DAG.

BAHASA INDONESIA

Setiap hari pukul 02.00, Anda perlu menjalankan satu statement SQL yang mengagregasi penjualan kemarin ke tabel ringkasan di BigQuery. Tidak ada proses lain yang terlibat. Apa solusi paling sederhana dengan overhead operasional terkecil?

A. Buat BigQuery scheduled query.
B. Bangun pipeline Dataflow yang berjalan setiap hari.
C. Jalankan cron job di VM Compute Engine yang memanggil bq CLI.
D. Buat environment Cloud Composer dengan DAG.

✔ **Jawaban benar: A**

Kenapa benar: Scheduled query adalah fitur bawaan BigQuery (berjalan di atas BigQuery Data Transfer Service) untuk menjalankan SQL secara berkala. Fitur ini mendukung parameter @run_date atau @run_time, tujuan tabel, dan notifikasi, tanpa infrastruktur tambahan.

B salah: Dataflow tidak perlu untuk transformasi SQL sederhana di dalam BigQuery.

C salah: VM harus dikelola dan dimonitor sendiri.

D salah: Composer terlalu berat dan mahal untuk satu query.

Soal 40

Section 3 · Data Pipeline Orchestration

ENGLISH

IoT devices publish JSON messages to a Pub/Sub topic. The message fields already match the columns of a BigQuery table, and no transformation is needed. You want the messages written to BigQuery with the least latency, cost, and operational effort. What should you do?

A. Write a Cloud Run service that receives push messages and calls the BigQuery streaming API.

B. Create a Dataflow streaming job from a custom Apache Beam pipeline.

C. Create a Cloud Storage subscription and load the files into BigQuery every hour.

D. Create a BigQuery subscription on the topic that writes directly to the table, using the table schema.

BAHASA INDONESIA

Perangkat IoT mempublikasikan pesan JSON ke topic Pub/Sub. Field pesan sudah sesuai dengan kolom tabel BigQuery dan tidak perlu transformasi. Anda ingin pesan ditulis ke BigQuery dengan latensi, biaya, dan usaha operasional sekecil mungkin. Apa yang harus dilakukan?

A. Tulis service Cloud Run yang menerima push message lalu memanggil API streaming BigQuery.

B. Buat job streaming Dataflow dari pipeline Apache Beam custom.

C. Buat Cloud Storage subscription lalu load file ke BigQuery setiap jam.

D. Buat BigQuery subscription pada topic yang menulis langsung ke tabel, memakai skema tabel.

✔ **Jawaban benar: D**

Kenapa benar: BigQuery subscription di Pub/Sub menulis pesan langsung ke tabel BigQuery tanpa perantara, tanpa kode, dan tanpa layanan tambahan. Ini pilihan paling sederhana untuk ingestion event-driven ketika transformasi tidak diperlukan.

A salah: Anda harus menulis dan memelihara kode sendiri.

B salah: Dataflow tepat jika butuh transformasi atau windowing. Tanpa transformasi, Dataflow menambah biaya dan kompleksitas.

C salah: Load per jam menambah latensi dan langkah ekstra.

Soal 41

Section 3 · Data Pipeline Orchestration

ENGLISH

Partners upload CSV files to a Cloud Storage bucket at unpredictable times. Each new file must immediately start a containerized processing service on Cloud Run. You want an event-driven design with no polling. What should you configure?

A. An Eventarc trigger for the Cloud Storage object finalized event that targets the Cloud Run service

B. A BigQuery scheduled query that lists new objects

C. A Cloud Scheduler job that checks the bucket every minute

D. A Dataproc Workflow Template

BAHASA INDONESIA

Partner meng-upload file CSV ke bucket Cloud Storage pada waktu yang tidak bisa diprediksi. Setiap file baru harus langsung memicu service pemrosesan berbasis container di Cloud Run. Anda ingin desain event-driven tanpa polling. Apa yang harus dikonfigurasi?

A. Trigger Eventarc untuk event Cloud Storage object finalized yang menargetkan service Cloud Run

B. BigQuery scheduled query yang mendaftar objek baru

C. Job Cloud Scheduler yang mengecek bucket setiap menit

D. Dataproc Workflow Template

✔ Jawaban benar: A

Kenapa benar: Eventarc mengirim event dari sumber Google Cloud ke target seperti Cloud Run, Cloud Run functions, Workflows, dan GKE. Event google.cloud.storage.object.v1.finalized terjadi setiap kali objek baru selesai ditulis, sehingga Cloud Run dipicu secara otomatis dan real-time.

B salah: Scheduled query tidak bisa memicu Cloud Run dan bukan desain event-driven.

C salah: Ini polling: ada jeda waktu, biaya terbuang, dan logika "file mana yang baru" harus dibuat sendiri.

D salah: Workflow Template untuk job Spark/Hadoop di Dataproc, bukan pemicu berbasis event.

Soal 42

Section 3 · Data Pipeline Orchestration

ENGLISH

A streaming Dataflow job is falling behind: dashboards show data that is 20 minutes old. You need to find which pipeline step is the bottleneck and see metrics such as data freshness, system latency, and throughput per step. Where should you look first?

A. The Cloud Storage bucket's access logs

B. The Dataflow job monitoring UI (job graph and job metrics)

C. The Looker Studio report settings

D. The BigQuery INFORMATION_SCHEMA.JOBS view

BAHASA INDONESIA

Sebuah job Dataflow streaming tertinggal: dashboard menampilkan data yang sudah 20 menit lalu. Anda perlu mencari langkah pipeline mana yang menjadi bottleneck dan melihat metrik seperti data freshness, system latency, dan throughput per langkah. Di mana Anda sebaiknya melihat terlebih dahulu?

A. Access log bucket Cloud Storage

B. UI monitoring job Dataflow (job graph dan job metrics)

C. Pengaturan laporan Looker Studio

D. View INFORMATION_SCHEMA.JOBS di BigQuery

✔ Jawaban benar: B

Kenapa benar: UI job Dataflow menampilkan job graph per langkah (dengan informasi throughput dan langkah yang lambat atau macet), metrik data freshness dan system latency, autoscaling worker, serta tautan ke log worker. Exam guide menyebut eksplisit: monitor Dataflow pipeline progress using the Dataflow job UI.

A salah: Access log storage tidak menunjukkan performa langkah pipeline.

C salah: Pengaturan laporan Looker Studio hanya terkait cache dan tampilan dashboard, bukan penyebab keterlambatan di pipeline.

D salah: INFORMATION_SCHEMA.JOBS berisi metadata job BigQuery, bukan langkah-langkah pipeline Dataflow.

Soal 43

Section 3 · Data Pipeline Orchestration

ENGLISH

A nightly BigQuery scheduled query occasionally fails, and nobody notices until analysts complain. You want the on-call engineer to receive an email automatically whenever the scheduled query run fails. What should you do?

A. Create a table snapshot every night.

B. Ask analysts to check the dashboard every morning.

C. Increase the BigQuery slot reservation.

D. In Cloud Logging, create a log-based alert (or a log-based metric with a Cloud Monitoring alerting policy) that matches the scheduled query error entries, with an email notification channel. Alternatively, enable the scheduled query's built-in email notification for failures.

BAHASA INDONESIA

Sebuah BigQuery scheduled query yang berjalan setiap malam kadang gagal, dan tidak ada yang sadar sampai analis komplain. Anda ingin engineer on-call otomatis menerima email setiap kali run scheduled query gagal. Apa yang harus dilakukan?

A. Buat table snapshot setiap malam.

B. Minta analis mengecek dashboard setiap pagi.

C. Tambah slot reservation BigQuery.

D. Di Cloud Logging, buat log-based alert (atau log-based metric dengan alerting policy Cloud Monitoring) yang mencocokkan entri error scheduled query, dengan notification channel email. Alternatifnya, aktifkan notifikasi email bawaan scheduled query untuk kegagalan.

✔ Jawaban benar: D

Kenapa benar: Cloud Logging menyimpan log run transfer atau scheduled query. Log-based alert, atau log-based metric yang dipakai di alerting policy Cloud Monitoring, bisa mengirim notifikasi ke email, SMS, Slack, atau PagerDuty saat error muncul. Scheduled query juga punya opsi notifikasi email bawaan untuk run yang gagal. Pola umumnya: Logging untuk menganalisis log, Monitoring untuk metrik dan alert.

A salah: Snapshot adalah backup data, bukan mekanisme notifikasi.

B salah: Pengecekan manual tidak otomatis dan lambat mendeteksi masalah.

C salah: Menambah slot tidak menjamin kegagalan hilang dan tetap tidak memberi notifikasi.

Soal 44 CHOOSE TWO

Section 3 · Data Pipeline Orchestration

ENGLISH

Which TWO situations are better suited to an ELT approach than to ETL? (Choose two.)

A. Raw data lands in BigQuery, and SQL-skilled analysts want to transform it there with Dataform or scheduled queries.

B. The business wants to keep the full raw data so it can be reprocessed later with new transformation logic.

C. The target system cannot perform transformations, so data must arrive fully cleaned.

D. Personal data must be removed before it is written to any storage in the cloud.

E. Complex record-by-record transformations must be done in Java on a stream before storage.

BAHASA INDONESIA

DUA situasi mana yang lebih cocok memakai pendekatan ELT dibanding ETL? (Pilih dua.)

A. Data mentah masuk ke BigQuery, dan analis yang mahir SQL ingin mentransformasinya di sana memakai Dataform atau scheduled query.

B. Bisnis ingin menyimpan seluruh data mentah agar bisa diproses ulang nanti dengan logika transformasi baru.

C. Sistem tujuan tidak bisa melakukan transformasi sehingga data harus datang dalam keadaan bersih.

D. Data pribadi harus dihapus sebelum ditulis ke storage apa pun di cloud.

E. Transformasi kompleks per record harus dilakukan dalam Java pada stream sebelum disimpan.

✔ Jawaban benar: A, B

Kenapa benar: ELT (Extract, Load, Transform) memuat data mentah dulu ke data warehouse yang kuat seperti BigQuery, lalu mentransformasinya di sana dengan SQL. Keuntungannya: skalabilitas BigQuery dimanfaatkan, data mentah tetap tersimpan sehingga bisa di-reprocess, dan tim SQL bisa bekerja mandiri.

C salah: Jika target tidak bisa mentransformasi, transformasi harus dilakukan sebelum load, yaitu ETL.

D salah: Data harus dibersihkan sebelum disimpan, jadi ini ciri ETL (transformasi sebelum load).

E salah: Transformasi dalam Java sebelum penyimpanan (misalnya dengan Dataflow) adalah pola ETL.

Soal 45

Section 3 · Data Pipeline Orchestration

ENGLISH

You are building a new pipeline with no existing code. It must handle a daily batch backfill and a real-time stream with the same business logic, scale workers automatically, and require no cluster management. Which service is the best fit?

A. Dataflow (Apache Beam)

B. Cloud SQL

C. Looker

D. Dataproc on a standard cluster

BAHASA INDONESIA

Anda membangun pipeline baru tanpa kode yang sudah ada. Pipeline harus menangani backfill batch harian dan stream real-time dengan logika bisnis yang sama, menambah atau mengurangi worker secara otomatis, dan tidak memerlukan pengelolaan cluster. Layanan mana yang paling cocok?

A. Dataflow (Apache Beam)

B. Cloud SQL

C. Looker

D. Dataproc dengan cluster standar

✔ **Jawaban benar: A**

Kenapa benar: Dataflow menjalankan pipeline Apache Beam. Model pemrogramannya menyatukan batch dan streaming dengan kode yang sama, layanannya serverless dengan autoscaling, dan dilengkapi windowing, triggers, serta exactly-once processing. Ini pilihan default untuk pipeline baru batch dan streaming di Google Cloud.

B salah: Cloud SQL adalah database, bukan engine pemrosesan pipeline.

C salah: Looker adalah tool BI.

D salah: Dataproc paling cocok jika sudah ada kode Spark/Hadoop. Cluster standar juga harus dikelola.

Soal 46

Section 4 · Data Management

ENGLISH

A new analyst must be able to run queries on the tables in the sales dataset, but must not modify or delete any data, and must not see other datasets in the project. Following the principle of least privilege, which roles should you grant?

A. roles/bigquery.dataViewer on the sales dataset, and roles/bigquery.jobUser on the project

B. The basic Editor role on the project

C. roles/bigquery.dataEditor on the project

D. roles/bigquery.admin on the sales dataset

BAHASA INDONESIA

Seorang analis baru harus bisa menjalankan query pada tabel-tabel di dataset sales, tetapi tidak boleh mengubah atau menghapus data dan tidak boleh melihat dataset lain di project. Sesuai prinsip least privilege, role apa yang harus diberikan?

A. roles/bigquery.dataViewer di dataset sales, dan roles/bigquery.jobUser di level project

B. Basic role Editor di level project

C. roles/bigquery.dataEditor di level project

D. roles/bigquery.admin di dataset sales

✔ **Jawaban benar: A**

Kenapa benar: Menjalankan query butuh dua hal: izin membaca data (bigquery.dataViewer, cukup diberikan di level dataset sales) dan izin membuat query job (bigquery.jobUser di project yang menjalankan job). Kombinasi predefined role dengan scope sempit ini memenuhi least privilege.

B salah: Editor adalah basic role yang sangat luas, mencakup hak mengubah hampir semua resource di project.

C salah: dataEditor memberi hak mengubah data, dan diberikan di semua dataset dalam project.

D salah: Admin memberi kendali penuh, termasuk menghapus tabel dan mengatur izin.

Soal 47

Section 4 · Data Management

ENGLISH

A Dataflow job runs as a dedicated service account. It must only write new output files to the bucket gs://exports-prod. It must not read, overwrite, or delete existing objects, and it must not access other buckets. Which role should you grant, and where?

A. roles/storage.objectAdmin on the project

B. roles/storage.admin on the project

C. roles/storage.objectCreator on the gs://exports-prod bucket

D. The basic Owner role on the bucket

BAHASA INDONESIA

Sebuah job Dataflow berjalan dengan service account khusus. Job itu hanya boleh menulis file output baru ke bucket gs://exports-prod. Ia tidak boleh membaca, menimpa, atau menghapus objek yang sudah ada, dan tidak boleh mengakses bucket lain. Role apa yang harus diberikan, dan di mana?

A. roles/storage.objectAdmin di level project

B. roles/storage.admin di level project

C. roles/storage.objectCreator di bucket gs://exports-prod

D. Basic role Owner di bucket

✔ Jawaban benar: C

Kenapa benar: Storage Object Creator hanya mengizinkan pembuatan objek baru (storage.objects.create), tanpa izin baca, hapus, atau timpa. Memberikannya di level bucket membatasi akses hanya ke bucket tersebut. Ini contoh least privilege.

A salah: Object Admin mengizinkan baca, tulis, dan hapus objek di semua bucket project.

B salah: Storage Admin memberi kendali penuh atas semua bucket di project.

D salah: Owner adalah basic role yang sangat luas dan tidak sesuai least privilege.

Soal 48 CHOOSE TWO

Section 4 · Data Management

ENGLISH

Your security team requires that access to a bucket of customer exports is controlled only through IAM, with no per-object ACLs, and that the bucket can never be made public, even by mistake. Which TWO settings should you enable? (Choose two.)

A. Fine-grained access control with object ACLs

B. Uniform bucket-level access

C. Grant allUsers the Storage Object Viewer role

D. Public access prevention (enforced)

E. Signed URLs that never expire

BAHASA INDONESIA

Tim keamanan mewajibkan akses ke bucket berisi ekspor data pelanggan hanya dikendalikan lewat IAM, tanpa ACL per objek, dan bucket tidak boleh pernah menjadi publik, termasuk karena kesalahan. DUA pengaturan mana yang harus diaktifkan? (Pilih dua.)

A. Fine-grained access control dengan ACL objek
B. Uniform bucket-level access
C. Beri allUsers role Storage Object Viewer
D. Public access prevention (enforced)
E. Signed URL yang tidak pernah kedaluwarsa

✔ Jawaban benar: B, D

Kenapa benar: Uniform bucket-level access menonaktifkan ACL sehingga akses hanya diatur oleh IAM di level bucket (dan dapat diwajibkan lewat organization policy). Public access prevention mencegah bucket atau objek dibagikan ke allUsers atau allAuthenticatedUsers, meskipun ada yang mencoba memberi akses publik.

A salah: Fine-grained memakai ACL per objek, justru bertentangan dengan syarat hanya IAM.

C salah: Memberi akses ke allUsers membuat data menjadi publik.

E salah: Signed URL memberi akses sementara ke siapa pun yang memegang URL. Masa berlakunya juga dibatasi maksimal 7 hari (V4), jadi URL tanpa kedaluwarsa tidak mungkin dan tidak aman.

Soal 49

Section 4 · Data Management

ENGLISH

The finance dataset contains an employees table with salary columns. The HR analytics team needs to query only employee_id, department, and hire_date. They must not be granted any access to the finance dataset itself. What should you do?

A. Grant the HR team roles/bigquery.dataViewer on the finance dataset.
B. Export the table to a CSV file every day and email it to HR.
C. Create a table snapshot of the employees table and share it with HR.
D. Create a view that selects only the allowed columns in a separate dataset that HR can access, and authorize that view on the finance dataset (authorized view).

BAHASA INDONESIA

Dataset finance berisi tabel employees dengan kolom gaji. Tim HR analytics hanya perlu meng-query employee_id, department, dan hire_date. Mereka tidak boleh diberi akses apa pun ke dataset finance itu sendiri. Apa yang harus dilakukan?

A. Beri tim HR roles/bigquery.dataViewer di dataset finance.
B. Ekspor tabel ke CSV setiap hari dan kirim lewat email ke HR.
C. Buat table snapshot dari tabel employees dan bagikan ke HR.
D. Buat view yang hanya memilih kolom yang diizinkan di dataset terpisah yang bisa diakses HR, lalu otorisasi view tersebut di dataset finance (authorized view).

✔ **Jawaban benar: D**

Kenapa benar: Authorized view memberi view tersebut izin membaca tabel sumber. Pengguna cukup diberi akses ke dataset tempat view berada, sehingga hanya bisa melihat kolom atau baris hasil view, tanpa akses ke tabel asli. Data juga selalu up-to-date karena tidak ada salinan.

A salah: HR akan bisa membaca seluruh tabel di dataset finance, termasuk gaji.

B salah: Cara ini manual, tidak aman, dan membuat salinan data yang tidak terkontrol.

C salah: Snapshot menyalin seluruh kolom termasuk gaji dan tidak ter-update.

Soal 50

Section 4 · Data Management

ENGLISH

Your company wants to share a curated BigQuery dataset of daily product prices with 30 external partner organizations. Partners should discover and subscribe to the data, query it from their own projects using their own compute budget, and always see the latest data without receiving copies. What should you use?

A. Use Storage Transfer Service to copy the data to each partner's bucket every night.

B. Add all partner users to your project with the basic Viewer role.

C. Export the dataset to Cloud Storage and give each partner a signed URL.

D. Publish the dataset as a listing in an Analytics Hub exchange, so partners subscribe and get a linked dataset in their projects.

BAHASA INDONESIA

Perusahaan Anda ingin membagikan dataset BigQuery terkurasi berisi harga produk harian ke 30 organisasi partner eksternal. Partner harus bisa menemukan dan subscribe ke data, meng-query-nya dari project mereka sendiri dengan biaya compute mereka sendiri, dan selalu melihat data terbaru tanpa menerima salinan. Apa yang sebaiknya digunakan?

A. Gunakan Storage Transfer Service untuk menyalin data ke bucket setiap partner setiap malam.

B. Tambahkan semua pengguna partner ke project Anda dengan basic role Viewer.

C. Ekspor dataset ke Cloud Storage dan beri setiap partner signed URL.

D. Publikasikan dataset sebagai listing di exchange Analytics Hub, sehingga partner subscribe dan mendapat linked dataset di project mereka.

✔ **Jawaban benar: D**

Kenapa benar: Analytics Hub (di konsol kini disebut BigQuery sharing) memungkinkan publisher membuat exchange dan listing. Subscriber mendapat linked dataset read-only di project mereka. Data tidak disalin (zero-copy) dan selalu terbaru, biaya query ditanggung subscriber, dan publisher bisa memantau penggunaan.

A salah: Membuat salinan berkala tidak real-time, dan data jadi berupa file, bukan dataset BigQuery yang bisa di-query.

B salah: Memberi basic role di project Anda terlalu luas, dan query partner akan ditagihkan ke project Anda jika dijalankan di sana.

C salah: Ekspor membuat salinan yang cepat usang dan sulit dikelola.

Soal 51

Section 4 · Data Management

ENGLISH

For a specific set of sensitive files, a compliance rule requires that Google never stores the encryption key. The company generates the key itself and must provide it with every read and write request to Cloud Storage. Which encryption option meets this requirement?

A. Customer-managed encryption keys (CMEK) in Cloud KMS

B. Google-managed encryption keys (default)

C. Customer-supplied encryption keys (CSEK)

D. Encryption in transit with TLS only

BAHASA INDONESIA

Untuk sekumpulan file sensitif tertentu, aturan compliance mewajibkan Google tidak pernah menyimpan kunci enkripsinya. Perusahaan membuat kunci sendiri dan harus mengirimkannya di setiap request baca dan tulis ke Cloud Storage. Opsi enkripsi mana yang memenuhi syarat ini?

A. Customer-managed encryption keys (CMEK) di Cloud KMS

B. Google-managed encryption keys (default)

C. Customer-supplied encryption keys (CSEK)

D. Hanya enkripsi in transit dengan TLS

✔ Jawaban benar: C

Kenapa benar: Dengan CSEK, pelanggan membuat dan memegang kunci AES-256 sendiri, lalu mengirimkannya di setiap request. Google hanya menyimpan hash kunci untuk validasi, bukan kuncinya. Jika kunci hilang, data tidak bisa dibuka. CSEK didukung di Cloud Storage dan Compute Engine, tetapi tidak di BigQuery.

A salah: Dengan CMEK, kunci dikendalikan pelanggan (rotasi, disable, IAM) tetapi tetap disimpan dan dikelola di Cloud KMS milik Google.

B salah: Dengan kunci default, Google yang membuat dan menyimpan kunci.

D salah: TLS hanya melindungi data saat transit, bukan data at rest, dan tidak memenuhi syarat kunci dipegang pelanggan.

Soal 52

Section 4 · Data Management

ENGLISH

Auditors require that the exact contents of the transactions table at the end of each quarter can be queried for the next 3 years. The preserved copy must be read-only and cost-efficient. What should you do?

A. Rely on BigQuery's fail-safe period.
B. Create a logical view filtered on the quarter's dates.
C. Create a table snapshot at each quarter end, with an expiration of 3 years.
D. Rely on BigQuery time travel.

BAHASA INDONESIA

Auditor mensyaratkan isi persis tabel transactions di setiap akhir kuartal bisa di-query selama 3 tahun ke depan. Salinan tersebut harus read-only dan hemat biaya. Apa yang harus dilakukan?

A. Mengandalkan periode fail-safe BigQuery.
B. Buat logical view yang difilter berdasarkan tanggal kuartal.
C. Buat table snapshot di setiap akhir kuartal dengan masa kedaluwarsa 3 tahun.
D. Mengandalkan time travel BigQuery.

✔ Jawaban benar: C

Kenapa benar: Table snapshot menyimpan isi tabel pada satu titik waktu, bersifat read-only, dan bisa diberi expiration. Biayanya efisien karena BigQuery hanya menagih data yang berbeda dari tabel dasar. Snapshot bisa di-query seperti tabel biasa atau di-restore menjadi tabel standar. Ingat juga bedanya dengan table clone, yang bisa ditulis (writable).

A salah: Fail-safe hanya 7 hari setelah periode time travel, hanya bisa dipulihkan lewat Google Support, dan bukan fitur yang bisa di-query.

B salah: View tidak menyimpan data. Jika baris diubah atau dihapus, isi view ikut berubah.

D salah: Time travel hanya menjangkau maksimal 7 hari ke belakang.

Soal 53

Section 4 · Data Management

ENGLISH

A company stores monthly report exports that are opened about once per quarter for reviews. The files must be kept for 2 years. You want the lowest total cost, including retrieval and minimum storage duration charges. Which storage class should you set for new objects?

A. Standard
B. Nearline
C. Coldline
D. Archive

BAHASA INDONESIA

Sebuah perusahaan menyimpan ekspor laporan bulanan yang dibuka sekitar sekali per kuartal untuk review. File harus disimpan selama 2 tahun. Anda ingin total biaya terendah, termasuk biaya pengambilan data dan biaya durasi penyimpanan minimum. Storage class apa yang sebaiknya diatur untuk objek baru?

A. Standard
B. Nearline
C. Coldline
D. Archive

✔ Jawaban benar: C

Kenapa benar: Panduan Google untuk setiap kelas: Standard untuk data yang sering diakses (tanpa durasi minimum); Nearline untuk akses kurang dari sekali sebulan (minimum 30 hari); Coldline untuk akses kurang dari sekali per kuartal atau 90 hari (minimum 90 hari); Archive untuk akses kurang dari sekali setahun (minimum 365 hari). Akses per kuartal paling cocok dengan Coldline.

A salah: Standard punya harga penyimpanan termahal, jadi boros untuk data yang jarang dibuka.

B salah: Nearline lebih murah daripada Standard, tetapi biaya penyimpanannya lebih mahal daripada Coldline, sedangkan data hanya diakses per kuartal.

D salah: Archive punya biaya retrieval tertinggi dan minimum 365 hari. Akses setiap kuartal membuat biaya retrieval-nya tidak ekonomis.

Soal 54

Section 4 · Data Management

ENGLISH

A shared analytics bucket contains millions of objects. Some are read daily, many are never read again, and the access pattern of individual objects is unknown and changes over time. You want to reduce storage costs automatically and avoid retrieval and early-deletion fees. What should you do?

A. Write a monthly script that changes storage classes based on object creation dates.
B. Enable Autoclass on the bucket.
C. Create a lifecycle rule that moves all objects to Archive after 30 days.
D. Set the bucket's default storage class to Coldline.

BAHASA INDONESIA

Sebuah bucket analitik bersama berisi jutaan objek. Sebagian dibaca setiap hari, banyak yang tidak pernah dibaca lagi, dan pola akses tiap objek tidak diketahui serta berubah dari waktu ke waktu. Anda ingin mengurangi biaya penyimpanan secara otomatis dan menghindari biaya retrieval serta early deletion. Apa yang harus dilakukan?

A. Tulis skrip bulanan yang mengubah storage class berdasarkan tanggal pembuatan objek.
B. Aktifkan Autoclass pada bucket.
C. Buat lifecycle rule yang memindahkan semua objek ke Archive setelah 30 hari.
D. Atur default storage class bucket menjadi Coldline.

✔ **Jawaban benar: B**

Kenapa benar: Autoclass memindahkan setiap objek berdasarkan aksesnya. Objek yang tidak diakses selama 30 hari pindah ke Nearline (dan bisa terus ke Coldline atau Archive jika terminal class Archive diaktifkan), sedangkan objek yang dibaca kembali ke Standard. Autoclass tidak mengenakan biaya retrieval dan early deletion, tetapi ada management fee. Catatan: Autoclass tidak bisa dikombinasikan dengan lifecycle rule SetStorageClass, dan objek di bawah 128 KiB tetap di Standard.

A salah: Skrip berdasarkan tanggal pembuatan tidak mencerminkan akses, rawan error, dan butuh perawatan.

C salah: Lifecycle rule berdasarkan umur, bukan akses. Objek yang masih dibaca harian akan pindah ke Archive dan terkena biaya retrieval mahal.

D salah: Objek yang dibaca harian akan terkena biaya retrieval Coldline dan minimum 90 hari.

Soal 55

Section 4 · Data Management

ENGLISH

A company stores critical business documents in Cloud Storage. They need the data in two specific regions (us-east1 and us-west1) and, if a whole region fails, a recovery point objective (RPO) of 15 minutes for newly written objects. What should you configure?

A. A multi-region US bucket with default replication

B. A regional bucket in us-east1 with Object Versioning

C. Two regional buckets and a daily gcloud storage rsync job

D. A dual-region bucket (us-east1 and us-west1) with Turbo replication enabled

BAHASA INDONESIA

Sebuah perusahaan menyimpan dokumen bisnis kritis di Cloud Storage. Mereka butuh data berada di dua region tertentu (us-east1 dan us-west1) dan, jika satu region gagal total, recovery point objective (RPO) 15 menit untuk objek yang baru ditulis. Apa yang harus dikonfigurasi?

A. Bucket multi-region US dengan default replication

B. Bucket regional di us-east1 dengan Object Versioning

C. Dua bucket regional dan job gcloud storage rsync harian

D. Bucket dual-region (us-east1 dan us-west1) dengan Turbo replication aktif

✔ **Jawaban benar: D**

Kenapa benar: Bucket dual-region menyimpan data di dua region yang Anda pilih. Turbo replication (khusus dual-region) menjamin 100% objek baru tereplikasi ke region kedua dalam 15 menit, yaitu RPO 15 menit. Default replication hanya menargetkan 99,9% objek dalam 1 jam dan 100% dalam 12 jam.

A salah: Multi-region tidak memungkinkan Anda memilih region spesifik, dan default replication tidak menjamin RPO 15 menit.

B salah: Bucket regional hanya ada di satu region. Versioning melindungi dari penghapusan atau penimpaan, bukan dari kegagalan region.

C salah: Sinkronisasi harian berarti RPO sampai 24 jam dan harus dikelola sendiri.

Soal 56 CHOOSE TWO

Section 4 · Data Management

ENGLISH

To reduce storage costs, temporary files under the tmp/ prefix in a Cloud Storage bucket must be deleted automatically 7 days after creation, and partitions older than 90 days in a date-partitioned BigQuery table must be removed automatically. Which TWO configurations achieve this with no custom code? (Choose two.)

A. Enable Object Versioning on the bucket.

B. Set the partition expiration of the BigQuery table to 90 days.

C. Apply a bucket retention policy of 7 days.

D. An Object Lifecycle Management rule with the action Delete and the conditions age = 7 and matchesPrefix = ["tmp/"]

E. Create a BigQuery table snapshot every 90 days.

BAHASA INDONESIA

Untuk menghemat biaya penyimpanan, file sementara di prefix tmp/ pada bucket Cloud Storage harus terhapus otomatis 7 hari setelah dibuat, dan partisi yang lebih tua dari 90 hari pada tabel BigQuery yang dipartisi per tanggal harus terhapus otomatis. DUA konfigurasi mana yang mencapainya tanpa kode custom? (Pilih dua.)

A. Aktifkan Object Versioning pada bucket.

B. Atur partition expiration tabel BigQuery menjadi 90 hari.

C. Terapkan retention policy bucket 7 hari.

D. Rule Object Lifecycle Management dengan action Delete dan kondisi age = 7 serta matchesPrefix = ["tmp/"]

E. Buat table snapshot BigQuery setiap 90 hari.

✔ Jawaban benar: B, D

Kenapa benar: Lifecycle rule di Cloud Storage bisa menghapus objek berdasarkan kondisi seperti age dan prefix, otomatis tanpa kode. Di BigQuery, partition expiration menghapus partisi yang melewati umur tertentu secara otomatis. Ada juga default table expiration di level dataset untuk tabel.

A salah: Versioning justru menyimpan versi lama, sehingga biaya bertambah.

C salah: Retention policy mencegah penghapusan sebelum periode tertentu. Ia tidak menghapus objek setelah 7 hari.

E salah: Snapshot menambah data yang disimpan, bukan menghapus.

Soal 57

Section 4 · Data Management

ENGLISH

A law firm stores contract documents in Cloud Storage. Each document must be kept, unmodified and undeletable, for 5 years after its contract is closed. The closing date is not known when the document is uploaded. What should you configure?

A. A bucket retention policy of 5 years with default event-based holds enabled, and release each object's hold when its contract is closed

B. Object Versioning only

C. A temporary hold on each object that is removed after 5 years

D. A lifecycle rule that deletes objects after 5 years

BAHASA INDONESIA

Sebuah firma hukum menyimpan dokumen kontrak di Cloud Storage. Setiap dokumen harus disimpan tanpa bisa diubah atau dihapus selama 5 tahun setelah kontraknya ditutup. Tanggal penutupan kontrak tidak diketahui saat dokumen di-upload. Apa yang harus dikonfigurasi?

A. Retention policy bucket 5 tahun dengan default event-based hold aktif, lalu lepas hold setiap objek saat kontraknya ditutup

B. Hanya Object Versioning

C. Temporary hold pada setiap objek yang dilepas setelah 5 tahun

D. Lifecycle rule yang menghapus objek setelah 5 tahun

✔ Jawaban benar: A

Kenapa benar: Event-based hold menahan objek agar tidak bisa dihapus atau diganti selama hold aktif. Jika bucket punya retention policy, hitungan periode retensi objek dimulai ketika event-based hold dilepas, yaitu saat kontrak ditutup. Default event-based hold memastikan setiap objek baru otomatis ter-hold. Untuk kepatuhan yang sangat ketat, retention policy bisa dikunci dengan Bucket Lock agar tidak bisa dikurangi atau dihapus.

B salah: Versioning menyimpan versi lama, tetapi versi tetap bisa dihapus permanen dan tidak ada periode retensi yang dipaksakan.

C salah: Temporary hold tidak memengaruhi perhitungan retention period. Ia hanya penahan manual, dan melepasnya setelah 5 tahun harus dilacak sendiri per objek.

D salah: Lifecycle rule hanya mengatur penghapusan. Ia tidak mencegah orang menghapus atau mengubah objek lebih awal, dan hitungannya dari tanggal upload, bukan dari penutupan kontrak.

Soal 58 CHOOSE TWO

Section 4 · Data Management

ENGLISH

An order management app uses Cloud SQL for PostgreSQL in us-central1. Requirements: (1) automatic failover with no committed transaction lost if a zone fails, and (2) offload heavy read-only reporting

queries from the primary, with a copy in another region that can be promoted manually during a regional disaster. Which TWO actions should you take? (Choose two.)

A. Create a cross-region read replica, for example in us-east1.
B. Schedule a daily export to Cloud Storage.
C. Enable high availability (regional instance) on the primary.
D. Create a second independent primary instance and write to both from the app.
E. Increase the primary's machine size.

BAHASA INDONESIA

Sebuah aplikasi manajemen order memakai Cloud SQL for PostgreSQL di us-central1. Kebutuhan: (1) failover otomatis tanpa kehilangan transaksi yang sudah di-commit jika sebuah zona gagal, dan (2) memindahkan beban query reporting read-only yang berat dari primary, dengan salinan di region lain yang bisa di-promote secara manual saat terjadi bencana regional. DUA tindakan mana yang harus dilakukan? (Pilih dua.)

A. Buat cross-region read replica, misalnya di us-east1.
B. Jadwalkan ekspor harian ke Cloud Storage.
C. Aktifkan high availability (regional instance) pada primary.
D. Buat instance primary kedua yang independen dan tulis ke keduanya dari aplikasi.
E. Perbesar ukuran mesin primary.

✔ Jawaban benar: A, C

Kenapa benar: HA Cloud SQL memakai primary dan standby di dua zona dalam satu region dengan replikasi sinkron ke disk di kedua zona. Jika satu zona gagal, failover terjadi otomatis tanpa kehilangan transaksi yang sudah di-commit. Standby tidak bisa dipakai untuk membaca. Read replica memakai replikasi asinkron, bisa ditempatkan di region lain, melayani query baca, dan bisa di-promote secara manual menjadi primary untuk disaster recovery regional.

B salah: Ekspor harian berarti RPO sampai 24 jam dan pemulihannya lambat. Ini bukan HA.

D salah: Menulis ke dua database independen menimbulkan inkonsistensi data dan bukan fitur Cloud SQL.

E salah: Mesin yang lebih besar tidak memberi failover maupun salinan di region lain.

Soal 59

Section 4 · Data Management

ENGLISH

At 10:15, a developer accidentally ran a DELETE statement without a WHERE clause on a production Cloud SQL for MySQL instance. Automated backups and point-in-time recovery are enabled. You need to recover the data as it was at 10:14 with minimal data loss. What should you do?

A. Use point-in-time recovery to create a new instance (clone) as of 10:14, then recover the data from it.
B. Restore last night's automated backup over the production instance.
C. Promote a read replica, because it still has the deleted rows.
D. Fail over the high-availability instance to the standby.

BAHASA INDONESIA

Pukul 10.15, seorang developer tidak sengaja menjalankan DELETE tanpa klausa WHERE di instance produksi Cloud SQL for MySQL. Automated backup dan point-in-time recovery sudah aktif. Anda perlu memulihkan data seperti kondisi pukul 10.14 dengan kehilangan data minimal. Apa yang harus dilakukan?

A. Gunakan point-in-time recovery untuk membuat instance baru (clone) pada kondisi pukul 10.14, lalu pulihkan data darinya.

B. Restore automated backup semalam ke instance produksi.

C. Promote read replica karena masih memiliki baris yang terhapus.

D. Lakukan failover instance high availability ke standby.

✔ Jawaban benar: A

Kenapa benar: Point-in-time recovery (PITR) memakai backup ditambah log transaksi (binary log di MySQL) untuk memulihkan ke waktu tertentu. Hasilnya berupa instance baru, sehingga instance produksi tidak tertimpa, dan data yang hilang bisa diambil atau dialihkan dari instance tersebut.

B salah: Backup semalam menghilangkan semua perubahan dari tengah malam sampai 10.14, dan me-restore ke produksi akan menimpa data terbaru lainnya.

C salah: Replikasi ke read replica cepat, jadi DELETE kemungkinan besar sudah tereplikasi ke sana juga.

D salah: Standby HA tersinkron secara sinkron, sehingga DELETE juga sudah ada di standby. HA melindungi dari kegagalan infrastruktur, bukan kesalahan manusia.

Soal 60

Section 4 · Data Management

ENGLISH

A bank's policy states that the encryption keys protecting BigQuery data at rest must be created, rotated, and disabled by the bank, with access to the keys controlled through IAM and recorded in audit logs. The keys can be managed within Google Cloud. What should you do?

A. Rely on the default Google-managed encryption.

B. Enforce TLS 1.2 for all client connections.

C. Use customer-supplied encryption keys (CSEK) on BigQuery queries.

D. Create keys in Cloud KMS and configure the BigQuery dataset to use customer-managed encryption keys (CMEK), granting the BigQuery service account the Cloud KMS CryptoKey Encrypter/Decrypter role.

BAHASA INDONESIA

Kebijakan sebuah bank menyatakan kunci enkripsi yang melindungi data BigQuery at rest harus dibuat, dirotasi, dan dinonaktifkan oleh bank, dengan akses ke kunci dikendalikan lewat IAM dan tercatat di audit log. Kunci boleh dikelola di dalam Google Cloud. Apa yang harus dilakukan?

A. Mengandalkan enkripsi default yang dikelola Google.

B. Wajibkan TLS 1.2 untuk semua koneksi klien.

C. Gunakan customer-supplied encryption keys (CSEK) pada query BigQuery.

D. Buat kunci di Cloud KMS dan konfigurasikan dataset BigQuery agar memakai customer-managed encryption keys (CMEK), lalu beri service account BigQuery role Cloud KMS CryptoKey Encrypter/Decrypter.

✔ Jawaban benar: D

Kenapa benar: CMEK memakai kunci di Cloud KMS yang dikendalikan pelanggan: rotasi, disable, destroy, IAM, dan Cloud Audit Logs. BigQuery mendukung default KMS key di level dataset atau tabel. Service account BigQuery perlu role cloudkms.cryptoKeyEncrypterDecrypter pada kunci tersebut. Jika kunci dinonaktifkan, data tidak bisa dibaca. Perbedaan enkripsi: at rest adalah data yang tersimpan di disk (default sudah terenkripsi), sedangkan in transit adalah data yang bergerak di jaringan (TLS).

A salah: Dengan kunci default, pelanggan tidak bisa membuat, merotasi, atau menonaktifkan kunci sendiri.

B salah: TLS melindungi data in transit, bukan at rest, dan tidak memberi kendali atas kunci.

C salah: CSEK tidak didukung di BigQuery. CSEK hanya untuk Cloud Storage dan Compute Engine.

Ringkasan Kunci Jawaban

Kolom "Jawabanku" dan "✓/✗" diisi sendiri saat latihan.

No	Domain	Kunci	Jawabanku	✓/✗
1	Data Preparation & Ingestion	**D**		
2	Data Preparation & Ingestion	**D**		
3	Data Preparation & Ingestion	**D**		
4	Data Preparation & Ingestion	**B**		
5	Data Preparation & Ingestion	**B**		
6	Data Preparation & Ingestion	**B**		
7	Data Preparation & Ingestion	**C**		
8	Data Preparation & Ingestion	**B**		
9	Data Preparation & Ingestion	**B**		
10	Data Preparation & Ingestion	**C**		
11	Data Preparation & Ingestion	**D**		
12	Data Preparation & Ingestion	**A**		
13	Data Preparation & Ingestion	**B**		
14	Data Preparation & Ingestion	**B**		
15	Data Preparation & Ingestion	**B**		
16	Data Preparation & Ingestion	**A**		
17	Data Preparation & Ingestion	**A, B** (pilih dua)		
18	Data Preparation & Ingestion	**C**		
19	Data Analysis & Presentation	**A**		
20	Data Analysis & Presentation	**C**		
21	Data Analysis & Presentation	**A**		
22	Data Analysis & Presentation	**D**		
23	Data Analysis & Presentation	**A**		
24	Data Analysis & Presentation	**A**		
25	Data Analysis & Presentation	**C**		
26	Data Analysis & Presentation	**C**		
27	Data Analysis & Presentation	**D**		
28	Data Analysis & Presentation	**B**		
29	Data Analysis & Presentation	**B**		
30	Data Analysis & Presentation	**C, D** (pilih dua)		
31	Data Analysis & Presentation	**A**		

32	Data Analysis & Presentation	**D**		
33	Data Analysis & Presentation	**C**		
34	Data Analysis & Presentation	**C**		
35	Data Pipeline Orchestration	**A**		
36	Data Pipeline Orchestration	**C**		
37	Data Pipeline Orchestration	**B**		
38	Data Pipeline Orchestration	**B**		
39	Data Pipeline Orchestration	**A**		
40	Data Pipeline Orchestration	**D**		
41	Data Pipeline Orchestration	**A**		
42	Data Pipeline Orchestration	**B**		
43	Data Pipeline Orchestration	**D**		
44	Data Pipeline Orchestration	**A, B** (pilih dua)		
45	Data Pipeline Orchestration	**A**		
46	Data Management	**A**		
47	Data Management	**C**		
48	Data Management	**B, D** (pilih dua)		
49	Data Management	**D**		
50	Data Management	**D**		
51	Data Management	**C**		
52	Data Management	**C**		
53	Data Management	**C**		
54	Data Management	**B**		
55	Data Management	**D**		
56	Data Management	**B, D** (pilih dua)		
57	Data Management	**A**		
58	Data Management	**A, C** (pilih dua)		
59	Data Management	**A**		
60	Data Management	**D**		

Rekap Skor per Domain

Domain	Jumlah soal	Benar	%
Section 1 · Data Preparation & Ingestion	18		
Section 2 · Data Analysis & Presentation	16		
Section 3 · Data Pipeline Orchestration	11		
Section 4 · Data Management	15		
Total	**60**		

Google tidak mempublikasikan nilai kelulusan (passing score) ujian ini. Sebagai patokan pribadi, targetkan ≥ 80–85% secara konsisten pada soal yang belum pernah kamu lihat sebelum menjadwalkan ujian.