GOOGLE CLOUD CERTIFIED · ASSOCIATE DATA PRACTITIONER

Latihan Soal Google Cloud Associate Data Practitioner – Prediksi Ujian (Set 2)

60 soal skenario orisinal baru (tidak mengulang Set 1) · Bilingual (English / Bahasa Indonesia) · Kunci jawaban & pembahasan lengkap

Disusun untuk: Muhammad Yusuf Ridho

Acuan: Associate Data Practitioner Certification Exam Guide v1.0 (Google Cloud)

Versi: Oktober 2026

Cara Memakai Buku Ini

1. **Kerjakan seperti ujian asli.** Baca soal versi English dulu (ujian resmi tersedia dalam English dan Japanese), lalu tutup bagian jawaban dengan kertas. Target waktu: ±2 menit per soal (ujian asli 2 jam untuk 50–60 soal).
2. **Bingung istilah?** Baca terjemahan Bahasa Indonesia di kotak abu-abu.
3. **Cocokkan jawaban**, lalu baca pembahasan. Bagian terpenting adalah "kenapa opsi lain salah", karena ujian ADP banyak memakai distraktor yang terdengar benar.
4. **Soal "Choose two" (Pilih dua)** ada 6 buah (no. 15, 22, 43, 47, 56, 59), mengikuti format multiple-select di ujian asli. Nilainya benar hanya jika kedua pilihan tepat.
5. **Catat salahmu per domain** di tabel ringkasan jawaban di halaman akhir, lalu ulangi materi domain yang paling lemah.

Domain (exam guide v1.0)	Bobot resmi	Jumlah soal	Nomor
Section 1 · Data Preparation & Ingestion	~30%	18	1–18
Section 2 · Data Analysis & Presentation	~27%	16	19–34
Section 3 · Data Pipeline Orchestration	~18%	11	35–45
Section 4 · Data Management	~25%	15	46–60
Total	**100%**	**60**	**1–60**

Fokus khusus (berdasarkan catatan kelemahanmu): pemilihan tool ingestion/storage (Transfer Appliance, STS vs BigQuery DTS, Datastream, Firestore/AlloyDB/Bigtable), Storage Write API, partitioning & clustering, BI Engine, Looker vs Looker Studio, LookML/PDT, alur BigQuery ML (TRANSFORM, ML.EXPLAIN_PREDICT, embedding & VECTOR_SEARCH), Dataflow windowing & Pub/Sub dead-letter, Composer vs Workflows vs scheduled query vs Dataform, Eventarc, IAM least privilege & service account, row-level security & data masking, signed URL, lifecycle & versioning, Cloud SQL HA, CMEK, time travel. Sudut pandang skenarionya sengaja berbeda dari Set 1.

> **Penting, soal ini bukan bocoran.** Soal ujian resmi Google bersifat rahasia dan tidak dipublikasikan. Semua soal di sini orisinal, disusun dari exam guide resmi dan dokumentasi Google Cloud agar gaya dan cakupannya semirip mungkin dengan ujian. Nama beberapa produk sedang di-rebrand oleh Google (misalnya Analytics Hub menjadi "BigQuery sharing", Dataplex Universal Catalog menjadi "Knowledge Catalog", dan Vertex AI menjadi "Gemini Enterprise Agent Platform" di dokumentasi; CSEK untuk Compute Engine sudah deprecated). Buku ini memakai nama seperti di exam guide v1.0. Selalu cek dokumentasi resmi untuk detail angka atau fitur terbaru.

Soal 1

Section 1 · Data Preparation & Ingestion

ENGLISH

A research institute must move 1.5 PB of genomics files from its on-premises data center to Cloud Storage within 6 weeks. The site's only internet link is 1 Gbps, and it is shared with daily operations. What is the most appropriate approach?

A. Upload the files with gcloud storage cp running in parallel from several servers.

B. Use Storage Transfer Service with on-premises agents and no bandwidth limit.

C. Use BigQuery Data Transfer Service to load the files.

D. Order Transfer Appliance, copy the data locally, and ship the appliance back to Google.

BAHASA INDONESIA

Sebuah lembaga riset harus memindahkan 1,5 PB file genomik dari data center on-premises ke Cloud Storage dalam 6 minggu. Satu-satunya koneksi internet di lokasi itu 1 Gbps dan dipakai bersama untuk operasional harian. Pendekatan apa yang paling tepat?

A. Upload file dengan gcloud storage cp secara paralel dari beberapa server.

B. Gunakan Storage Transfer Service dengan agent on-premises tanpa batas bandwidth.

C. Gunakan BigQuery Data Transfer Service untuk me-load file.

D. Pesan Transfer Appliance, salin data secara lokal, lalu kirim kembali perangkat ke Google.

✔ Jawaban benar: D

Kenapa benar: Hitung dulu: 1,5 PB × 8 bit ÷ 1 Gbps ≈ 12 juta detik ≈ 139 hari, itu pun kalau link dipakai penuh. Jadi transfer online mustahil selesai dalam 6 minggu. Transfer Appliance adalah perangkat penyimpanan fisik yang diisi di lokasi lalu dikirim ke Google, dan cocok untuk data berukuran ratusan TB sampai PB dengan bandwidth terbatas.

A salah: gcloud paralel tetap dibatasi link 1 Gbps yang sama.

B salah: Masalahnya bandwidth, bukan tool. Butuh sekitar 139 hari, dan memakai link tanpa batas juga mengganggu operasional.

C salah: BQ DTS memuat data ke tabel BigQuery dari sumber yang didukung. Ia tidak memindahkan file on-premises ke Cloud Storage.

Soal 2

Section 1 · Data Preparation & Ingestion

ENGLISH

An online game sends player events from many microservices. Traffic sometimes spikes 10× for a few minutes, and the downstream processing service cannot keep up during spikes. No event may be lost, and producers must not slow down. What should you place between the producers and the processing service?

A. A BigQuery scheduled query

B. A Cloud Storage bucket that producers write one file per event to

C. A Cloud SQL table that producers insert into

D. A Pub/Sub topic, with the processing service consuming from a subscription

BAHASA INDONESIA

Sebuah game online mengirim event pemain dari banyak microservice. Trafik kadang melonjak 10× selama beberapa menit, dan layanan pemrosesan di hilir tidak sanggup mengikuti saat lonjakan. Tidak boleh ada event yang hilang, dan producer tidak boleh melambat. Apa yang sebaiknya ditempatkan di antara producer dan layanan pemrosesan?

A. BigQuery scheduled query

B. Bucket Cloud Storage yang ditulisi satu file per event oleh producer

C. Tabel Cloud SQL yang di-insert oleh producer

D. Topic Pub/Sub, dengan layanan pemrosesan mengonsumsi dari subscription

✔ Jawaban benar: D

Kenapa benar: Pub/Sub adalah layanan messaging asinkron yang memisahkan (decouple) producer dan consumer. Pesan disimpan di subscription sampai di-acknowledge (default retensi 7 hari), sehingga lonjakan trafik bisa diserap sebagai buffer. Consumer memproses sesuai kemampuannya tanpa kehilangan data, dan producer tidak perlu menunggu.

A salah: Scheduled query menjalankan SQL berkala, bukan buffer pesan real-time.

B salah: Satu file per event tidak efisien (biaya operasi tinggi) dan tidak menyediakan mekanisme antrean atau acknowledgement.

C salah: Database OLTP bisa menjadi bottleneck saat lonjakan tulis, dan bukan dirancang sebagai antrean pesan.

Soal 3

Section 1 · Data Preparation & Ingestion

ENGLISH

A Java application must write order events directly into a BigQuery table in near real time. Duplicate rows are not acceptable even if the application retries after network errors, and you want the most cost-effective streaming ingestion method. What should you use?

A. Writing CSV files to Cloud Storage and querying them as an external table

B. The BigQuery Storage Write API with a committed-type stream and offsets, for exactly-once delivery

C. A load job every second

D. The legacy tabledata.insertAll streaming API

BAHASA INDONESIA

Sebuah aplikasi Java harus menulis event order langsung ke tabel BigQuery secara near real-time. Baris duplikat tidak boleh terjadi meskipun aplikasi melakukan retry setelah error jaringan, dan Anda ingin metode streaming ingestion yang paling hemat biaya. Apa yang sebaiknya digunakan?

A. Menulis file CSV ke Cloud Storage lalu meng-query-nya sebagai external table

B. BigQuery Storage Write API dengan stream tipe committed dan offset, untuk exactly-once delivery

C. Load job setiap detik

D. API streaming lama tabledata.insertAll

✔ Jawaban benar: B

Kenapa benar: Storage Write API (gRPC) adalah API ingestion terbaru BigQuery untuk streaming dan batch. Harganya lebih murah daripada insertAll, dan dengan stream offset ia mendukung semantik exactly-once, sehingga retry tidak membuat duplikat.

A salah: Ini bukan ingestion ke tabel BigQuery dan tidak near real-time untuk query yang efisien.

C salah: Load job punya kuota harian per tabel dan tidak dirancang untuk dijalankan setiap detik.

D salah: insertAll hanya best-effort deduplication (insertId), lebih mahal, dan sekarang disebut legacy.

Soal 4

Section 1 · Data Preparation & Ingestion

ENGLISH

Analysts want to join live inventory data that lives in a Cloud SQL for PostgreSQL database with historical sales data in BigQuery. They don't want to build an ETL pipeline or copy the inventory data, and some latency in the query is acceptable. What should you do?

A. Use Transfer Appliance.

B. Export the inventory database to CSV every minute.

C. Use Database Migration Service to move the inventory database into BigQuery.

D. Use a BigQuery federated query with EXTERNAL_QUERY through a Cloud SQL connection.

BAHASA INDONESIA

Analis ingin men-join data inventaris live yang ada di Cloud SQL for PostgreSQL dengan data penjualan historis di BigQuery. Mereka tidak mau membangun pipeline ETL atau menyalin data inventaris, dan sedikit latensi pada query masih bisa diterima. Apa yang harus dilakukan?

A. Gunakan Transfer Appliance.

B. Ekspor database inventaris ke CSV setiap menit.

C. Gunakan Database Migration Service untuk memindahkan database inventaris ke BigQuery.

D. Gunakan federated query BigQuery dengan EXTERNAL_QUERY melalui Cloud SQL connection.

✔ **Jawaban benar: D**

Kenapa benar: Federated query (EXTERNAL_QUERY) membuat BigQuery mengirim query ke Cloud SQL secara langsung melalui connection resource. Hasilnya bisa di-join dengan tabel BigQuery dalam satu query, tanpa ETL dan tanpa salinan permanen. Cocok untuk analisis ad-hoc data operasional.

A salah: Transfer Appliance untuk memindahkan data on-premises dalam jumlah besar secara fisik.

B salah: Ekspor tiap menit adalah ETL manual yang mahal dan membebani database.

C salah: DMS memigrasikan database ke Cloud SQL atau AlloyDB, bukan ke BigQuery. Lagi pula yang diminta bukan migrasi.

Soal 5

Section 1 · Data Preparation & Ingestion

ENGLISH

A team is building a mobile chat app. Each user's messages must sync in real time across devices, the app must keep working offline and sync when reconnected, and the data model is a flexible JSON-like document per conversation. Which database should you choose?

A. Bigtable
B. Firestore
C. Cloud Storage
D. BigQuery

BAHASA INDONESIA

Sebuah tim membangun aplikasi chat mobile. Pesan setiap pengguna harus tersinkron real-time di semua perangkat, aplikasi harus tetap berjalan saat offline lalu sinkron ketika terhubung kembali, dan model datanya berupa dokumen fleksibel mirip JSON per percakapan. Database apa yang sebaiknya dipilih?

A. Bigtable
B. Firestore
C. Cloud Storage
D. BigQuery

✔ **Jawaban benar: B**

Kenapa benar: Firestore adalah database NoSQL dokumen serverless dengan listener real-time, dukungan offline di SDK mobile dan web, dan skema fleksibel. Ini use case khas Firestore.

A salah: Bigtable unggul untuk throughput sangat tinggi berbasis row key, tetapi tidak punya sinkronisasi real-time maupun SDK offline untuk klien mobile.

C salah: Cloud Storage menyimpan file atau objek, bukan dokumen yang bisa di-query dan disinkronkan real-time.

D salah: BigQuery adalah data warehouse analitik, bukan database aplikasi real-time.

Soal 6

Section 1 · Data Preparation & Ingestion

ENGLISH

A company runs a PostgreSQL-based ERP system with heavy transactional load. Managers also need fast analytical queries on the same live data without moving it to another system. The team wants to keep full PostgreSQL compatibility and a fully managed service. Which service fits best?

A. Firestore
B. Cloud SQL for MySQL
C. AlloyDB for PostgreSQL
D. Bigtable

BAHASA INDONESIA

Sebuah perusahaan menjalankan sistem ERP berbasis PostgreSQL dengan beban transaksi berat. Manajer juga butuh query analitik cepat pada data live yang sama tanpa memindahkannya ke sistem lain. Tim ingin tetap kompatibel penuh dengan PostgreSQL dan memakai layanan fully managed. Layanan mana yang paling cocok?

A. Firestore
B. Cloud SQL for MySQL
C. AlloyDB for PostgreSQL
D. Bigtable

✔ Jawaban benar: C

Kenapa benar: AlloyDB for PostgreSQL adalah database fully managed yang kompatibel dengan PostgreSQL. Ia dirancang untuk workload transaksional berat dan dilengkapi columnar engine untuk mempercepat query analitik pada data operasional yang sama (HTAP).

A salah: Firestore adalah database dokumen NoSQL, bukan pengganti ERP relasional.

B salah: MySQL tidak kompatibel dengan aplikasi PostgreSQL.

D salah: Bigtable adalah NoSQL tanpa SQL relasional dan tidak kompatibel dengan PostgreSQL.

Soal 7

Section 1 · Data Preparation & Ingestion

ENGLISH

The marketing department wants Google Ads and YouTube Channel performance data in BigQuery every day for reporting. They want no code, automatic scheduling, and automatic backfills when needed. What should you use?

A. Datastream
B. Storage Transfer Service
C. BigQuery Data Transfer Service with the Google Ads and YouTube connectors
D. A Dataflow streaming job that reads from the Google Ads UI

BAHASA INDONESIA

Departemen marketing ingin data performa Google Ads dan YouTube Channel masuk ke BigQuery setiap hari untuk reporting. Mereka ingin tanpa kode, terjadwal otomatis, dan bisa backfill otomatis bila diperlukan. Apa yang sebaiknya digunakan?

A. Datastream
B. Storage Transfer Service
C. BigQuery Data Transfer Service dengan connector Google Ads dan YouTube
D. Job Dataflow streaming yang membaca dari UI Google Ads

✔ Jawaban benar: C

Kenapa benar: BigQuery Data Transfer Service punya connector bawaan untuk sumber SaaS Google seperti Google Ads, YouTube, Campaign Manager, Google Play, dan lainnya. Transfer dijadwalkan otomatis ke dataset BigQuery, mendukung backfill, dan tidak butuh kode.

A salah: Datastream untuk CDC dari database, bukan dari platform iklan.

B salah: STS memindahkan file ke Cloud Storage, bukan menarik data laporan Google Ads ke BigQuery.

D salah: Dataflow tidak bisa "membaca UI". Integrasi custom ke API Ads juga butuh banyak kode, padahal ada connector managed.

Soal 8

Section 1 · Data Preparation & Ingestion

ENGLISH

Every night, a partner delivers Parquet files that you append to the BigQuery table sales.partner_orders with a load job. This week, the partner added two new optional columns, and the load job now fails with a schema mismatch error. You want to keep appending without recreating the table or losing history. What should you do?

A. Ask the partner to stop sending the new columns forever.
B. Run the append load job with the schema update option ALLOW_FIELD_ADDITION (for example, bq load --schema_update_option=ALLOW_FIELD_ADDITION).
C. Delete the table, and reload all history with the new schema.
D. Convert the files to CSV, and drop the header row.

BAHASA INDONESIA

Setiap malam partner mengirim file Parquet yang Anda tambahkan (append) ke tabel BigQuery sales.partner_orders dengan load job. Minggu ini partner menambahkan dua kolom opsional baru, dan load job sekarang gagal dengan error schema mismatch. Anda ingin tetap melakukan append tanpa membuat ulang tabel atau kehilangan histori. Apa yang harus dilakukan?

A. Minta partner berhenti mengirim kolom baru selamanya.

B. Jalankan load job append dengan schema update option ALLOW_FIELD_ADDITION (misalnya bq load --schema_update_option=ALLOW_FIELD_ADDITION).

C. Hapus tabel lalu load ulang seluruh histori dengan skema baru.

D. Ubah file menjadi CSV dan hapus baris header.

✔ Jawaban benar: B

Kenapa benar: Load job (dan query job) yang melakukan append bisa memperluas skema tabel dengan schema update option ALLOW_FIELD_ADDITION (menambah kolom NULLABLE baru) atau ALLOW_FIELD_RELAXATION (mengubah REQUIRED menjadi NULLABLE). Parquet membawa skemanya sendiri, sehingga kolom baru terdeteksi otomatis. Baris lama akan bernilai NULL di kolom baru.

A salah: Ini tidak realistis dan menghambat kebutuhan bisnis. Evolusi skema adalah hal normal.

C salah: Membuat ulang tabel tidak perlu, mahal, dan berisiko.

D salah: CSV tidak menyelesaikan perbedaan skema, dan Anda kehilangan keunggulan format kolumnar yang self-describing.

Soal 9

Section 1 · Data Preparation & Ingestion

ENGLISH

Upstream teams frequently add new optional fields to event records. You want to store the events in files that carry their own schema, support schema evolution, are compact binary, and can be loaded quickly into BigQuery in parallel even when compressed. Which file format should you choose?

A. Apache Avro

B. Newline-delimited JSON with gzip compression

C. CSV

D. Plain text logs

BAHASA INDONESIA

Tim di hulu sering menambahkan field opsional baru ke record event. Anda ingin menyimpan event dalam file yang membawa skemanya sendiri, mendukung evolusi skema, berformat biner yang ringkas, dan bisa di-load cepat ke BigQuery secara paralel meskipun terkompresi. Format file apa yang sebaiknya dipilih?

A. Apache Avro

B. Newline-delimited JSON dengan kompresi gzip

C. CSV

D. Log teks biasa

✔ Jawaban benar: A

Kenapa benar: Avro adalah format biner berbasis baris dengan skema tertanam di file, dan mendukung evolusi skema seperti menambah field opsional. Google merekomendasikan Avro untuk load ke BigQuery karena blok data tetap bisa dibaca paralel walaupun file terkompresi.

B salah: File JSON yang di-gzip tidak bisa dibaca paralel oleh BigQuery, sehingga load lebih lambat. JSON juga tidak membawa skema formal.

C salah: CSV tidak membawa skema dan tidak mendukung nested field maupun evolusi skema dengan baik.

D salah: Log teks tanpa struktur harus diurai terlebih dahulu.

Soal 10

Section 1 · Data Preparation & Ingestion

ENGLISH

A JSON order feed contains an array of line items per order, and each line item has nested product attributes. Analysts want to load it into BigQuery while keeping the one-row-per-order grain, and avoid expensive joins. What is the recommended schema design?

A. Flatten everything into a single wide table with one row per product attribute.

B. Convert the JSON to CSV and drop the nested fields.

C. Use a STRUCT for nested attributes and a REPEATED (ARRAY) field for line items within the order row.

D. Store each line item in a separate dataset.

BAHASA INDONESIA

Feed order dalam format JSON berisi array line item per order, dan setiap line item punya atribut produk yang bersarang (nested). Analis ingin me-load-nya ke BigQuery dengan tetap mempertahankan grain satu baris per order, serta menghindari join yang mahal. Desain skema apa yang direkomendasikan?

A. Ratakan semuanya menjadi satu tabel lebar dengan satu baris per atribut produk.

B. Ubah JSON menjadi CSV dan buang field nested.

C. Gunakan STRUCT untuk atribut nested dan field REPEATED (ARRAY) untuk line item di dalam baris order.

D. Simpan setiap line item di dataset terpisah.

✔ Jawaban benar: C

Kenapa benar: BigQuery mendukung nested dan repeated field (STRUCT dan ARRAY). Denormalisasi seperti ini menyimpan line item di dalam baris order, sehingga tidak perlu join ke tabel lain. Ini sesuai praktik terbaik BigQuery untuk data semi-terstruktur, dan saat analisis Anda tinggal memakai UNNEST.

A salah: Meratakan semua data membuat duplikasi besar dan merusak grain satu baris per order.

B salah: Membuang field nested berarti kehilangan informasi.

D salah: Memecah ke dataset terpisah memaksa join dan menambah kompleksitas.

Soal 11

Section 1 · Data Preparation & Ingestion

ENGLISH

A daily CSV file from a partner has one header row, and occasionally up to about 50 malformed rows. The load job into BigQuery currently fails. You want the load to succeed by skipping the header and tolerating up to 100 bad rows. Which bq load options should you use?

A. --skip_leading_rows=1 --max_bad_records=100

B. --allow_jagged_rows=false --max_bad_records=0

C. --source_format=AVRO

D. --autodetect --replace

BAHASA INDONESIA

File CSV harian dari partner punya satu baris header dan kadang berisi hingga sekitar 50 baris rusak. Load job ke BigQuery saat ini gagal. Anda ingin load berhasil dengan melewati header dan menoleransi hingga 100 baris rusak. Opsi bq load apa yang sebaiknya digunakan?

A. --skip_leading_rows=1 --max_bad_records=100

B. --allow_jagged_rows=false --max_bad_records=0

C. --source_format=AVRO

D. --autodetect --replace

✔ **Jawaban benar: A**

Kenapa benar: --skip_leading_rows=1 melewati baris header. --max_bad_records=100 membuat load job tetap sukses selama jumlah baris rusak tidak melebihi 100. Sebaiknya jumlah baris yang dilewati tetap dipantau sebagai metrik kualitas data.

B salah: max_bad_records=0 berarti satu baris rusak saja sudah membuat job gagal.

C salah: File-nya CSV. Mengganti source_format ke AVRO akan membuat load gagal.

D salah: --autodetect hanya mendeteksi skema dan --replace menimpa tabel. Keduanya tidak menoleransi baris rusak.

Soal 12

Section 1 · Data Preparation & Ingestion

ENGLISH

In a BigQuery staging table, the phone column contains values such as "+62 812-3456-789", "0812 3456 789", and "(0812)3456789". You want to keep only digits so the values can be matched. Which expression should you use?

A. REGEXP_REPLACE(phone, r'[^0-9]', '')

B. UPPER(phone)

C. CAST(phone AS INT64)

D. TRIM(phone)

BAHASA INDONESIA

Di tabel staging BigQuery, kolom phone berisi nilai seperti "+62 812-3456-789", "0812 3456 789", dan "(0812)3456789". Anda ingin hanya menyisakan digit agar nilainya bisa dicocokkan. Ekspresi mana yang digunakan?

A. REGEXP_REPLACE(phone, r'[^0-9]', '')

B. UPPER(phone)

C. CAST(phone AS INT64)

D. TRIM(phone)

✔ **Jawaban benar: A**

Kenapa benar: REGEXP_REPLACE dengan pola [^0-9] mengganti semua karakter yang bukan digit (spasi, tanda hubung, kurung, plus) dengan string kosong. Ini teknik pembersihan data yang umum di ELT BigQuery. Langkah lanjutan seperti menyeragamkan awalan 62 atau 0 bisa ditambahkan setelahnya.

B salah: UPPER hanya mengubah huruf menjadi kapital, tanpa efek pada nomor telepon.

C salah: CAST akan error karena ada karakter non-digit. Tanda + dan nol di depan juga akan hilang dan maknanya berubah.

D salah: TRIM hanya menghapus spasi di awal dan akhir string.

Soal 13

Section 1 · Data Preparation & Ingestion

ENGLISH

Every night, files must be copied from a Cloud Storage bucket in project A to a bucket in project B, owned by another department. Objects that were deleted at the source should also be deleted at the destination. You want a managed, scheduled solution with logging and retries. What should you use?

A. BigQuery Data Transfer Service

B. Transfer Appliance

C. Storage Transfer Service with a bucket-to-bucket transfer job, a daily schedule, and the option to delete destination objects that are not in the source

D. A Pub/Sub BigQuery subscription

BAHASA INDONESIA

Setiap malam, file harus disalin dari bucket Cloud Storage di project A ke bucket di project B milik departemen lain. Objek yang sudah dihapus di sumber juga harus dihapus di tujuan. Anda ingin solusi managed yang terjadwal, dengan logging dan retry. Apa yang sebaiknya digunakan?

A. BigQuery Data Transfer Service

B. Transfer Appliance

C. Storage Transfer Service dengan transfer job bucket-ke-bucket, jadwal harian, dan opsi menghapus objek di tujuan yang tidak ada di sumber

D. Pub/Sub BigQuery subscription

✔ Jawaban benar: C

Kenapa benar: Storage Transfer Service mendukung transfer antar bucket Cloud Storage, termasuk lintas project. Transfer bisa dijadwalkan, punya opsi sinkronisasi (menghapus objek di tujuan yang tidak ada di sumber), retry otomatis, dan logging. Service agent STS perlu izin di kedua bucket.

A salah: BQ DTS memuat data ke BigQuery, bukan menyalin objek antar bucket.

B salah: Transfer Appliance untuk migrasi fisik dari on-premises.

D salah: Pub/Sub BigQuery subscription menulis pesan ke tabel BigQuery, bukan menyalin file.

Soal 14

Section 1 · Data Preparation & Ingestion

ENGLISH

Sensor readings from 100,000 devices are served to a mobile app through Bigtable with millisecond lookups. The data science team now wants to run ad hoc SQL over 2 years of history, with GROUP BY across all devices and joins to a device-metadata table. Where should this analytical workload run?

A. In BigQuery, either by querying Bigtable as an external source or, for repeated heavy analysis, by loading or exporting the history into native BigQuery tables

B. Directly on Bigtable with complex scans for every query

C. In Firestore

D. In Memorystore

BAHASA INDONESIA

Data sensor dari 100.000 perangkat disajikan ke aplikasi mobile melalui Bigtable dengan lookup dalam milidetik. Tim data science kini ingin menjalankan SQL ad-hoc atas riwayat 2 tahun, dengan GROUP BY untuk semua perangkat dan join ke tabel metadata perangkat. Di mana workload analitik ini sebaiknya dijalankan?

A. Di BigQuery, dengan meng-query Bigtable sebagai sumber eksternal, atau (untuk analisis berat yang berulang) dengan me-load atau mengekspor riwayatnya ke tabel BigQuery native

B. Langsung di Bigtable dengan scan kompleks untuk setiap query

C. Di Firestore

D. Di Memorystore

✔ Jawaban benar: A

Kenapa benar: Bigtable dioptimalkan untuk lookup per row key dengan latensi rendah, bukan agregasi SQL ad-hoc dan join. BigQuery adalah data warehouse analitik yang bisa meng-query Bigtable sebagai external table. Untuk performa terbaik pada analisis berulang, data dimuat ke tabel native. Pola umum: Bigtable untuk serving, BigQuery untuk analitik.

B salah: Scan besar di Bigtable untuk analitik ad-hoc tidak efisien, tidak mendukung join SQL secara alami, dan bisa mengganggu latensi aplikasi.

C salah: Firestore adalah database dokumen untuk aplikasi, bukan analitik skala besar.

D salah: Memorystore adalah cache in-memory (Redis/Memcached), bukan untuk analitik historis.

Soal 15 CHOOSE TWO

Section 1 · Data Preparation & Ingestion

ENGLISH

In a BigQuery staging table, the discount column (NUMERIC) contains NULL for orders without a discount. A report must treat these values as 0 when computing net revenue. Which TWO expressions return 0 for NULL and keep the other values unchanged? (Choose two.)

A. COALESCE(discount, 0)

B. IFNULL(discount, 0)

C. SAFE_CAST(discount AS STRING)

D. NULLIF(discount, 0)

E. CAST(NULL AS NUMERIC)

BAHASA INDONESIA

Di sebuah tabel staging BigQuery, kolom discount (NUMERIC) berisi NULL untuk order tanpa diskon. Sebuah laporan harus menganggap nilai tersebut sebagai 0 saat menghitung net revenue. DUA ekspresi mana yang mengembalikan 0 untuk NULL dan membiarkan nilai lain tidak berubah? (Pilih dua.)

A. COALESCE(discount, 0)
B. IFNULL(discount, 0)
C. SAFE_CAST(discount AS STRING)
D. NULLIF(discount, 0)
E. CAST(NULL AS NUMERIC)

✔ Jawaban benar: A, B

Kenapa benar: COALESCE mengembalikan argumen pertama yang tidak NULL, sedangkan IFNULL(expr, pengganti) mengembalikan pengganti bila expr bernilai NULL. Untuk dua argumen hasil keduanya identik. Ini teknik cleaning standar untuk menangani nilai kosong sebelum agregasi.

C salah: Ekspresi ini hanya mengubah tipe ke STRING. NULL tetap NULL.

D salah: NULLIF(discount, 0) justru kebalikannya, yaitu mengubah 0 menjadi NULL.

E salah: Ekspresi ini selalu menghasilkan NULL, tidak memakai kolom sama sekali.

Soal 16

Section 1 · Data Preparation & Ingestion

ENGLISH

During ingestion, PII fields must be hashed and obvious duplicates removed before the data lands in BigQuery. After it lands, the analytics team builds complex dimensional models in BigQuery using SQL. Which data manipulation methodology does this describe?

A. ETL
B. ETLT
C. EL only
D. ELT

BAHASA INDONESIA

Saat ingestion, field PII harus di-hash dan duplikat yang jelas harus dibuang sebelum data masuk BigQuery. Setelah masuk, tim analitik membangun model dimensional yang kompleks di BigQuery dengan SQL. Metodologi manipulasi data apa yang digambarkan?

A. ETL
B. ETLT
C. EL saja
D. ELT

✔ **Jawaban benar: B**

Kenapa benar: ETLT (Extract, Transform, Load, Transform) melakukan transformasi ringan sebelum load (masking/hashing PII, dedup sederhana), lalu transformasi berat setelah load di data warehouse dengan SQL, misalnya lewat Dataform. Exam guide menyebut ETL, ELT, dan ETLT secara eksplisit.

A salah: Pada ETL murni, seluruh transformasi (termasuk modeling) dilakukan sebelum load.

C salah: EL tidak melakukan transformasi sama sekali.

D salah: Pada ELT murni, data dimuat mentah tanpa transformasi sebelum load, padahal di sini ada hashing PII sebelum load.

Soal 17

Section 1 · Data Preparation & Ingestion

ENGLISH

A team must choose a Cloud Storage location for nightly batch files that are processed only by BigQuery and Dataflow jobs running in us-central1. There is no multi-region availability requirement, and the goal is the lowest storage cost and no inter-region network charges. Which location should you choose?

A. Region europe-west1

B. Region us-central1

C. Dual-region us-central1 and us-east1 with Turbo replication

D. Multi-region US

BAHASA INDONESIA

Sebuah tim harus memilih lokasi Cloud Storage untuk file batch malam yang hanya diproses oleh job BigQuery dan Dataflow di us-central1. Tidak ada kebutuhan availability multi-region, dan targetnya biaya penyimpanan terendah serta tanpa biaya jaringan antar-region. Lokasi mana yang dipilih?

A. Region europe-west1

B. Region us-central1

C. Dual-region us-central1 dan us-east1 dengan Turbo replication

D. Multi-region US

✔ **Jawaban benar: B**

Kenapa benar: Bucket regional di region yang sama dengan compute menghasilkan biaya penyimpanan terendah dan latensi terbaik, dan tidak ada biaya replikasi atau transfer antar-region. Data tetap redundan antar zona di region tersebut.

A salah: Region yang berbeda dari compute menimbulkan latensi dan biaya transfer antar-region.

C salah: Dual-region dengan Turbo replication menambah biaya penyimpanan dan replikasi, padahal tidak ada kebutuhan DR lintas region.

D salah: Multi-region lebih mahal dan tidak dibutuhkan.

Soal 18

Section 1 · Data Preparation & Ingestion

ENGLISH

You must load 30 GB of daily text log files from Cloud Storage into BigQuery. Each line must be parsed with a small JavaScript function that extracts fields, and you want a managed, scalable solution with the least code. What should you do?

A. Use BigQuery Data Transfer Service for YouTube.

B. Write a custom Spark job on a Dataproc cluster.

C. Use Database Migration Service.

D. Use the Google-provided Dataflow template "Cloud Storage Text to BigQuery" with a JavaScript user-defined function (UDF).

BAHASA INDONESIA

Anda harus me-load 30 GB file log teks harian dari Cloud Storage ke BigQuery. Setiap baris perlu diurai dengan fungsi JavaScript kecil yang mengekstrak field, dan Anda ingin solusi managed yang scalable dengan kode paling sedikit. Apa yang harus dilakukan?

A. Gunakan BigQuery Data Transfer Service untuk YouTube.

B. Tulis job Spark custom di cluster Dataproc.

C. Gunakan Database Migration Service.

D. Gunakan template Dataflow dari Google "Cloud Storage Text to BigQuery" dengan JavaScript user-defined function (UDF).

✔ Jawaban benar: D

Kenapa benar: Dataflow menyediakan template siap pakai buatan Google. Template Cloud Storage Text to BigQuery membaca file teks, menjalankan UDF JavaScript untuk transformasi per baris, lalu menulis ke BigQuery. Pipeline-nya serverless dan autoscaling tanpa perlu menulis pipeline Beam sendiri.

A salah: Connector YouTube tidak ada hubungannya dengan file log di Cloud Storage.

B salah: Spark custom butuh lebih banyak kode dan pengelolaan cluster.

C salah: DMS untuk migrasi database, bukan file log.

Soal 19

Section 2 · Data Analysis & Presentation

ENGLISH

A 40 TB BigQuery events table is queried hundreds of times a day. Almost every query filters on a date range of event_timestamp, and most also filter on customer_id. You want to reduce the bytes scanned and improve performance. How should you redesign the table?

A. Partition by customer_id and cluster by event_timestamp.

B. Remove the partitioning and add LIMIT to all queries.

C. Partition by DATE(event_timestamp) and cluster by customer_id.

D. Create one table per customer.

BAHASA INDONESIA

Tabel events BigQuery berukuran 40 TB di-query ratusan kali per hari. Hampir semua query memfilter rentang tanggal pada event_timestamp, dan sebagian besar juga memfilter customer_id. Anda ingin mengurangi byte yang di-scan dan meningkatkan performa. Bagaimana tabel sebaiknya dirancang ulang?

A. Partisi berdasarkan customer_id dan cluster berdasarkan event_timestamp.

B. Hapus partisi dan tambahkan LIMIT di semua query.

C. Partisi berdasarkan DATE(event_timestamp) dan cluster berdasarkan customer_id.

D. Buat satu tabel per pelanggan.

✔ Jawaban benar: C

Kenapa benar: Partisi per tanggal memungkinkan partition pruning, sehingga hanya partisi dalam rentang tanggal yang dibaca. Clustering pada customer_id mengurutkan data di dalam partisi, sehingga filter customer_id membaca lebih sedikit blok. Ini kombinasi standar untuk mengoptimalkan biaya dan performa BigQuery.

A salah: Partisi integer-range pada customer_id dengan banyak nilai tidak efisien dan dibatasi jumlah partisi maksimum. Filter utama (tanggal) juga tidak akan memanfaatkan pruning.

B salah: LIMIT tidak mengurangi byte yang di-scan pada BigQuery.

D salah: Ribuan tabel (sharding) sulit dikelola dan lebih lambat daripada satu tabel yang dipartisi.

Soal 20

Section 2 · Data Analysis & Presentation

ENGLISH

A partitioned BigQuery table is shared with many analysts. Several analysts accidentally ran queries without a date filter and scanned the entire table, which caused unexpected costs. You want BigQuery to reject queries on this table that do not filter on the partitioning column. What should you configure?

A. Set require_partition_filter = TRUE on the table.

B. Remove clustering from the table.

C. Grant analysts roles/bigquery.dataEditor.

D. Convert the table into a view.

BAHASA INDONESIA

Tabel BigQuery yang dipartisi dibagikan ke banyak analis. Beberapa analis tidak sengaja menjalankan query tanpa filter tanggal dan men-scan seluruh tabel, sehingga muncul biaya tak terduga. Anda ingin BigQuery menolak query pada tabel ini yang tidak memfilter kolom partisi. Apa yang harus dikonfigurasi?

A. Set require_partition_filter = TRUE pada tabel.

B. Hapus clustering dari tabel.

C. Beri analis roles/bigquery.dataEditor.

D. Ubah tabel menjadi view.

✔ **Jawaban benar: A**

Kenapa benar: Opsi require_partition_filter memaksa setiap query ke tabel partisi menyertakan filter pada kolom partisi yang bisa dipakai untuk pruning. Query tanpa filter itu akan gagal, bukan men-scan seluruh tabel. Kontrol biaya lain yang melengkapinya: maximum bytes billed per query dan custom quota per pengguna atau project.

B salah: Menghapus clustering justru menurunkan efisiensi dan tidak mencegah full scan.

C salah: Role dataEditor memberi hak lebih luas (mengubah data) dan tidak membatasi biaya query.

D salah: View tidak mencegah full scan pada tabel di bawahnya.

Soal 21

Section 2 · Data Analysis & Presentation

ENGLISH

A product manager needs a daily count of unique visitors over a 10-billion-row clickstream table to display on a dashboard. An approximate result with about 1% error is acceptable if the query is much faster and cheaper. Which function should you use?

A. COUNT(DISTINCT visitor_id)

B. ARRAY_AGG(visitor_id)

C. APPROX_COUNT_DISTINCT(visitor_id)

D. COUNT(*)

BAHASA INDONESIA

Seorang product manager butuh jumlah pengunjung unik harian dari tabel clickstream berisi 10 miliar baris untuk ditampilkan di dashboard. Hasil perkiraan dengan error sekitar 1% bisa diterima asalkan query jauh lebih cepat dan murah. Fungsi apa yang sebaiknya digunakan?

A. COUNT(DISTINCT visitor_id)

B. ARRAY_AGG(visitor_id)

C. APPROX_COUNT_DISTINCT(visitor_id)

D. COUNT(*)

✔ **Jawaban benar: C**

Kenapa benar: APPROX_COUNT_DISTINCT memakai algoritma HyperLogLog++ untuk memperkirakan jumlah nilai unik dengan resource jauh lebih sedikit daripada COUNT(DISTINCT). Fungsi ini cocok untuk dashboard skala besar ketika akurasi mutlak tidak wajib. Ada juga fungsi HLL_COUNT untuk sketch yang bisa digabung.

A salah: COUNT(DISTINCT) memberi hasil tepat tetapi lebih berat dan lambat untuk data miliaran baris.

B salah: ARRAY_AGG mengumpulkan semua ID ke dalam array, sangat berat dan bisa melebihi batas memori.

D salah: COUNT(*) menghitung semua baris, bukan pengunjung unik.

Soal 22 CHOOSE TWO

Section 2 · Data Analysis & Presentation

ENGLISH

A table is partitioned by order_date and has 300 columns. An analyst's query is SELECT * FROM sales WHERE region = 'APAC' LIMIT 100. Which TWO changes will reduce the bytes processed by this query? (Choose two.)

A. Reduce LIMIT 100 to LIMIT 10.

B. Add ORDER BY region.

C. Select only the columns that are actually needed instead of SELECT *.

D. Add a filter on order_date for the required date range.

E. Run the same query twice to warm the cache.

BAHASA INDONESIA

Sebuah tabel dipartisi berdasarkan order_date dan memiliki 300 kolom. Query seorang analis adalah SELECT * FROM sales WHERE region = 'APAC' LIMIT 100. DUA perubahan mana yang akan mengurangi byte yang diproses oleh query ini? (Pilih dua.)

A. Kurangi LIMIT 100 menjadi LIMIT 10.

B. Tambahkan ORDER BY region.

C. Pilih hanya kolom yang benar-benar dibutuhkan, bukan SELECT *.

D. Tambahkan filter order_date untuk rentang tanggal yang dibutuhkan.

E. Jalankan query yang sama dua kali untuk "memanaskan" cache.

✔ **Jawaban benar: C, D**

Kenapa benar: BigQuery bersifat kolumnar, sehingga yang ditagih adalah kolom yang dibaca. Memilih sedikit kolom langsung memangkas byte. Filter pada kolom partisi memicu partition pruning, sehingga partisi di luar rentang tidak dibaca. Untuk sekadar melihat contoh data, gunakan fitur Preview tabel di console yang tidak dikenai biaya.

A salah: LIMIT tidak mengurangi byte yang di-scan pada query biasa. Seluruh kolom yang dipilih tetap dibaca.

B salah: ORDER BY menambah komputasi dan tidak mengurangi byte yang dibaca.

E salah: Cached result hanya berlaku untuk query yang identik dan tidak mengubah byte yang diproses pada run pertama. Mengandalkannya bukan optimasi desain.

Soal 23

Section 2 · Data Analysis & Presentation

ENGLISH

Executives use a Looker Studio dashboard on top of BigQuery. It has many charts that run small aggregation queries, and the users complain about slow load times during morning meetings. You want to speed up the interactive queries with minimal changes to the dashboard. What should you do?

A. Create a BigQuery BI Engine reservation in the same location as the dataset.

B. Export the data to Google Sheets.

C. Move the data to Cloud SQL.

D. Rewrite the dashboard as a Colab notebook.

BAHASA INDONESIA

Para eksekutif memakai dashboard Looker Studio di atas BigQuery. Dashboard punya banyak chart yang menjalankan query agregasi kecil, dan pengguna mengeluh waktu muatnya lambat saat rapat pagi. Anda ingin mempercepat query interaktif dengan perubahan minimal pada dashboard. Apa yang harus dilakukan?

A. Buat reservasi BigQuery BI Engine di lokasi yang sama dengan dataset.

B. Ekspor data ke Google Sheets.

C. Pindahkan data ke Cloud SQL.

D. Tulis ulang dashboard sebagai notebook Colab.

✔ Jawaban benar: A

Kenapa benar: BI Engine adalah layanan analisis in-memory di BigQuery yang mempercepat query interaktif dari tool BI seperti Looker Studio dan Looker, tanpa perlu mengubah dashboard. Cukup buat reservasi kapasitas memori di lokasi yang sama dengan dataset. Materialized view atau tabel agregat bisa membantu sebagai pelengkap.

B salah: Sheets punya batas ukuran dan menghasilkan salinan data yang cepat usang.

C salah: Cloud SQL tidak dirancang untuk analitik skala besar dan migrasinya merepotkan.

D salah: Notebook bukan pengganti dashboard eksekutif yang interaktif.

Soal 24

Section 2 · Data Analysis & Presentation

ENGLISH

Business users at a company that already uses Looker want to answer new ad hoc questions themselves. For example, they want revenue by product category for last quarter in a specific region, without writing SQL and using only approved metric definitions. Which Looker feature should they use?

A. A CSV export from BigQuery

B. A Looker Studio calculated field

C. A SQL Runner query written by each user

D. An Explore built on the governed LookML model

BAHASA INDONESIA

Pengguna bisnis di perusahaan yang sudah memakai Looker ingin menjawab pertanyaan ad-hoc baru secara mandiri, misalnya revenue per kategori produk kuartal lalu di region tertentu, tanpa menulis SQL dan hanya memakai definisi metrik yang disetujui. Fitur Looker apa yang sebaiknya dipakai?

A. Ekspor CSV dari BigQuery

B. Calculated field Looker Studio

C. Query SQL Runner yang ditulis oleh masing-masing pengguna

D. Explore yang dibangun di atas model LookML terkelola

✔ Jawaban benar: D

Kenapa benar: Explore adalah antarmuka self-service di Looker. Pengguna memilih dimension, measure, dan filter yang sudah didefinisikan di LookML, lalu Looker membuat SQL-nya secara otomatis. Dengan begitu semua orang memakai definisi metrik yang sama dan terkelola.

A salah: Ekspor CSV bersifat manual, tidak terkelola, dan cepat usang.

B salah: Looker Studio adalah produk berbeda, dan calculated field di sana tidak memakai model LookML terkelola milik Looker.

C salah: SQL Runner menuntut kemampuan SQL dan melewati definisi metrik terkelola.

Soal 25

Section 2 · Data Analysis & Presentation

ENGLISH

In Looker, analysts need a "customer lifetime value" field that is calculated by aggregating the orders table per customer. They then want to use it as a dimension, for example to group customers into LTV tiers. The underlying database has no such table. What is the LookML approach?

A. Add hidden: yes to the orders view.

B. Create a Looker Studio report.

C. Define a derived table in a new view (derived_table with sql, optionally persisted with a datagroup) that computes LTV per customer, and join it to the customers explore.

D. Define a measure with type: sum and use it directly as a tier dimension.

BAHASA INDONESIA

Di Looker, analis butuh field "customer lifetime value" yang dihitung dengan mengagregasi tabel orders per pelanggan. Mereka lalu ingin memakainya sebagai dimension, misalnya untuk mengelompokkan pelanggan ke tier LTV. Database tidak memiliki tabel seperti itu. Bagaimana pendekatannya di LookML?

A. Tambahkan hidden: yes pada view orders.

B. Buat laporan Looker Studio.

C. Definisikan derived table di view baru (derived_table dengan sql, opsional dipersist dengan datagroup) yang menghitung LTV per pelanggan, lalu join ke explore customers.

D. Definisikan measure dengan type: sum lalu langsung pakai sebagai dimension tier.

✔ Jawaban benar: C

Kenapa benar: Derived table di LookML adalah tabel hasil query (SQL-based atau native derived table) yang diperlakukan seperti view biasa. Hasil agregasi per pelanggan menjadi kolom, sehingga bisa dijadikan dimension, termasuk type: tier untuk pengelompokan. Persistent derived table (PDT) menyimpan hasilnya di database dan di-rebuild sesuai datagroup.

A salah: hidden hanya menyembunyikan field dan tidak menghitung LTV.

B salah: Pindah tool tidak memenuhi kebutuhan model Looker yang terkelola.

D salah: Measure adalah agregasi saat query, jadi tidak bisa langsung dipakai sebagai dimension pengelompokan per baris pelanggan.

Soal 26

Section 2 · Data Analysis & Presentation

ENGLISH

A Looker view has a created_at timestamp column. Users want to group results by created date, week, month, and year without you having to define four separate dimensions. Which LookML construct should you use?

A. dimension_group: created { type: time timeframes: [raw, date, week, month, year] sql: ${TABLE}.created_at ;; }

B. explore: created {}

C. `measure: created { type: count }`

D. `dimension: created { type: string sql: ${TABLE}.created_at ;; }`

BAHASA INDONESIA

Sebuah view Looker memiliki kolom timestamp created_at. Pengguna ingin mengelompokkan hasil berdasarkan tanggal, minggu, bulan, dan tahun pembuatan, tanpa Anda harus mendefinisikan empat dimension terpisah. Konstruksi LookML apa yang digunakan?

A. dimension_group: created { type: time timeframes: [raw, date, week, month, year] sql: ${TABLE}.created_at ;; }

B. explore: created {}

C. `measure: created { type: count }`

D. `dimension: created { type: string sql: ${TABLE}.created_at ;; }`

✔ Jawaban benar: A

Kenapa benar: dimension_group dengan type: time dan daftar timeframes otomatis membuat banyak dimension terkait, seperti created_date, created_week, created_month, dan created_year, dari satu kolom waktu. Ini cara standar menangani tanggal di LookML.

B salah: Explore adalah titik awal query (dan biasanya didefinisikan di file model), bukan definisi field waktu.

C salah: Measure count menghitung baris dan tidak membuat pengelompokan waktu.

D salah: Kolom waktu dengan type: string tidak bisa dikelompokkan per minggu atau bulan secara benar.

Soal 27

Section 2 · Data Analysis & Presentation

ENGLISH

You build a Looker Studio report on a BigQuery table that has row-level security, so each sales rep should see only their own accounts. After you share the report, every rep sees all accounts. What should you change?

A. Set the data source credentials to Viewer's credentials, so each viewer queries BigQuery with their own identity and permissions.

B. Keep Owner's credentials and add a report-level filter.

C. Make the report public.

D. Export the table to Google Sheets per rep.

BAHASA INDONESIA

Anda membuat laporan Looker Studio di atas tabel BigQuery yang memakai row-level security, sehingga setiap sales rep seharusnya hanya melihat akun miliknya. Setelah laporan dibagikan, setiap rep justru melihat semua akun. Apa yang harus diubah?

A. Ubah kredensial data source menjadi Viewer's credentials, agar setiap viewer meng-query BigQuery dengan identitas dan izinnya sendiri.

B. Tetap gunakan Owner's credentials dan tambahkan filter di level laporan.

C. Jadikan laporan publik.

D. Ekspor tabel ke Google Sheets untuk setiap rep.

✔ Jawaban benar: A

Kenapa benar: Dengan Owner's credentials, semua viewer mengakses data dengan izin pemilik data source, yang bisa melihat semua baris. Dengan Viewer's credentials, setiap viewer harus punya akses sendiri ke dataset, dan kebijakan BigQuery (row-level security, column-level security) diterapkan sesuai identitas masing-masing.

B salah: Filter di laporan bisa diubah atau dilewati oleh pengguna dan bukan kontrol keamanan. Data tetap diambil dengan izin pemilik.

C salah: Membuat publik justru memperluas akses.

D salah: Salinan manual per rep tidak skalabel, tidak aman, dan cepat usang.

Soal 28

Section 2 · Data Analysis & Presentation

ENGLISH

You are training a BigQuery ML model to detect fraudulent transactions. Only 0.5% of the training rows are fraud. The first model shows 99.5% accuracy but catches almost no fraud. Which evaluation approach is most appropriate?

A. Use the number of clusters.

B. Keep using accuracy, because it is very high.

C. Focus on precision, recall, F1, and ROC AUC or PR curves from ML.EVALUATE, and consider class weighting such as auto_class_weights = TRUE.

D. Use mean squared error.

BAHASA INDONESIA

Anda melatih model BigQuery ML untuk mendeteksi transaksi fraud. Hanya 0,5% baris training yang merupakan fraud. Model pertama menunjukkan akurasi 99,5% tetapi hampir tidak menangkap fraud sama sekali. Pendekatan evaluasi apa yang paling tepat?

A. Gunakan jumlah cluster.

B. Tetap memakai accuracy karena nilainya sangat tinggi.

C. Fokus pada precision, recall, F1, serta ROC AUC atau kurva PR dari ML.EVALUATE, dan pertimbangkan pembobotan kelas seperti auto_class_weights = TRUE.

D. Gunakan mean squared error.

✔ Jawaban benar: C

Kenapa benar: Pada data tidak seimbang, model yang selalu menjawab "bukan fraud" sudah mendapat akurasi 99,5%, jadi accuracy menyesatkan. Recall mengukur berapa banyak fraud yang tertangkap, dan precision mengukur berapa banyak tebakan fraud yang benar. Opsi auto_class_weights di BQML menyeimbangkan bobot kelas saat training.

A salah: Jumlah cluster adalah konsep clustering (k-means), bukan evaluasi klasifikasi.

B salah: Accuracy tinggi di sini tidak berarti apa-apa karena model gagal pada kelas yang penting.

D salah: MSE adalah metrik regresi, bukan klasifikasi.

Soal 29

Section 2 · Data Analysis & Presentation

ENGLISH

When you train a BigQuery ML model, you standardize numeric features and bucketize the customer's age. You want the exact same preprocessing to be applied automatically when ML.PREDICT is called later, so it never drifts from training. What should you use?

A. Apply the preprocessing manually in every prediction query.

B. A Cloud Storage lifecycle rule.

C. The TRANSFORM clause in the CREATE MODEL statement, for example with ML.STANDARD_SCALER and ML.BUCKETIZE.

D. A Looker derived table.

BAHASA INDONESIA

Saat melatih model BigQuery ML, Anda menstandardisasi fitur numerik dan membuat bucket usia pelanggan. Anda ingin preprocessing yang persis sama diterapkan otomatis ketika ML.PREDICT dipanggil nanti, sehingga tidak pernah berbeda dari saat training. Apa yang sebaiknya digunakan?

A. Terapkan preprocessing secara manual di setiap query prediksi.

B. Lifecycle rule Cloud Storage.

C. Klausa TRANSFORM pada statement CREATE MODEL, misalnya dengan ML.STANDARD_SCALER dan ML.BUCKETIZE.

D. Derived table Looker.

✔ **Jawaban benar: C**

Kenapa benar: Klausa TRANSFORM menyimpan langkah feature engineering sebagai bagian dari model. Saat ML.EVALUATE atau ML.PREDICT dipanggil, transformasi yang sama diterapkan otomatis ke data mentah. Ini mencegah training-serving skew.

A salah: Preprocessing manual rawan berbeda dari training dan sulit dipelihara.

B salah: Lifecycle rule mengatur objek storage dan tidak terkait ML.

D salah: Derived table Looker adalah konsep BI, bukan bagian dari model ML.

Soal 30

Section 2 · Data Analysis & Presentation

ENGLISH

An e-commerce site has a BigQuery table of user_id, product_id, and the number of times each user viewed each product. It wants to recommend products each user is likely to be interested in, using only SQL. Which BigQuery ML model type and function should you use?

A. KMEANS, then ML.PREDICT

B. LINEAR_REG, then ML.EVALUATE only

C. ARIMA_PLUS, then ML.FORECAST

D. MATRIX_FACTORIZATION (with implicit feedback), then ML.RECOMMEND

BAHASA INDONESIA

Sebuah situs e-commerce punya tabel BigQuery berisi user_id, product_id, dan berapa kali setiap pengguna melihat setiap produk. Situs itu ingin merekomendasikan produk yang kemungkinan diminati setiap pengguna hanya dengan SQL. Tipe model dan fungsi BigQuery ML apa yang sebaiknya digunakan?

A. KMEANS, lalu ML.PREDICT

B. LINEAR_REG, lalu hanya ML.EVALUATE

C. ARIMA_PLUS, lalu ML.FORECAST

D. MATRIX_FACTORIZATION (dengan implicit feedback), lalu ML.RECOMMEND

✔ **Jawaban benar: D**

Kenapa benar: Matrix factorization adalah model rekomendasi (collaborative filtering) di BQML. Opsinya meliputi user_col, item_col, dan rating_col. Jumlah view adalah sinyal implicit feedback (feedback_type = 'IMPLICIT'), dan ML.RECOMMEND menghasilkan skor rekomendasi per pasangan pengguna dan produk.

A salah: K-means mengelompokkan data dan tidak menghasilkan rekomendasi item per pengguna.

B salah: Linear regression memprediksi angka dan bukan model rekomendasi. ML.EVALUATE pun hanya mengevaluasi, tidak menghasilkan rekomendasi.

C salah: ARIMA_PLUS untuk forecasting time series.

Soal 31

Section 2 · Data Analysis & Presentation

ENGLISH

A churn model in BigQuery ML flags a key customer as high risk. The account manager asks which features drove this specific prediction, for example tenure or support tickets. What should you use?

A. INFORMATION_SCHEMA.JOBS

B. ML.EVALUATE

C. ML.TRAINING_INFO

D. ML.EXPLAIN_PREDICT on that customer's row, to get feature attributions

BAHASA INDONESIA

Model churn di BigQuery ML menandai seorang pelanggan penting sebagai berisiko tinggi. Account manager bertanya fitur mana yang mendorong prediksi spesifik ini, misalnya lama berlangganan atau jumlah tiket support. Apa yang sebaiknya digunakan?

A. INFORMATION_SCHEMA.JOBS

B. ML.EVALUATE

C. ML.TRAINING_INFO

D. ML.EXPLAIN_PREDICT pada baris pelanggan tersebut, untuk mendapatkan atribusi fitur

✔ Jawaban benar: D

Kenapa benar: ML.EXPLAIN_PREDICT mengembalikan prediksi beserta atribusi fitur (explainable AI) per baris, sehingga Anda bisa menunjukkan kontribusi setiap fitur pada prediksi itu. Untuk kepentingan fitur secara global di seluruh model, gunakan ML.GLOBAL_EXPLAIN.

A salah: INFORMATION_SCHEMA.JOBS berisi metadata job query.

B salah: ML.EVALUATE memberi metrik performa model secara agregat, bukan penjelasan per baris.

C salah: ML.TRAINING_INFO menampilkan riwayat iterasi training, bukan alasan sebuah prediksi.

Soal 32

Section 2 · Data Analysis & Presentation

ENGLISH

A support team wants to find past tickets that are semantically similar to a new ticket. For example, "can't log in" should match "password reset not working". All 3 million tickets are stored in BigQuery, and the team wants to stay within SQL. What is the best approach?

A. Train a KMEANS model with 2 clusters.

B. Use LIKE '%login%' filters.

C. Use APPROX_COUNT_DISTINCT on the ticket text.

D. Create a remote model for a Google text-embedding endpoint, generate embeddings for the tickets with the BigQuery embedding function (AI.GENERATE_EMBEDDING; older name ML.GENERATE_EMBEDDING), and then use VECTOR_SEARCH, optionally with a vector index.

BAHASA INDONESIA

Tim support ingin menemukan tiket lama yang mirip secara makna dengan tiket baru. Misalnya "can't log in" harus cocok dengan "password reset not working". Semua 3 juta tiket ada di BigQuery, dan tim ingin tetap memakai SQL. Pendekatan terbaik?

A. Latih model KMEANS dengan 2 cluster.

B. Gunakan filter LIKE '%login%'.

C. Gunakan APPROX_COUNT_DISTINCT pada teks tiket.

D. Buat remote model untuk endpoint text-embedding Google, buat embedding tiket dengan fungsi embedding BigQuery (AI.GENERATE_EMBEDDING; nama lama ML.GENERATE_EMBEDDING), lalu gunakan VECTOR_SEARCH, opsional dengan vector index.

✔ Jawaban benar: D

Kenapa benar: Embedding mengubah teks menjadi vektor yang merepresentasikan makna. VECTOR_SEARCH mencari vektor terdekat (misalnya dengan cosine distance), sehingga tiket bermakna mirip ditemukan walaupun kata-katanya berbeda. Semuanya dilakukan di BigQuery melalui remote model ke model embedding Google.

A salah: Dua cluster terlalu kasar dan tidak memberi daftar tiket yang paling mirip untuk satu tiket baru.

B salah: LIKE hanya mencocokkan kata persis, sehingga sinonim dan parafrase tidak tertangkap.

C salah: Fungsi ini menghitung perkiraan jumlah nilai unik dan tidak terkait kemiripan makna.

Soal 33

Section 2 · Data Analysis & Presentation

ENGLISH

A data scientist who is fluent in pandas wants to analyze a 2 TB BigQuery table from a Colab Enterprise notebook. Loading it into the notebook's memory with pandas fails. They want a pandas-like Python API where the computation runs inside BigQuery. What should they use?

A. BigQuery DataFrames (bigframes)

B. Looker Studio

C. pandas.read_csv on an exported file

D. Cloud SQL

BAHASA INDONESIA

Seorang data scientist yang mahir pandas ingin menganalisis tabel BigQuery berukuran 2 TB dari notebook Colab Enterprise. Me-load tabel itu ke memori notebook dengan pandas selalu gagal. Ia ingin API Python mirip pandas yang komputasinya dijalankan di dalam BigQuery. Apa yang sebaiknya digunakan?

A. BigQuery DataFrames (bigframes)

B. Looker Studio

C. pandas.read_csv pada file hasil ekspor

D. Cloud SQL

✔ Jawaban benar: A

Kenapa benar: BigQuery DataFrames (paket bigframes) menyediakan API mirip pandas (bigframes.pandas) dan scikit-learn (bigframes.ml). Operasinya diterjemahkan menjadi SQL dan dijalankan di BigQuery, sehingga data besar tidak perlu ditarik ke memori notebook.

B salah: Looker Studio adalah tool dashboard, bukan API analisis Python.

C salah: Mengekspor 2 TB lalu membacanya dengan pandas tetap akan kehabisan memori dan boros waktu.

D salah: Memindahkan data ke Cloud SQL tidak membantu analisis skala besar.

Soal 34

Section 2 · Data Analysis & Presentation

ENGLISH

A trained BigQuery ML churn model should score all active customers every morning, and write the results into a table that a Looker dashboard reads. You want the simplest serverless solution. What should you do?

A. Export the model to Cloud Storage, and have analysts run it locally.

B. Deploy the model to a Compute Engine VM and call it from a cron job.

C. Retrain the model every morning, and use ML.TRAINING_INFO as the scores.

D. Create a BigQuery scheduled query that runs CREATE OR REPLACE TABLE ... AS SELECT * FROM ML.PREDICT(MODEL ..., (SELECT ... FROM active_customers)).

BAHASA INDONESIA

Sebuah model churn BigQuery ML yang sudah dilatih harus memberi skor ke semua pelanggan aktif setiap pagi, lalu menulis hasilnya ke tabel yang dibaca dashboard Looker. Anda ingin solusi serverless yang paling sederhana. Apa yang harus dilakukan?

A. Ekspor model ke Cloud Storage lalu biarkan analis menjalankannya di komputer lokal.

B. Deploy model ke VM Compute Engine lalu panggil dari cron job.

C. Latih ulang model setiap pagi dan pakai ML.TRAINING_INFO sebagai skor.

D. Buat BigQuery scheduled query yang menjalankan CREATE OR REPLACE TABLE ... AS SELECT * FROM ML.PREDICT(MODEL ..., (SELECT ... FROM active_customers)).

✔ **Jawaban benar: D**

Kenapa benar: Batch prediction di BQML cukup dengan ML.PREDICT dalam query. Menjadwalkannya sebagai scheduled query membuat hasil prediksi segar setiap pagi tanpa infrastruktur tambahan, dan dashboard Looker tinggal membaca tabel hasilnya.

A salah: Proses manual di lokal tidak otomatis dan berisiko.

B salah: VM dan cron menambah infrastruktur yang harus dikelola, padahal ML.PREDICT sudah tersedia di BigQuery.

C salah: ML.TRAINING_INFO berisi informasi training, bukan skor prediksi. Retrain harian juga belum tentu diperlukan.

Soal 35

Section 3 · Data Pipeline Orchestration

ENGLISH

A streaming pipeline reads temperature readings from Pub/Sub and must compute the average per sensor for every 5-minute period. Some readings arrive up to 2 minutes late because of weak mobile connections, and they must still be counted in the correct period. How should you implement this?

A. Use a BigQuery scheduled query every 5 minutes based on ingestion time.

B. In Dataflow, use fixed (tumbling) windows of 5 minutes based on event time, with an allowed lateness of at least 2 minutes and appropriate triggers.

C. Use a Pub/Sub BigQuery subscription, and ignore late data.

D. Use Cloud Scheduler to call a Cloud Run service every 5 minutes.

BAHASA INDONESIA

Sebuah pipeline streaming membaca data suhu dari Pub/Sub dan harus menghitung rata-rata per sensor untuk setiap periode 5 menit. Sebagian data datang terlambat hingga 2 menit karena koneksi seluler yang lemah, dan data itu tetap harus dihitung di periode yang benar. Bagaimana mengimplementasikannya?

A. Gunakan BigQuery scheduled query setiap 5 menit berbasis waktu ingestion.

B. Di Dataflow, gunakan fixed (tumbling) window 5 menit berbasis event time, dengan allowed lateness minimal 2 menit dan trigger yang sesuai.

C. Gunakan Pub/Sub BigQuery subscription dan abaikan data terlambat.

D. Gunakan Cloud Scheduler untuk memanggil service Cloud Run setiap 5 menit.

✔ **Jawaban benar: B**

Kenapa benar: Apache Beam di Dataflow mendukung windowing berbasis event time (waktu kejadian, bukan waktu tiba), watermark, allowed lateness, dan trigger. Fixed window 5 menit dengan allowed lateness memastikan data yang terlambat tetap masuk ke window yang benar.

A salah: Scheduled query berbasis waktu ingestion akan memasukkan data terlambat ke periode yang salah, dan latensinya lebih tinggi.

C salah: Mengabaikan data terlambat melanggar syarat, dan subscription BigQuery tidak melakukan agregasi window.

D salah: Anda harus membuat sendiri logika window dan penanganan data terlambat. Solusi ini tidak skalabel.

Soal 36

Section 3 · Data Pipeline Orchestration

ENGLISH

Your team created a Cloud Composer environment months ago. Today its only DAG runs a single BigQuery SQL statement once a day. Finance asks you to cut costs without losing functionality. What should you do?

A. Replace the DAG with a BigQuery scheduled query, and delete the Composer environment.

B. Move the SQL to a Dataproc cluster.

C. Run the SQL from a Compute Engine VM with cron.

D. Increase the Composer environment size so the job runs faster.

BAHASA INDONESIA

Tim Anda membuat environment Cloud Composer beberapa bulan lalu. Saat ini satu-satunya DAG di sana hanya menjalankan satu statement SQL BigQuery sekali sehari. Tim finance meminta Anda memangkas biaya tanpa kehilangan fungsi. Apa yang harus dilakukan?

A. Ganti DAG dengan BigQuery scheduled query, lalu hapus environment Composer.

B. Pindahkan SQL ke cluster Dataproc.

C. Jalankan SQL dari VM Compute Engine dengan cron.

D. Perbesar ukuran environment Composer agar job lebih cepat.

✔ Jawaban benar: A

Kenapa benar: Environment Composer memakai resource yang terus berjalan (dan terus ditagih) walaupun hanya ada satu task harian. Untuk satu SQL terjadwal, scheduled query bawaan BigQuery memberi fungsi yang sama tanpa biaya infrastruktur orkestrasi. Composer baru sepadan untuk pipeline multi-task yang kompleks.

B salah: Dataproc untuk Spark/Hadoop, tidak cocok dan lebih mahal untuk SQL BigQuery.

C salah: VM juga terus berjalan dan harus dikelola, jadi bukan penghematan yang terbaik.

D salah: Memperbesar environment justru menambah biaya.

Soal 37

Section 3 · Data Pipeline Orchestration

ENGLISH

You have a Workflows definition that calls three APIs to refresh a partner data feed. It must run every weekday at 06:00 Asia/Jakarta time. What is the simplest managed way to schedule it?

A. Create a Cloud Composer environment.

B. Create a Cloud Scheduler job, with a cron expression and time zone, that triggers a Workflows execution.

C. Use a Pub/Sub BigQuery subscription.

D. Use a BigQuery scheduled query to call the APIs.

BAHASA INDONESIA

Anda punya definisi Workflows yang memanggil tiga API untuk memperbarui feed data partner. Workflow harus berjalan setiap hari kerja pukul 06.00 waktu Asia/Jakarta. Cara managed paling sederhana untuk menjadwalkannya?

A. Buat environment Cloud Composer.

B. Buat job Cloud Scheduler dengan ekspresi cron dan zona waktu, yang memicu eksekusi Workflows.

C. Gunakan Pub/Sub BigQuery subscription.

D. Gunakan BigQuery scheduled query untuk memanggil API.

✔ Jawaban benar: B

Kenapa benar: Cloud Scheduler adalah cron managed yang mendukung zona waktu dan bisa langsung memicu eksekusi Workflows (dengan service account yang punya izin menjalankan workflow). Workflows sendiri tidak punya jadwal bawaan, sehingga pasangan Scheduler + Workflows adalah pola standar.

A salah: Composer berlebihan dan mahal hanya untuk menjadwalkan satu workflow.

C salah: Subscription itu menulis pesan Pub/Sub ke BigQuery dan tidak menjadwalkan apa pun.

D salah: Scheduled query menjalankan SQL dan tidak bisa memanggil API eksternal.

Soal 38

Section 3 · Data Pipeline Orchestration

ENGLISH

A Dataform table rebuilds a 10 TB fact table from scratch every hour, which is slow and expensive. New source rows are only ever appended, and each has an ingestion timestamp. You want each run to process only the new rows. What should you change?

A. Use type: "table" with a larger slot reservation.

B. Run the action less often, once a month.

C. Change the config to type: "view".

D. Change the table's config to type: "incremental", and add a WHERE condition inside ${when(incremental(), ...)} that selects only rows newer than the maximum timestamp already in the table.

BAHASA INDONESIA

Sebuah tabel Dataform membangun ulang tabel fakta 10 TB dari nol setiap jam, sehingga lambat dan mahal. Baris baru di sumber selalu hanya ditambahkan (append), dan masing-masing punya timestamp ingestion. Anda ingin setiap run hanya memproses baris baru. Apa yang harus diubah?

A. Gunakan type: "table" dengan slot reservation yang lebih besar.

B. Jalankan action lebih jarang, sebulan sekali.

C. Ubah config menjadi type: "view".

D. Ubah config tabel menjadi type: "incremental" dan tambahkan kondisi WHERE di dalam ${when(incremental(), ...)} yang hanya memilih baris yang lebih baru dari timestamp maksimum yang sudah ada di tabel.

✔ Jawaban benar: D

Kenapa benar: Tabel incremental di Dataform hanya memasukkan (atau, dengan uniqueKey, me-merge) baris baru pada run berikutnya. Fungsi when(incremental(), ...) menambahkan filter hanya ketika tabel sudah ada, sehingga run pertama tetap membangun tabel penuh.

A salah: Slot tambahan mempercepat proses tetapi tetap memproses ulang 10 TB setiap jam.

B salah: Menjalankan lebih jarang melanggar kebutuhan data yang segar.

C salah: View menghitung ulang seluruh data di setiap query, jadi biayanya pindah ke sisi pembaca.

Soal 39

Section 3 · Data Pipeline Orchestration

ENGLISH

A team has several existing PySpark batch scripts that run nightly. They want to run them on Google Cloud with minimal code changes, but they don't want to create, size, or manage any clusters. What should you recommend?

A. Run them on Cloud SQL.

B. Run the scripts as batch workloads on Dataproc Serverless (Serverless for Apache Spark).

C. Rewrite the scripts in Apache Beam for Dataflow.

D. Convert the scripts to LookML.

BAHASA INDONESIA

Sebuah tim punya beberapa skrip batch PySpark yang berjalan setiap malam. Mereka ingin menjalankannya di Google Cloud dengan perubahan kode minimal, tetapi tidak mau membuat, menentukan ukuran, atau mengelola cluster apa pun. Apa rekomendasi Anda?

A. Jalankan di Cloud SQL.

B. Jalankan skrip sebagai batch workload di Dataproc Serverless (Serverless for Apache Spark).

C. Tulis ulang skrip dengan Apache Beam untuk Dataflow.

D. Ubah skrip menjadi LookML.

✔ **Jawaban benar: B**

Kenapa benar: Dataproc Serverless (kini juga disebut Google Cloud Serverless for Apache Spark) menjalankan workload Spark (PySpark, Spark SQL, dan lainnya) tanpa cluster yang harus dikelola. Resource disediakan dan di-autoscale otomatis, dan Anda cukup mengirim batch job berisi skrip yang sudah ada.

A salah: Cloud SQL adalah database, bukan tempat menjalankan Spark.

C salah: Menulis ulang ke Beam berarti banyak perubahan kode, padahal syaratnya perubahan minimal.

D salah: LookML adalah bahasa pemodelan BI, bukan engine pemrosesan.

Soal 40

Section 3 · Data Pipeline Orchestration

ENGLISH

A push subscription delivers Pub/Sub messages to a Cloud Run service. A few malformed messages always fail, are redelivered endlessly, and waste resources. You want them set aside after several attempts so that they can be inspected later. What should you configure?

A. Configure a dead-letter topic on the subscription, with a maximum number of delivery attempts, and grant the Pub/Sub service agent the required permissions.

B. Delete the subscription every hour.

C. Reduce the message retention to 10 minutes.

D. Switch to a BigQuery subscription.

BAHASA INDONESIA

Sebuah push subscription mengirim pesan Pub/Sub ke service Cloud Run. Beberapa pesan rusak selalu gagal diproses, dikirim ulang tanpa henti, dan membuang resource. Anda ingin pesan seperti itu disisihkan setelah beberapa kali percobaan agar bisa diperiksa nanti. Apa yang harus dikonfigurasi?

A. Konfigurasikan dead-letter topic pada subscription dengan jumlah maksimum delivery attempt, dan beri service agent Pub/Sub izin yang diperlukan.

B. Hapus subscription setiap jam.

C. Kurangi message retention menjadi 10 menit.

D. Ganti ke BigQuery subscription.

✔ **Jawaban benar: A**

Kenapa benar: Fitur dead-letter topic di Pub/Sub memindahkan pesan yang gagal di-acknowledge setelah N kali percobaan (bisa diatur dari 5 sampai 100) ke topic terpisah. Pesan normal tetap berjalan, dan pesan bermasalah bisa dianalisis atau diproses ulang. Service agent Pub/Sub perlu izin publish ke dead-letter topic dan subscribe ke subscription sumber.

B salah: Menghapus subscription menghilangkan semua pesan yang belum diproses.

C salah: Retensi pendek membuat pesan hilang tanpa jejak, termasuk pesan valid yang tertunda.

D salah: Mengganti tujuan ke BigQuery tidak menyelesaikan masalah pemrosesan di Cloud Run.

Soal 41

Section 3 · Data Pipeline Orchestration

ENGLISH

A Dataflow job consumes from a Pub/Sub subscription. You want the on-call team to be alerted if the job stops keeping up, for example when messages wait in the subscription for more than 10 minutes. What should you configure?

A. A BigQuery scheduled query that counts rows

B. A Looker Studio report that refreshes daily

C. A Cloud Monitoring alerting policy on the subscription's oldest unacknowledged message age metric, with a 10-minute threshold

D. A Cloud Storage lifecycle rule

BAHASA INDONESIA

Sebuah job Dataflow mengonsumsi pesan dari subscription Pub/Sub. Anda ingin tim on-call mendapat alert jika job tidak lagi sanggup mengikuti, misalnya saat pesan menunggu di subscription lebih dari 10 menit. Apa yang harus dikonfigurasi?

A. BigQuery scheduled query yang menghitung baris

B. Laporan Looker Studio yang refresh setiap hari

C. Alerting policy Cloud Monitoring pada metrik umur pesan unacknowledged tertua di subscription, dengan threshold 10 menit

D. Lifecycle rule Cloud Storage

✔ Jawaban benar: C

Kenapa benar: Pub/Sub mengekspor metrik ke Cloud Monitoring, termasuk subscription/oldest_unacked_message_age dan num_undelivered_messages (backlog). Alerting policy dengan threshold dan notification channel memberi peringatan otomatis saat consumer tertinggal. Di sisi Dataflow, metrik system lag dan data freshness juga bisa dipakai.

A salah: Menghitung baris di BigQuery tidak langsung mengukur backlog dan tidak memberi alert real-time.

B salah: Refresh harian terlalu lambat dan bukan mekanisme alert.

D salah: Lifecycle rule mengatur objek storage dan tidak berkaitan dengan monitoring.

Soal 42

Section 3 · Data Pipeline Orchestration

ENGLISH

Whenever an external team's load job finishes writing to the BigQuery table raw.orders, you must automatically start a Workflows execution that runs data validation and then refreshes downstream tables. The external team cannot change its process. What should you set up?

A. A Transfer Appliance

B. An Eventarc trigger that uses Cloud Audit Logs for BigQuery job-completion events on that table, with the workflow as the destination

C. A Cloud Scheduler job every minute that polls the table's last-modified time

D. A Pub/Sub BigQuery subscription

BAHASA INDONESIA

Setiap kali load job milik tim eksternal selesai menulis ke tabel BigQuery raw.orders, Anda harus otomatis memulai eksekusi Workflows yang menjalankan validasi data lalu memperbarui tabel hilir. Tim eksternal tidak bisa mengubah prosesnya. Apa yang harus disiapkan?

A. Transfer Appliance

B. Trigger Eventarc yang memakai Cloud Audit Logs untuk event penyelesaian job BigQuery pada tabel tersebut, dengan workflow sebagai tujuan

C. Job Cloud Scheduler setiap menit yang memeriksa waktu modifikasi terakhir tabel

D. Pub/Sub BigQuery subscription

✔ Jawaban benar: B

Kenapa benar: Eventarc bisa memicu target (termasuk Workflows, Cloud Run, dan functions) berdasarkan entri Cloud Audit Logs dari layanan Google Cloud, termasuk job BigQuery yang selesai. Ini desain event-driven tanpa polling dan tanpa mengubah proses tim lain. Trigger memfilter serviceName bigquery.googleapis.com dan methodName yang sesuai, dan workflow bisa memeriksa nama tabel di payload event sebelum melanjutkan.

A salah: Transfer Appliance adalah perangkat migrasi fisik.

C salah: Polling menambah jeda dan biaya, dan logika deteksinya harus dibuat sendiri.

D salah: Subscription ini menulis pesan Pub/Sub ke BigQuery, bukan memicu workflow saat tabel berubah.

Soal 43 CHOOSE TWO

Section 3 · Data Pipeline Orchestration

ENGLISH

Your SQL transformations are managed in a Dataform repository. Which TWO are valid ways to run the Dataform workflow automatically every day? (Choose two.)

A. Create a Pub/Sub BigQuery subscription.

B. Trigger the Dataform workflow from a Cloud Composer DAG (with the Dataform operators) or from Workflows, scheduled with Cloud Scheduler.

C. Order a Transfer Appliance.

D. Schedule a Looker dashboard delivery.

E. Create a Dataform workflow configuration with a daily schedule, linked to a release configuration.

BAHASA INDONESIA

Transformasi SQL Anda dikelola di repository Dataform. DUA cara mana yang valid untuk menjalankan workflow Dataform secara otomatis setiap hari? (Pilih dua.)

A. Buat Pub/Sub BigQuery subscription.

B. Picu workflow Dataform dari DAG Cloud Composer (dengan operator Dataform) atau dari Workflows yang dijadwalkan dengan Cloud Scheduler.

C. Pesan Transfer Appliance.

D. Jadwalkan pengiriman dashboard Looker.

E. Buat workflow configuration Dataform dengan jadwal harian yang terhubung ke release configuration.

✔ **Jawaban benar: B, E**

Kenapa benar: Dataform punya penjadwalan bawaan. Release configuration meng-compile kode dari branch tertentu, lalu workflow configuration menjalankan action terpilih sesuai jadwal cron. Dataform juga bisa dipicu dari orkestrator eksternal seperti Cloud Composer (operator Dataform di Airflow) atau Workflows + Cloud Scheduler bila pipeline-nya melibatkan langkah lain.

A salah: Pub/Sub BigQuery subscription untuk ingest pesan dan tidak menjalankan Dataform.

C salah: Transfer Appliance tidak terkait penjadwalan.

D salah: Pengiriman dashboard hanya mengirim laporan dan tidak menjalankan transformasi.

Soal 44

Section 3 · Data Pipeline Orchestration

ENGLISH

A nightly Dataflow batch job failed with the status "Failed". You need to find the stack trace that explains which transform threw an exception. Where should you look?

A. The IAM policy of the project

B. The Cloud Storage bucket's storage class

C. The BigQuery table schema

D. The job's logs in the Dataflow monitoring UI (job logs and worker logs, backed by Cloud Logging)

BAHASA INDONESIA

Sebuah job batch Dataflow malam gagal dengan status "Failed". Anda perlu menemukan stack trace yang menjelaskan transform mana yang melempar exception. Di mana sebaiknya melihat?

A. Kebijakan IAM project

B. Storage class bucket Cloud Storage

C. Skema tabel BigQuery

D. Log job di UI monitoring Dataflow (job log dan worker log, yang berasal dari Cloud Logging)

✔ Jawaban benar: D

Kenapa benar: Dataflow mengirim job message dan worker log ke Cloud Logging. Panel log di UI job Dataflow menampilkannya per langkah, termasuk error dan stack trace dari worker. Anda juga bisa memfilter langsung di Logs Explorer berdasarkan job ID. Job graph membantu melihat langkah mana yang gagal.

A salah: IAM policy bisa menjadi penyebab error izin, tetapi tempat melihat detail error-nya tetap di log.

B salah: Storage class tidak berisi informasi error pipeline.

C salah: Skema tabel mungkin relevan sebagai penyebab, tetapi tidak menunjukkan stack trace error.

Soal 45

Section 3 · Data Pipeline Orchestration

ENGLISH

Every night, an analyst exports two large BigQuery tables to Cloud Storage, runs a Spark job on Dataproc to join and aggregate them, and loads the result back into BigQuery. The logic is a simple join with GROUP BY. You want to simplify the pipeline and reduce cost and operational effort. What should you do?

A. Use Transfer Appliance to move the exports.

B. Move both tables to Cloud SQL.

C. Replace it with a single SQL transformation in BigQuery (ELT), scheduled as a scheduled query or a Dataform action.

D. Keep the pipeline, but use a bigger Dataproc cluster.

BAHASA INDONESIA

Setiap malam seorang analis mengekspor dua tabel BigQuery besar ke Cloud Storage, menjalankan job Spark di Dataproc untuk men-join dan mengagregasinya, lalu me-load hasilnya kembali ke BigQuery. Logikanya hanya join sederhana dengan GROUP BY. Anda ingin menyederhanakan pipeline dan mengurangi biaya serta usaha operasional. Apa yang harus dilakukan?

A. Gunakan Transfer Appliance untuk memindahkan hasil ekspor.

B. Pindahkan kedua tabel ke Cloud SQL.

C. Ganti dengan satu transformasi SQL di BigQuery (ELT), dijadwalkan sebagai scheduled query atau action Dataform.

D. Pertahankan pipeline tetapi gunakan cluster Dataproc yang lebih besar.

✔ Jawaban benar: C

Kenapa benar: Data sudah ada di BigQuery, dan join plus agregasi adalah kekuatan utama BigQuery SQL. Mengekspor data, memprosesnya di Spark, lalu memuatnya kembali hanya menambah biaya dan titik kegagalan. Pola ELT di dalam BigQuery lebih sederhana, serverless, dan biasanya lebih cepat.

A salah: Transfer Appliance untuk migrasi on-premises. Data ini sudah ada di cloud.

B salah: Cloud SQL tidak cocok untuk join analitik pada tabel besar.

D salah: Cluster lebih besar menambah biaya tanpa menghapus langkah ekspor dan import yang tidak perlu.

Soal 46

Section 4 · Data Management

ENGLISH

Auditors need to list BigQuery datasets and tables and read their metadata (schemas, row counts) in a project, but they must NOT be able to read any table data. No predefined role exactly matches this set of permissions in your organization's policy review. What is the best approach that follows least privilege?

A. Grant roles/bigquery.dataViewer.

B. Grant roles/owner for one day.

C. Grant roles/bigquery.metadataViewer, or create a custom role with only the needed metadata permissions if a tighter set is required.

D. Grant roles/bigquery.admin.

BAHASA INDONESIA

Auditor perlu melihat daftar dataset dan tabel BigQuery serta membaca metadatanya (skema, jumlah baris) di sebuah project, tetapi TIDAK boleh membaca data tabel apa pun. Dalam review kebijakan organisasi Anda, tidak ada predefined role yang persis cocok dengan kumpulan izin ini. Pendekatan terbaik yang mengikuti least privilege?

A. Beri roles/bigquery.dataViewer.

B. Beri roles/owner selama satu hari.

C. Beri roles/bigquery.metadataViewer, atau buat custom role berisi izin metadata yang diperlukan saja jika butuh izin yang lebih ketat.

D. Beri roles/bigquery.admin.

✔ Jawaban benar: C

Kenapa benar: BigQuery Metadata Viewer memberi akses ke metadata dataset dan tabel tanpa izin membaca data (tidak ada bigquery.tables.getData). Jika organisasi butuh izin yang lebih sempit lagi, custom role IAM memungkinkan Anda memilih permission satu per satu. Inilah penerapan least privilege.

A salah: Data Viewer bisa membaca isi tabel, sehingga melanggar syarat.

B salah: Owner adalah basic role yang sangat luas. Pembatasan waktu tidak menjadikannya least privilege.

D salah: Admin memberi kontrol penuh, termasuk membaca dan menghapus data.

Soal 47 CHOOSE TWO

Section 4 · Data Management

ENGLISH

A Dataflow streaming job reads from the Pub/Sub subscription orders-sub and writes to the BigQuery dataset sales. Security requires least privilege and no use of the default Compute Engine service account. Which TWO actions should you take? (Choose two.)

A. Grant that service account roles/pubsub.subscriber on orders-sub, and roles/bigquery.dataEditor on the sales dataset.

B. Make the BigQuery dataset public.

C. Grant the default Compute Engine service account roles/editor on the project.

D. Grant all developers roles/owner so the job never fails because of permissions.

E. Create a dedicated service account for the Dataflow workers, and run the job with it (it also needs roles/dataflow.worker).

BAHASA INDONESIA

Sebuah job streaming Dataflow membaca dari subscription Pub/Sub orders-sub dan menulis ke dataset BigQuery sales. Tim keamanan mewajibkan least privilege dan melarang pemakaian default Compute Engine service account. DUA tindakan mana yang harus dilakukan? (Pilih dua.)

A. Beri service account tersebut roles/pubsub.subscriber pada orders-sub dan roles/bigquery.dataEditor pada dataset sales.

B. Jadikan dataset BigQuery publik.

C. Beri default Compute Engine service account roles/editor di project.

D. Beri semua developer roles/owner agar job tidak pernah gagal karena izin.

E. Buat service account khusus untuk worker Dataflow dan jalankan job dengannya (akun ini juga perlu roles/dataflow.worker).

✔ **Jawaban benar: A, E**

Kenapa benar: Praktik terbaiknya adalah memakai worker service account khusus (user-managed) per pipeline, lalu memberinya role yang sempit di level resource. Role yang diperlukan: Dataflow Worker, Pub/Sub Subscriber hanya pada subscription itu, dan BigQuery Data Editor hanya pada dataset tujuan. Untuk menjalankan query atau load job mungkin juga dibutuhkan bigquery.jobUser di project.

B salah: Dataset publik membuka data ke siapa pun dan tidak ada hubungannya dengan izin pipeline.

C salah: Editor di level project terlalu luas, dan syaratnya melarang default service account.

D salah: Owner untuk semua orang bertentangan langsung dengan least privilege.

Soal 48

Section 4 · Data Management

ENGLISH

A single BigQuery table, sales, contains transactions for all countries. Country managers must query the same table, but each must see only the rows for their own country. Analysts in headquarters must see all rows. You don't want to maintain one copy of the table per country. What should you implement?

A. Separate datasets per country, each holding a copied table

B. Row-level security: row access policies on sales with filters such as country = 'ID', each granted to the matching manager group, plus a policy with TRUE for headquarters

C. Customer-managed encryption keys per country

D. Column-level security with policy tags on the country column

BAHASA INDONESIA

Satu tabel BigQuery, sales, berisi transaksi semua negara. Manajer negara harus meng-query tabel yang sama, tetapi masing-masing hanya boleh melihat baris negaranya sendiri. Analis di kantor pusat harus melihat semua baris. Anda tidak ingin memelihara satu salinan tabel per negara. Apa yang harus diimplementasikan?

A. Dataset terpisah per negara, masing-masing berisi salinan tabel

B. Row-level security: row access policy pada sales dengan filter seperti country = 'ID', masing-masing diberikan ke grup manajer yang sesuai, ditambah policy TRUE untuk kantor pusat

C. Customer-managed encryption key per negara

D. Column-level security dengan policy tag pada kolom country

✔ **Jawaban benar: B**

Kenapa benar: Row access policy (CREATE ROW ACCESS POLICY ... GRANT TO (...) FILTER USING (...)) menyaring baris yang dikembalikan sesuai identitas pengguna, pada tabel yang sama. Grup yang perlu melihat semua data cukup diberi policy dengan FILTER USING (TRUE).

A salah: Menyalin tabel per negara menambah biaya storage dan pemeliharaan, sesuatu yang ingin dihindari.

C salah: Enkripsi melindungi data at rest dan tidak menyaring baris per pengguna.

D salah: Policy tag membatasi akses ke kolom, bukan memilih baris tertentu.

Soal 49

Section 4 · Data Management

ENGLISH

A customers table contains an email column. Marketing analysts must be able to run queries that join and group on that column, but they must never see the real email values. A small privacy team must see the real values. What should you implement in BigQuery?

A. Remove the email column from the table.

B. Create a view for each analyst.

C. Make the dataset private, so no one can read it.

D. Attach a policy tag to the column with a data masking rule (for example, a hash), grant analysts the Masked Reader role, and grant the privacy team Fine-Grained Reader.

BAHASA INDONESIA

Tabel customers berisi kolom email. Analis marketing harus bisa menjalankan query yang melakukan join dan group pada kolom itu, tetapi tidak boleh melihat nilai email asli. Tim privasi yang kecil harus melihat nilai aslinya. Apa yang harus diimplementasikan di BigQuery?

A. Hapus kolom email dari tabel.

B. Buat view untuk setiap analis.

C. Jadikan dataset privat agar tidak ada yang bisa membacanya.

D. Pasang policy tag pada kolom dengan aturan data masking (misalnya hash), beri analis role Masked Reader, dan beri tim privasi role Fine-Grained Reader.

✔ Jawaban benar: D

Kenapa benar: Dynamic data masking di BigQuery dibangun di atas policy tag. Pengguna dengan role Masked Reader melihat nilai yang disamarkan (misalnya hash SHA-256), dan hash itu tetap konsisten sehingga join dan GROUP BY tetap bisa dilakukan. Pemegang Fine-Grained Reader melihat nilai asli. Satu tabel melayani dua kebutuhan.

A salah: Menghapus kolom membuat join dan grouping mustahil, dan tim privasi juga kehilangan datanya.

B salah: Membuat view per analis sulit dikelola dan tidak ditegakkan di level kolom.

C salah: Ini memblokir semua akses, termasuk kebutuhan analis yang sah.

Soal 50

Section 4 · Data Management

ENGLISH

An external auditor without a Google account needs to download one 3 GB report from a private Cloud Storage bucket within the next 24 hours. Afterward, access must stop automatically. What should you do?

A. Grant allUsers roles/storage.objectViewer on the bucket.

B. Email the file as an attachment.

C. Make the bucket public for 24 hours.

D. Generate a V4 signed URL for that object with a 24-hour expiration, and send it to the auditor.

BAHASA INDONESIA

Seorang auditor eksternal tanpa akun Google perlu mengunduh satu laporan 3 GB dari bucket Cloud Storage privat dalam 24 jam ke depan. Setelah itu akses harus berhenti otomatis. Apa yang harus dilakukan?

A. Beri allUsers roles/storage.objectViewer pada bucket.

B. Kirim file sebagai lampiran email.

C. Jadikan bucket publik selama 24 jam.

D. Buat V4 signed URL untuk objek tersebut dengan masa berlaku 24 jam, lalu kirimkan ke auditor.

✔ **Jawaban benar: D**

Kenapa benar: Signed URL memberi akses berbatas waktu ke satu objek tanpa perlu akun Google. Masa berlakunya maksimal 7 hari (604.800 detik) untuk V4, jadi 24 jam masih bisa. Setelah kedaluwarsa, URL tidak berlaku lagi tanpa langkah manual apa pun.

A salah: allUsers berarti akses publik ke seluruh bucket tanpa batas waktu.

B salah: File 3 GB melebihi batas lampiran email dan tidak bisa dikontrol setelah terkirim.

C salah: Bucket publik membuka semua objek ke siapa saja, dan Anda harus ingat menutupnya kembali.

Soal 51

Section 4 · Data Management

ENGLISH

You publish a curated BigQuery dataset to partner organizations. Partners must be able to query it in their own projects, but the contract forbids them from copying or exporting the data out of the shared view. What should you use?

A. Publish a listing in BigQuery sharing (formerly Analytics Hub) with data egress restrictions enabled, so subscribers query a linked dataset.

B. Export the data to CSV, and email it to the partners.

C. Grant the partners roles/bigquery.dataOwner on the dataset.

D. Copy the dataset into each partner's project every day.

BAHASA INDONESIA

Anda memublikasikan dataset BigQuery yang sudah dikurasi ke organisasi partner. Partner harus bisa meng-query dari project mereka sendiri, tetapi kontrak melarang mereka menyalin atau mengekspor data dari tampilan yang dibagikan. Apa yang harus digunakan?

A. Publikasikan listing di BigQuery sharing (dulu Analytics Hub) dengan data egress restriction aktif, sehingga subscriber meng-query linked dataset.

B. Ekspor data ke CSV lalu email ke partner.

C. Beri partner roles/bigquery.dataOwner pada dataset.

D. Salin dataset ke project setiap partner setiap hari.

✔ **Jawaban benar: A**

Kenapa benar: BigQuery sharing (Analytics Hub) membagikan data tanpa menyalinnya. Subscriber mendapat linked dataset read-only di project mereka sendiri. Listing bisa diberi pembatasan egress yang mencegah copy, ekspor, atau penulisan hasil query ke tabel lain, sesuai kebutuhan kontrak.

B salah: File CSV keluar sepenuhnya dari kontrol Anda dan melanggar larangan ekspor.

C salah: Data Owner memberi kontrol penuh, termasuk mengubah dan menghapus data.

D salah: Menyalin data justru dilarang, dan juga boros storage serta tenaga.

Soal 52

Section 4 · Data Management

ENGLISH

Object Versioning is enabled on a bucket to protect against accidental overwrites. Storage costs keep growing because old versions pile up. Policy: keep at most 3 older versions of each object, and delete any noncurrent version 30 days after it became noncurrent. What should you configure?

A. A retention policy of 30 days

B. Lifecycle Delete rules with the conditions numNewerVersions: 3 and daysSinceNoncurrentTime: 30, applied to noncurrent objects

C. Disable versioning and delete the bucket.

D. An Autoclass setting

BAHASA INDONESIA

Object Versioning diaktifkan pada sebuah bucket untuk melindungi dari overwrite tidak sengaja. Biaya storage terus naik karena versi lama menumpuk. Kebijakannya: simpan maksimal 3 versi lama untuk setiap objek, dan hapus versi noncurrent 30 hari setelah menjadi noncurrent. Apa yang harus dikonfigurasi?

A. Retention policy 30 hari

B. Lifecycle rule Delete dengan kondisi numNewerVersions: 3 dan daysSinceNoncurrentTime: 30, diterapkan ke objek noncurrent

C. Matikan versioning dan hapus bucket.

D. Pengaturan Autoclass

✔ **Jawaban benar: B**

Kenapa benar: Lifecycle management punya kondisi khusus untuk versi noncurrent. numNewerVersions menghapus versi yang sudah punya N versi lebih baru, dan daysSinceNoncurrentTime menghapus versi setelah N hari menjadi noncurrent. Pakai dua rule terpisah (rule-rule di-OR). Versi live tidak tersentuh.

A salah: Retention policy mencegah penghapusan, kebalikan dari yang dibutuhkan.

C salah: Menghapus bucket menghilangkan semua data, termasuk versi live.

D salah: Autoclass memindahkan kelas storage tetapi tidak menghapus versi lama.

Soal 53

Section 4 · Data Management

ENGLISH

Log files in a Standard-class bucket are read often during their first month, rarely for the rest of the quarter, almost never for the rest of the year, and must be kept for 7 years for compliance. The access pattern is predictable, and you want to minimize storage cost. Which lifecycle configuration fits best?

A. SetStorageClass to Nearline at age 30 days, to Coldline at age 90 days, to Archive at age 365 days, and Delete at about 7 years (2555 days)

B. Delete objects at age 30 days.

C. Move everything to Archive on day 1.

D. Keep everything in Standard forever.

BAHASA INDONESIA

File log di bucket kelas Standard sering dibaca pada bulan pertama, jarang dibaca selama sisa kuartal, hampir tidak pernah dibaca selama sisa tahun, dan harus disimpan 7 tahun untuk kepatuhan. Pola aksesnya bisa diprediksi, dan Anda ingin meminimalkan biaya storage. Konfigurasi lifecycle mana yang paling cocok?

A. SetStorageClass ke Nearline pada umur 30 hari, ke Coldline pada umur 90 hari, ke Archive pada umur 365 hari, dan Delete pada sekitar 7 tahun (2555 hari)

B. Hapus objek pada umur 30 hari.

C. Pindahkan semua ke Archive di hari pertama.

D. Simpan semua di Standard selamanya.

✔ **Jawaban benar: A**

Kenapa benar: Karena polanya bisa diprediksi, lifecycle rule berbasis umur (Age) dengan SetStorageClass bertahap adalah solusi paling murah. Ambang 30/90/365 hari sejalan dengan durasi penyimpanan minimum Nearline (30), Coldline (90) dan Archive (365), sehingga biaya penghapusan dini bisa dihindari. Rule Delete menegakkan retensi 7 tahun.

B salah: Menghapus di hari ke-30 melanggar retensi 7 tahun.

C salah: Pada bulan pertama data sering dibaca. Archive mengenakan biaya retrieval tinggi dan minimum 365 hari.

D salah: Standard paling mahal untuk data yang jarang diakses.

Soal 54

Section 4 · Data Management

ENGLISH

A BigQuery table holds 5 years of history in ingestion-time partitions. Partitions older than a few months are never modified, but they are still queried occasionally. Someone proposes exporting old partitions to Cloud Storage Coldline to save money. What is the best response?

A. Export immediately, because BigQuery storage costs the same regardless of age.

B. Keep the data in BigQuery, because partitions that are not modified for 90 consecutive days automatically move to long-term storage pricing (about 50% cheaper) and remain fully queryable.

C. Delete partitions older than 90 days.

D. Copy the table to Cloud SQL.

BAHASA INDONESIA

Sebuah tabel BigQuery menyimpan histori 5 tahun dalam partisi berbasis ingestion time. Partisi yang lebih tua dari beberapa bulan tidak pernah diubah, tetapi sesekali masih di-query. Seseorang mengusulkan untuk mengekspor partisi lama ke Cloud Storage Coldline agar hemat. Tanggapan terbaik?

A. Segera ekspor, karena biaya storage BigQuery sama berapa pun umurnya.

B. Simpan data di BigQuery, karena partisi yang tidak diubah selama 90 hari berturut-turut otomatis mendapat harga long-term storage (sekitar 50% lebih murah) dan tetap bisa di-query sepenuhnya.

C. Hapus partisi yang lebih tua dari 90 hari.

D. Salin tabel ke Cloud SQL.

✔ Jawaban benar: B

Kenapa benar: BigQuery otomatis menerapkan harga long-term storage untuk tabel atau partisi yang tidak dimodifikasi selama 90 hari berturut-turut, kira-kira setengah harga active storage. Performa, durabilitas, dan cara query tetap sama. Mengekspor ke Coldline menambah kerumitan (external table, biaya retrieval) demi penghematan yang mungkin kecil.

A salah: Pernyataannya salah, karena long-term storage memang lebih murah.

C salah: Data masih dibutuhkan untuk query sesekali, jadi tidak boleh dihapus.

D salah: Cloud SQL lebih mahal dan tidak cocok untuk histori analitik besar.

Soal 55

Section 4 · Data Management

ENGLISH

After a revenue figure in a dashboard turned out wrong, leadership asks you to quickly see which upstream tables and jobs feed the BigQuery table finance.revenue_daily, and which downstream tables depend on it. What should you use?

A. Data lineage in Dataplex (now Knowledge Catalog), which automatically records lineage for BigQuery jobs

B. BigQuery table snapshots

C. Cloud Storage Object Versioning

D. Cloud SQL read replicas

BAHASA INDONESIA

Setelah angka revenue di dashboard ternyata salah, pimpinan meminta Anda segera melihat tabel dan job hulu mana saja yang mengisi tabel BigQuery finance.revenue_daily, serta tabel hilir mana yang bergantung padanya. Apa yang harus digunakan?

A. Data lineage di Dataplex (kini Knowledge Catalog), yang otomatis mencatat lineage dari job BigQuery

B. Table snapshot BigQuery

C. Object Versioning Cloud Storage

D. Read replica Cloud SQL

✔ Jawaban benar: A

Kenapa benar: Ketika Data Lineage API diaktifkan, lineage untuk job BigQuery (query, copy, load) dicatat otomatis dan ditampilkan sebagai graf hulu-hilir di konsol BigQuery dan Dataplex (Knowledge Catalog). Ini memudahkan analisis dampak dan pencarian akar masalah data.

B salah: Snapshot menyimpan salinan titik waktu, bukan alur data.

C salah: Versioning menyimpan versi objek di bucket dan tidak memetakan ketergantungan antar tabel.

D salah: Read replica untuk skala baca database operasional.

Soal 56 CHOOSE TWO

Section 4 · Data Management

ENGLISH

You enabled high availability (HA, regional) on a Cloud SQL for MySQL instance. Which TWO statements are true? (Choose two.)

A. HA places the standby in a different region for disaster recovery.

B. HA replaces the need for backups, because data can never be lost.

C. The standby can serve read-only queries to offload reporting traffic.

D. A standby instance runs in a different zone of the same region, and data is replicated synchronously to it.

E. If the primary zone fails, Cloud SQL fails over automatically, and clients keep using the same IP address.

BAHASA INDONESIA

Anda mengaktifkan high availability (HA, regional) pada instance Cloud SQL for MySQL. DUA pernyataan mana yang benar? (Pilih dua.)

A. HA menempatkan standby di region lain untuk disaster recovery.

B. HA menggantikan kebutuhan backup karena data tidak mungkin hilang.

C. Standby bisa melayani query read-only untuk mengurangi beban laporan.

D. Instance standby berjalan di zona lain dalam region yang sama, dan data direplikasi secara sinkron ke sana.

E. Jika zona primary gagal, Cloud SQL melakukan failover otomatis dan klien tetap memakai alamat IP yang sama.

✔ **Jawaban benar: D, E**

Kenapa benar: Konfigurasi HA Cloud SQL memakai primary dan standby di zona berbeda dalam satu region, dengan replikasi sinkron ke persistent disk regional. Saat failover, standby mengambil alih, dan IP statis yang sama tetap dipakai sehingga aplikasi tidak perlu diubah.

A salah: Standby ada di region yang sama. DR lintas region memakai cross-region read replica.

B salah: HA tidak melindungi dari kesalahan logis (misalnya DELETE tidak sengaja), jadi backup dan PITR tetap diperlukan.

C salah: Standby HA tidak melayani traffic baca. Untuk itu gunakan read replica.

Soal 57

Section 4 · Data Management

ENGLISH

A media company serves static assets and dataset downloads to users across North America and Europe. Data must stay available even if a whole region has an outage, and the team wants the simplest configuration, with no specific requirement on which exact regions are used. Which bucket location type should you choose?

A. Single region in us-central1

B. Multi-region (for example US or EU), or a dual-region if specific regions are required

C. A zonal persistent disk

D. A Cloud SQL instance

BAHASA INDONESIA

Sebuah perusahaan media menyajikan aset statis dan unduhan dataset ke pengguna di Amerika Utara dan Eropa. Data harus tetap tersedia walaupun satu region mengalami gangguan total, dan tim ingin konfigurasi paling sederhana tanpa syarat region spesifik. Tipe lokasi bucket mana yang sebaiknya dipilih?

A. Single region di us-central1

B. Multi-region (misalnya US atau EU), atau dual-region jika butuh region spesifik

C. Persistent disk zonal

D. Instance Cloud SQL

✔ Jawaban benar: B

Kenapa benar: Bucket multi-region menyimpan data secara redundan di beberapa region dalam satu area geografis besar, sehingga tetap tersedia saat satu region gagal. Konfigurasinya paling sederhana bila Anda tidak perlu memilih region tertentu. Dual-region cocok bila Anda harus menentukan dua region spesifik atau butuh turbo replication.

A salah: Single region tidak bertahan saat region itu mengalami outage.

C salah: Persistent disk zonal adalah block storage untuk VM, bukan untuk distribusi file publik.

D salah: Cloud SQL adalah database relasional, bukan penyimpanan file statis.

Soal 58

Section 4 · Data Management

ENGLISH

Sensitive BigQuery tables are protected with a customer-managed encryption key (CMEK) in Cloud KMS. During a security incident, the CISO wants to immediately make the data unreadable without deleting the tables, and keep the ability to restore access later. What should you do?

A. Delete the BigQuery dataset.

B. Disable the Cloud KMS key version used by the tables, and re-enable it later to restore access.

C. Rotate the key, which immediately re-encrypts all data.

D. Switch the tables to Google-managed encryption.

BAHASA INDONESIA

Tabel BigQuery yang sensitif dilindungi customer-managed encryption key (CMEK) di Cloud KMS. Saat terjadi insiden keamanan, CISO ingin data langsung tidak bisa dibaca tanpa menghapus tabel, dan tetap bisa memulihkan akses nanti. Apa yang harus dilakukan?

A. Hapus dataset BigQuery.

B. Nonaktifkan (disable) key version Cloud KMS yang dipakai tabel, lalu aktifkan kembali nanti untuk memulihkan akses.

C. Rotasi key, yang langsung mengenkripsi ulang semua data.

D. Ubah tabel ke enkripsi Google-managed.

✔ Jawaban benar: B

Kenapa benar: Dengan CMEK, Anda mengendalikan key. Men-disable key version membuat data yang dilindunginya tidak bisa diakses (efeknya bisa butuh beberapa saat untuk menyebar), dan men-enable kembali memulihkan akses. Menghancurkan (destroy) key version bersifat permanen setelah masa scheduled-destruction, jadi tidak cocok bila akses ingin dipulihkan.

A salah: Menghapus dataset menghilangkan data, padahal yang diminta adalah akses yang bisa dipulihkan.

C salah: Rotasi membuat versi key baru untuk data baru. Data lama tidak otomatis dienkripsi ulang, dan aksesnya juga tidak dicabut.

D salah: Pindah ke Google-managed key justru membuat data tetap bisa dibaca dan menghilangkan kontrol Anda.

Soal 59 CHOOSE TWO

Section 4 · Data Management

ENGLISH

A new compliance officer asks how data is encrypted in BigQuery and Cloud Storage. Which TWO statements are correct? (Choose two.)

A. Disabling a CMEK key has no effect on access to the data it protects.

B. You must enable CMEK, otherwise data at rest is stored unencrypted.

C. BigQuery supports customer-supplied encryption keys (CSEK) for tables.

D. Data at rest is encrypted by default with Google-managed keys, with no configuration needed.

E. Data in transit between clients and Google Cloud services is protected with TLS.

BAHASA INDONESIA

Seorang compliance officer baru bertanya bagaimana data dienkripsi di BigQuery dan Cloud Storage. DUA pernyataan mana yang benar? (Pilih dua.)

A. Menonaktifkan key CMEK tidak berpengaruh pada akses ke data yang dilindunginya.

B. Anda wajib mengaktifkan CMEK, jika tidak data at rest disimpan tanpa enkripsi.

C. BigQuery mendukung customer-supplied encryption key (CSEK) untuk tabel.

D. Data at rest dienkripsi secara default dengan key yang dikelola Google, tanpa konfigurasi tambahan.

E. Data in transit antara klien dan layanan Google Cloud dilindungi dengan TLS.

✔ Jawaban benar: D, E

Kenapa benar: Google Cloud selalu mengenkripsi data at rest secara default (Google-managed encryption keys), dan data in transit ke endpoint Google dilindungi TLS. CMEK adalah opsi tambahan untuk kontrol key, bukan syarat agar data terenkripsi.

A salah: Disable key CMEK membuat data tidak bisa diakses. Itulah salah satu tujuan CMEK.

B salah: Enkripsi at rest selalu aktif. CMEK hanya mengubah siapa yang mengendalikan key.

C salah: BigQuery tidak mendukung CSEK. Opsinya adalah default encryption atau CMEK. CSEK tersedia di Cloud Storage.

Soal 60

Section 4 · Data Management

ENGLISH

An engineer accidentally deleted the BigQuery table analytics.events 2 days ago. The dataset uses the default time travel window, and no snapshots or backups exist. What should you do to recover the table?

A. Nothing, because deleted BigQuery tables can never be recovered.

B. Restore it from Cloud Storage Object Versioning.

C. Restore it within the time travel window, for example by copying analytics.events@<timestamp before deletion> to a new or the original table with bq cp.

D. Ask the Cloud SQL team to run point-in-time recovery.

BAHASA INDONESIA

Seorang engineer tidak sengaja menghapus tabel BigQuery analytics.events 2 hari lalu. Dataset memakai jendela time travel default, dan tidak ada snapshot atau backup. Apa yang harus dilakukan untuk memulihkan tabel?

A. Tidak ada, karena tabel BigQuery yang dihapus tidak pernah bisa dipulihkan.

B. Pulihkan dari Object Versioning Cloud Storage.

C. Pulihkan dalam jendela time travel, misalnya dengan menyalin analytics.events@<timestamp sebelum penghapusan> ke tabel baru atau tabel asli memakai bq cp.

D. Minta tim Cloud SQL menjalankan point-in-time recovery.

✔ **Jawaban benar: C**

Kenapa benar: Time travel BigQuery (default 7 hari, bisa diatur 2–7 hari) memungkinkan pemulihan tabel yang terhapus dengan menyalin snapshot pada waktu sebelum penghapusan. Contohnya bq cp dataset.table@EPOCH_MS dataset.table_restored. Setelah jendela time travel lewat, ada fail-safe 7 hari yang hanya bisa diakses lewat Cloud Customer Care.

A salah: Salah, karena time travel justru dirancang untuk kasus ini.

B salah: Object Versioning berlaku untuk objek Cloud Storage, bukan tabel BigQuery.

D salah: PITR Cloud SQL tidak berhubungan dengan BigQuery.

Ringkasan Kunci Jawaban

Kolom "Jawabanku" dan "✓/✗" diisi sendiri saat latihan.

No	Domain	Kunci	Jawabanku	✓/✗
1	Data Preparation & Ingestion	**D**		
2	Data Preparation & Ingestion	**D**		
3	Data Preparation & Ingestion	**B**		
4	Data Preparation & Ingestion	**D**		
5	Data Preparation & Ingestion	**B**		
6	Data Preparation & Ingestion	**C**		
7	Data Preparation & Ingestion	**C**		
8	Data Preparation & Ingestion	**B**		
9	Data Preparation & Ingestion	**A**		
10	Data Preparation & Ingestion	**C**		
11	Data Preparation & Ingestion	**A**		
12	Data Preparation & Ingestion	**A**		
13	Data Preparation & Ingestion	**C**		
14	Data Preparation & Ingestion	**A**		
15	Data Preparation & Ingestion	**A, B** (pilih dua)		
16	Data Preparation & Ingestion	**B**		
17	Data Preparation & Ingestion	**B**		
18	Data Preparation & Ingestion	**D**		
19	Data Analysis & Presentation	**C**		
20	Data Analysis & Presentation	**A**		
21	Data Analysis & Presentation	**C**		
22	Data Analysis & Presentation	**C, D** (pilih dua)		
23	Data Analysis & Presentation	**A**		
24	Data Analysis & Presentation	**D**		
25	Data Analysis & Presentation	**C**		
26	Data Analysis & Presentation	**A**		
27	Data Analysis & Presentation	**A**		
28	Data Analysis & Presentation	**C**		
29	Data Analysis & Presentation	**C**		
30	Data Analysis & Presentation	**D**		
31	Data Analysis & Presentation	**D**		

32	Data Analysis & Presentation	**D**		
33	Data Analysis & Presentation	**A**		
34	Data Analysis & Presentation	**D**		
35	Data Pipeline Orchestration	**B**		
36	Data Pipeline Orchestration	**A**		
37	Data Pipeline Orchestration	**B**		
38	Data Pipeline Orchestration	**D**		
39	Data Pipeline Orchestration	**B**		
40	Data Pipeline Orchestration	**A**		
41	Data Pipeline Orchestration	**C**		
42	Data Pipeline Orchestration	**B**		
43	Data Pipeline Orchestration	**B, E** (pilih dua)		
44	Data Pipeline Orchestration	**D**		
45	Data Pipeline Orchestration	**C**		
46	Data Management	**C**		
47	Data Management	**A, E** (pilih dua)		
48	Data Management	**B**		
49	Data Management	**D**		
50	Data Management	**D**		
51	Data Management	**A**		
52	Data Management	**B**		
53	Data Management	**A**		
54	Data Management	**B**		
55	Data Management	**A**		
56	Data Management	**D, E** (pilih dua)		
57	Data Management	**B**		
58	Data Management	**B**		
59	Data Management	**D, E** (pilih dua)		
60	Data Management	**C**		

Rekap Skor per Domain

Domain	Jumlah soal	Benar	%
Section 1 · Data Preparation & Ingestion	18		
Section 2 · Data Analysis & Presentation	16		
Section 3 · Data Pipeline Orchestration	11		
Section 4 · Data Management	15		
Total	**60**		

Google tidak mempublikasikan nilai kelulusan (passing score) ujian ini. Sebagai patokan pribadi, targetkan ≥ 80–85% secara konsisten pada soal yang belum pernah kamu lihat sebelum menjadwalkan ujian.